UNIVERSIDAD NACIONAL DE ROSARIO
Facultad de Ciencias Económicas y Estadística

Imputación de Datos Faltantes en Series Temporales Univariadas: Evaluación Basada en Desempeño de Pronóstico

Tesina de grado

Carrera: Licenciatura en Estadística
Alumno: Sánchez Travella, Joaquín
Directora: Mag. Méndez, Fernanda

Año 2026

Agradecimientos

Resumen

Las series temporales univariadas constituyen una herramienta fundamental para el análisis y la predicción de fenómenos que evolucionan a lo largo del tiempo en múltiples áreas de aplicación. Sin embargo, en la práctica es frecuente la presencia de datos faltantes, lo que puede afectar tanto la calidad del análisis como el desempeño de los modelos predictivos. En este contexto, la imputación de valores faltantes surge como una estrategia clave para completar las series o estimar valores faltantes y permitir la aplicación de métodos de modelado y pronóstico.

El presente trabajo tiene como objetivo evaluar y comparar distintos métodos de imputación de datos faltantes en series temporales univariadas, incorporando como criterio principal el desempeño de pronóstico posterior, bajo el enfoque conocido como *forecast-after-imputation*. A diferencia de gran parte de la literatura existente, que se centra en la calidad de los datos imputados, este estudio analiza el impacto de las distintas técnicas de imputación sobre la capacidad predictiva de los modelos ajustados a partir de las series completas.

Para ello, se propone un esquema de simulación basado en series temporales completas a las que se les introducen valores faltantes de manera artificial, considerando distintos mecanismos de ausencia, patrones de observaciones faltantes y niveles de pérdida de información. Sobre estos datos incompletos se aplican diversos métodos de imputación, que incluyen tanto enfoques simples como técnicas más avanzadas adaptadas a la estructura temporal de los datos. Posteriormente, se ajustan modelos de series temporales y se evalúa su desempeño mediante métricas de error de pronóstico, tales como RMSE (*Root Mean Square Error*), MAE (*Mean Absolute Error*) y MAPE (*Mean Absolute Percentage Error*), considerando distintos horizontes de predicción y un enfoque de evaluación fuera de muestra.

Los resultados obtenidos permiten analizar cómo la elección del método de imputación influye en la precisión de los pronósticos, evidenciando que no existe una técnica universalmente superior en todos los escenarios considerados, sino que su desempeño depende de las características de la serie y del tipo de datos faltantes. En particular, se identifican escenarios en los que ciertos métodos resultan más adecuados cuando el objetivo principal es mejorar la capacidad predictiva.

En conclusión, este trabajo aporta una perspectiva integral para la evaluación de métodos de imputación en series temporales univariadas, integrando el proceso completo desde la imputación hasta el pronóstico. Asimismo, proporciona recomendaciones prácticas orientadas a la selección de técnicas en función del objetivo de predicción, contribuyendo al desarrollo de estrategias más robustas para el análisis y la predicción en presencia de datos faltantes.

Palabras clave: Series temporales univariadas, datos faltantes, imputación, pronóstico, desempeño.

Tabla de contenidos

1 Introducción **6**

2 Objetivos **8**
2.1 Objetivo general . . . 8
2.2 Objetivos específicos . . . 8

3 Metodología **9**
3.1 Conceptos básicos de series de tiempo . . . 9
3.1.1 Tendencia . . . 10
3.1.2 Componente estacional . . . 10
3.1.3 Componente ciclo . . . 11
3.1.4 Componente aleatorio . . . 11
3.2 Autocorrelación . . . 12
3.2.1 Función de autocorrelación . . . 12
3.2.2 Función de autocorrelación parcial . . . 12
3.3 Datos faltantes en series temporales . . . 13
3.3.1 Tipos de datos faltantes . . . 13
3.4 Métodos de imputación . . . 14
3.4.1 Valor aleatorio . . . 15
3.4.2 Valor definido . . . 16
3.4.3 Valor medio . . . 16
3.4.4 Valor mediano . . . 17
3.4.5 Valor modal . . . 17
3.4.6 Interpolación lineal . . . 17
3.4.7 Interpolación spline . . . 18
3.4.8 Interpolación de Stineman . . . 19
3.4.9 Media móvil simple . . . 19
3.4.10 Media móvil lineal ponderada . . . 20
3.4.11 Media móvil ponderada exponencial . . . 21
3.4.12 Última observación trasladada hacia adelante . . . 22
3.4.13 Siguiente observación trasladada hacia atrás . . . 22
3.4.14 División estacional . . . 23
3.4.15 Descomposición estacional . . . 23
3.4.16 Suavizado de Kalman en un modelo estructural . . . 24
3.4.17 Representación del espacio en estados de ARIMA y suavizado de Kalman . . . 25
3.5 Técnicas de modelado . . . 26
3.5.1 Procesos Autorregresivos (AR) . . . 26
3.5.2 Procesos Promedio Móvil (MA) . . . 27
3.5.3 Procesos Autorregresivos de Media Móvil (ARMA) . . . 27
3.5.4 Procesos Autorregresivos Integrados de Media Móvil (ARIMA) . . . 28
3.5.5 Procesos Estacionales, Autorregresivos Integrados de Media Móvil (SARIMA) 28
3.6 Modelos de pronóstico . . . 29
3.6.1 Modelos ARIMA Y SARIMA . . . 29
3.6.2 Modelo ETS . . . 29
3.6.3 Modelo Prophet . . . 30

3.7 Evaluación del desempeño . . . 31
3.7.1 Evaluación del desempeño de los métodos de imputación . . . 31
3.7.2 Evaluación del desempeño del pronóstico posterior . . . 31
3.7.3 Métricas del error . . . 32

4 Aplicación **33**
Caso de aplicación: Consumo de electricidad . . . 34
4.1 Análisis descriptivo . . . 35
4.2 Resultados . . . 39
4.2.1 Datos faltantes completamente al azar (MCAR) . . . 39
4.2.2 Datos faltantes completamente al azar en bloques (MCAR en bloques) . . . 52
4.2.3 Datos faltantes no al azar (MNAR) . . . 64
4.3 Comparación entre mecanismos MCAR, MAR y MNAR . . . 75

5 Conclusiones **77**

6 Bibliografía **78**

7 Anexo **79**

1. Introducción

Las series temporales desempeñan un papel fundamental en el análisis y la predicción de fenómenos que evolucionan a lo largo del tiempo, siendo ampliamente utilizadas en diversas áreas como la economía, la meteorología, la salud y los negocios. A través de ellas es posible identificar patrones, tendencias y comportamientos recurrentes que permiten anticipar escenarios futuros y apoyar la toma de decisiones. Sin embargo, en la práctica, es frecuente que los datos observados presenten valores faltantes debido a múltiples causas, tales como errores en dispositivos de medición, fallas en sensores, restricciones en la recolección de datos o eventos imprevistos.

La presencia de datos faltantes constituye un desafío relevante, ya que un tratamiento inadecuado de estos valores puede generar sesgos en las estimaciones, afectar la inferencia y disminuir la precisión de los modelos predictivos. En este contexto, la imputación de datos surge como una estrategia clave para el tratamiento de valores ausentes, permitiendo estimar valores plausibles y preservar, en la medida de lo posible, la estructura temporal de la serie. Este aspecto resulta particularmente relevante en el análisis de series temporales, donde muchos métodos de modelado y pronóstico requieren series completas para su correcta implementación.

Existen diversos métodos de imputación para series temporales univariadas, que van desde técnicas simples —como la imputación por media, interpolación o el método de último valor observado— hasta enfoques más complejos basados en la estructura temporal de la serie o en modelos estadísticos, como el suavizamiento de Kalman o los modelos ARIMA. No obstante, no existe un método de imputación que resulte óptimo en todos los contextos, ya que su desempeño depende de las características de la serie, del mecanismo de generación de los datos faltantes y de la estructura temporal subyacente.

En la mayoría de los estudios, la evaluación de los métodos de imputación se centra exclusivamente en la precisión de los valores reconstruidos, comparando los datos imputados con los valores reales mediante distintas métricas de error. Sin embargo, en muchos contextos aplicados, la imputación no constituye un objetivo en sí mismo, sino un paso previo para tareas posteriores, como el modelado y el pronóstico de series temporales. En consecuencia, resulta relevante analizar no solo qué tan bien un método de imputación logra aproximar los valores faltantes, sino también cómo afecta el desempeño de los modelos de pronóstico ajustados sobre las series imputadas.

Esta perspectiva permite evaluar si los métodos que presentan menor error de imputación son también aquellos que generan mejores predicciones, cuestión que no siempre ha sido abordada de manera sistemática en la literatura. En este sentido, se identifica un vacío en relación con la evaluación conjunta de la imputación y el desempeño predictivo, particularmente en el contexto de series temporales univariadas.

Como antecedente directo, este trabajo se apoya en la tesina de Tamplin (2025), en la cual se evaluaron distintos métodos de imputación mediante simulaciones de datos faltantes y métricas de precisión como RMSE, MAE y MAPE. La presente tesina propone extender dicho enfoque incorporando un criterio adicional de evaluación basado en el desempeño de pronóstico posterior (*forecast-after-imputation*), integrando así ambas dimensiones en un mismo marco metodológico.

En este marco, el objetivo del trabajo es analizar el desempeño de distintos métodos de imputación no solo en función de su capacidad de reconstrucción, sino también en función de su impacto sobre la calidad de los pronósticos generados a partir de las series imputadas. De este modo, se busca aportar

evidencia empírica que permita orientar la selección de métodos de imputación en situaciones donde el interés principal radica en la predicción.

La estructura del trabajo se organiza en siete capítulos, incluyendo la presente introducción. En el Capítulo 2 se presentan los objetivos de la tesina, mientras que en el Capítulo 3 se describe la metodología empleada. En el Capítulo 4 se desarrollan los experimentos de simulación, en los que se utilizan series temporales completas a las que se les introducen valores faltantes de manera controlada, con el objetivo de evaluar el efecto que distintos métodos de imputación tienen tanto sobre la reconstrucción de los datos como sobre el desempeño de los modelos de pronóstico. En el Capítulo 5 se presentan las conclusiones del trabajo y se proponen posibles líneas de investigación futura. Finalmente, en los Capítulos 6 y 7 se incluyen las referencias bibliográficas y los anexos, respectivamente.

2. Objetivos

2.1. Objetivo general

El objetivo principal de la tesina es analizar y comparar distintos métodos de imputación de datos faltantes en series temporales univariadas, considerando como criterio principal de evaluación el impacto de dichas técnicas sobre el desempeño de los modelos de pronóstico.

2.2. Objetivos específicos

- Revisar la literatura sobre métodos de imputación de datos faltantes en series temporales univariadas y su relación con tareas de pronóstico.
- Seleccionar un conjunto representativo de métodos de imputación que incluya técnicas simples, métodos basados en la estructura temporal de la serie y enfoques basados en modelos.
- Diseñar un esquema de simulación que contemple distintos mecanismos de datos faltantes (MCAR, MAR temporal y MNAR), así como diferentes patrones de ausencia (dispersos y en bloques) y niveles de pérdida de información.
- Construir un *pipeline* de procesamiento reproducible que integre de forma secuencial la generación de datos faltantes, la aplicación de técnicas de imputación, el ajuste de modelos de series temporales y la generación de predicciones.
- Comparar la eficacia de los métodos mediante el uso de métricas de error de imputación (RMSE, MAE y MAPE) en conjunto con métricas de desempeño de pronóstico para horizontes de tiempo de corto y mediano plazo ($h = 3, 6$ y 12).
- Validar el desempeño de los métodos mediante su aplicación a series temporales reales.
- Derivar recomendaciones prácticas fundamentadas en los resultados obtenidos, que permitan identificar qué técnicas de imputación resultan más adecuadas según la estructura de la serie y el objetivo específico de mejorar la predicción.

3. Metodología

3.1. Conceptos básicos de series de tiempo

Una serie temporal se define como una secuencia de observaciones ordenadas en el tiempo calendario, resultado de registrar los valores de una variable en intervalos generalmente regulares a lo largo del tiempo. Estos intervalos de tiempo definen la periodicidad (diaria, mensual, anual, etc.). Una característica fundamental de las series temporales es la dependencia entre sus observaciones, lo que implica que el orden en que estas ocurren resulta relevante para su análisis. En consecuencia, los métodos estadísticos basados en el supuesto de independencia entre observaciones no son directamente aplicables, por lo que se requieren enfoques específicos que tengan en cuenta la estructura temporal de los datos.

Formalmente, una serie temporal se define como un conjunto de variables aleatorias indexadas en el tiempo, $Y_1, ..., Y_T$. En este sentido, una serie temporal observada se denota por $y_1, ..., y_T$, donde el subíndice i indica el tiempo al que pertenece la observación y_i. El primer valor observado y_1 puede interpretarse como una realización de la variable aleatoria Y_1. Del mismo modo, y_2 es una realización de Y_2 y así sucesivamente. Las variables aleatorias Y_1, Y_2,..., Y_T no necesariamente son idénticamente distribuidas.

Los fenómenos observados mediante series temporales pueden clasificarse en dos clases. Los primeros son los que toman valores estables en el tiempo alrededor de un nivel constante, sin mostrar una tendencia a crecer o a decrecer a largo plazo. Estos procesos se denominan estacionarios. Por otro lado, existen los procesos no estacionarios, que son aquellos que pueden mostrar tendencia, estacionalidad y otros efectos evolutivos en el tiempo. En las series estacionarias, la media y varianza se mantienen constantes en el tiempo y la covarianza entre observaciones depende únicamente del rezago y no del tiempo en sí, mientras que en las no estacionarias, estas características cambian a través del tiempo.

Para un proceso $\{Y_t : t = 0, \pm 1, \pm 2, ... \}$ se define:

- La función media del proceso:
$$E(Y_t) = \mu_t \tag{1}$$
- La función varianza del proceso:
$$\sigma_t^2 = E(Y_t - \mu_t)^2 \tag{2}$$
- La función covarianza entre Y_{t_1} y Y_{t_2}:
$$\gamma(t_1, t_2) = E(Y_{t_1} - \mu_{t_1})(Y_{t_2} - \mu_{t_2}) \tag{3}$$

En un proceso estacionario resulta:

$$\mu_t = \mu, \quad \forall t \tag{4}$$
$$\sigma_t^2 = \sigma^2, \quad \forall t \tag{5}$$
$$\gamma(t_1, t_2) = \gamma(t_1 + k, t_2 + k), \quad \forall\, t_1, t_2 \text{ y } k \tag{6}$$

En este contexto, resulta útil descomponer una serie temporal en sus principales componentes no observables, ya que estos permiten interpretar y modelar su comportamiento a lo largo del tiempo. En particular, la presencia de tendencia, estacionalidad, ciclos y un componente aleatorio está estrechamente relacionada con la noción de no estacionariedad, dado que estos elementos introducen cambios sistemáticos en la media o en la estructura de dependencia de la serie. A continuación, se presentan definiciones más precisas de estos componentes, fundamentales para el análisis y modelado de series temporales.

3.1.1. Tendencia

La tendencia representa el comportamiento a largo plazo de una serie temporal, reflejando la evolución sostenida de la variable a lo largo del tiempo. Este componente describe la dirección general en la que se desplazan los datos, pudiendo manifestarse como un crecimiento, decrecimiento o estabilidad en el nivel medio de la serie. La tendencia no necesariamente es lineal, ya que puede presentar formas más complejas, como curvaturas o cambios en la pendiente, asociados a transformaciones estructurales del fenómeno analizado.

La presencia de tendencia implica que la media de la serie no permanece constante en el tiempo, lo que constituye una fuente de no estacionariedad. La identificación y modelado de la tendencia resultan fundamentales, ya que permiten separar el comportamiento estructural de largo plazo de otras fluctuaciones de menor escala. En muchos contextos aplicados, la tendencia se asocia a factores como crecimiento económico, cambios tecnológicos o evolución demográfica, entre otros.

3.1.2. Componente estacional

La estacionalidad se refiere a la existencia de patrones que se repiten de manera sistemática en intervalos de tiempo fijos y conocidos. Estos patrones suelen estar asociados a factores externos recurrentes, como las estaciones del año, los meses, los días de la semana o incluso las horas dentro del día. A diferencia de otros componentes, la estacionalidad presenta una periodicidad constante, lo que permite su identificación mediante herramientas descriptivas y su modelado a través de métodos específicos.

Se dice que una serie es estacional cuando su valor esperado no es constante, pero varía con una pauta cíclica. En concreto, si:

$$E(y_t) = E(y_{t+s}) \tag{7}$$

se dice que la serie tiene una estacionalidad de periodo s. El periodo estacional, s, define el número de observaciones que forma el ciclo estacional. Por ejemplo, $s = 12$ para series mensuales, $s = 4$ para series trimestrales, etc. Se supone que el valor de s es fijo en la serie. Es importante notar que puede existir mas de un tipo de estacionalidad en una serie.

Desde una perspectiva analítica, la estacionalidad introduce variaciones sistemáticas en la serie que dependen del momento dentro del ciclo temporal considerado. Esto implica que observaciones correspondientes a un mismo período dentro de distintos ciclos (por ejemplo, el mismo mes en diferentes años) tienden a presentar comportamientos similares. La adecuada identificación de este componente es esencial, ya que su omisión puede distorsionar el análisis de la tendencia y afectar la precisión de los modelos de pronóstico.

3.1.3. Componente ciclo

Los ciclos corresponden a fluctuaciones de la serie temporal que se desarrollan en horizontes de mediano y largo plazo, pero que no presentan una periodicidad fija ni conocida. A diferencia de la estacionalidad, cuya duración es constante, los ciclos pueden variar en su extensión, intensidad y forma, lo que dificulta su identificación y modelado. Este componente refleja cambios en la dinámica subyacente del fenómeno que no responden a patrones regulares, sino a procesos más complejos.

En muchos casos, los ciclos se asocian a fenómenos económicos, como expansiones y recesiones, aunque también pueden aparecer en otros contextos. Su duración suele ser mayor a la de los efectos estacionales y, en general, no existe un período predeterminado que permita anticipar su repetición. Desde el punto de vista del análisis de series temporales, los ciclos representan una fuente adicional de variabilidad que puede influir en la estructura de dependencia de la serie y en su comportamiento a largo plazo.

3.1.4. Componente aleatorio

El componente aleatorio, también denominado irregular o ruido, recoge la variabilidad de la serie temporal que no puede ser explicada por los componentes sistemáticos como la tendencia, la estacionalidad o los ciclos. Este componente representa fluctuaciones impredecibles originadas por factores no observados, errores de medición o variaciones inherentes al fenómeno bajo estudio.

En términos estadísticos, suele modelarse como un proceso estocástico con media cero y varianza constante, aunque en la práctica puede presentar estructuras más complejas, como heterocedasticidad o dependencia temporal. A diferencia de los componentes anteriores, el componente aleatorio no presenta una estructura sistemática identificable, lo que limita la capacidad de modelado determinístico. Sin embargo, su correcta caracterización es fundamental, ya que determina el nivel de incertidumbre asociado al análisis y establece un límite natural a la precisión de los pronósticos.

Las irregularidades pueden tener un impacto significativo en la precisión de los modelos de series temporales y en las previsiones, ya que pueden ocultar las tendencias subyacentes y los patrones de estacionalidad en los datos.

En conjunto, la identificación y análisis de estos componentes permiten comprender la estructura subyacente de una serie temporal, facilitando tanto su modelado como la formulación de pronósticos más precisos.

Una serie temporal, $Y_1, Y_2, \dots, Y_T$, puede descomponerse en sus componentes fundamentales mediante modelos de descomposición. En particular, el modelo aditivo se expresa como:

$$Y_t = T_t + E_t + C_t + A_t \tag{8}$$

donde: T_t representa la tendencia, E_t la componente estacional, C_t los ciclos y A_t la componente aleatoria.

Por otro lado, el modelo multiplicativo se define como:

$$Y_t = T_t \times E_t \times C_t \times A_t \tag{9}$$

el cual resulta más adecuado cuando la magnitud de las variaciones estacionales o cíclicas depende del nivel de la serie.

3.2. Autocorrelación

La autocorrelación es una medida fundamental en el análisis de series temporales que permite cuantificar el grado de dependencia existente entre observaciones de una misma serie en distintos momentos del tiempo. A diferencia de los datos independientes, en una serie temporal los valores suelen estar relacionados con sus propios valores pasados, lo que implica que la información contenida en una observación puede aportar conocimiento sobre observaciones futuras o pasadas. Esta dependencia temporal constituye una de las características distintivas de las series temporales y es clave para su modelado.

El estudio de la autocorrelación resulta esencial en la práctica, ya que proporciona información relevante sobre la estructura interna de la serie y orienta la selección de modelos adecuados para su análisis y pronóstico. En particular, muchas metodologías de modelado de series temporales se basan explícitamente en la forma en que las observaciones se correlacionan a lo largo del tiempo, lo que convierte a la autocorrelación en una herramienta central dentro del análisis estadístico de datos temporales.

3.2.1. Función de autocorrelación

La función de autocorrelación constituye una herramienta fundamental para el análisis de la dependencia temporal en una serie. Esta función describe cómo se correlacionan las observaciones de la serie con sus propios valores pasados en función del rezago considerado. En particular, permite analizar el grado de asociación lineal entre observaciones separadas por distintos intervalos de tiempo, proporcionando una visión global de la estructura de dependencia de la serie.

Para cada rezago k, la función de autocorrelación mide la intensidad de la relación lineal entre Y_t y Y_{t+k}, tomando valores comprendidos entre -1 y 1. Valores cercanos a 1 indican una fuerte correlación positiva, mientras que valores próximos a -1 reflejan una correlación negativa. Por su parte, valores cercanos a cero sugieren ausencia de dependencia lineal significativa para ese rezago. En el caso de series temporales estacionarias, la función de autocorrelación depende únicamente del rezago y no del tiempo, lo que simplifica su análisis e interpretación.

Formalmente, la autocorrelación para un rezago se calcula utilizando la siguiente fórmula:

$$\rho_k = \frac{\sum_{t=k+1}^{T}(y_t - \bar{y})(y_{t-k} - \bar{y})}{\sum_{t=1}^{T}(y_t - \bar{y})^2} \tag{10}$$

3.2.2. Función de autocorrelación parcial

La función de autocorrelación parcial constituye una herramienta complementaria a la función de autocorrelación, permitiendo analizar la dependencia directa entre observaciones de una serie temporal. Mientras que la autocorrelación mide la relación total entre y_t y y_{t+h}, la autocorrelación parcial evalúa la relación entre estas dos observaciones una vez eliminada la influencia de los valores intermedios comprendidos entre ambos momentos.

En otras palabras, la autocorrelación parcial mide el grado de dependencia lineal "pura" entre dos observaciones separadas por un rezago h, controlando por los efectos de los rezagos menores. Esto

permite aislar la contribución específica de cada rezago en la estructura de dependencia de la serie, evitando la superposición de efectos indirectos presentes en la función de autocorrelación.

El análisis de la función de autocorrelación parcial resulta especialmente útil en la identificación de modelos de series temporales, en particular en la determinación del orden de los modelos autorregresivos. De este modo, junto con la función de autocorrelación, constituye una herramienta fundamental en el análisis exploratorio y en el proceso de modelado de series temporales.

3.3. Datos faltantes en series temporales

En el desarrollo teórico de numerosos modelos y técnicas estadísticas, a menudo no se consideran ciertas situaciones que surgen en la práctica, entre las cuales se destaca la presencia de datos faltantes, también denominados valores perdidos o incompletos. Esta problemática es especialmente frecuente en el análisis de series temporales, donde es habitual encontrar observaciones ausentes dentro de la secuencia de datos.

Desde un punto de vista metodológico, no todos los datos faltantes presentan las mismas características ni tienen el mismo impacto sobre el análisis. En particular, la forma en que se generan los valores ausentes, conocida como mecanismo de faltantes, resulta fundamental para determinar el enfoque más adecuado para su tratamiento. Ignorar este aspecto puede conducir a la aplicación de métodos inapropiados y, en consecuencia, a conclusiones erróneas.

En este sentido, la literatura estadística distingue tres mecanismos principales de generación de datos faltantes: faltantes completamente al azar (MCAR), faltantes al azar (MAR) y faltantes no al azar (MNAR). Cada uno de estos mecanismos implica distintos supuestos sobre la relación entre la ausencia de datos y la información observada o no observada, lo que influye directamente en la elección y el desempeño de los métodos de imputación.

3.3.1. Tipos de datos faltantes

Hay varios tipos de observaciones faltantes:

- Datos faltantes completamente al azar (Missing Completely at Random, MCAR). Los datos faltantes siguen un patrón aleatorio; la probabilidad de que un valor esté perdido es independiente tanto del valor de esta variable como del valor de otras variables del conjunto de datos. La ausencia de información no procede de ninguna variable presente en la matriz de datos, ya que la base de datos se interpreta como una matriz en donde los renglones son las unidades de observación y las columnas representan a las variables de interés. Hay que señalar que, en la práctica, la hipótesis de este supuesto no siempre es satisfactoria porque la falta de respuesta se asocia a características personales.
- Datos faltantes al azar (Missing at Random, MAR). La probabilidad de que una respuesta sea dato faltante es independiente de los valores de la variable pero es dependiente de los valores de otras variables del conjunto de datos. En suma, la ausencia de datos está asociada a variables presentes en la matriz de datos. Por ejemplo, este supuesto, es usual en las encuestas de hogares que estudian el nivel socioeconómico, donde la falta de respuesta en la variable ingreso en las familias está correlacionada con sus ingresos y por lo tanto no se cumple el supuesto. En cambio, cuando la omisión ocurre en la categoría ocupacional, la falta de información no

necesariamente está correlacionada con el nivel de ingresos de las personas y por lo tanto sí se cumple el supuesto.

- Datos no faltantes al azar (Missing not at random, MNAR). La probabilidad de que una respuesta a una variable sea dato faltante es dependiente de los valores de la variable. Por ejemplo, en el estudio de las variables peso y edad; los sujetos con mayores valores de peso tienen un porcentaje de datos faltantes más elevado en esta variable para aquellos individuos con la misma edad. Este tipo de dato faltante también se denomina no ignorable.

Para series temporales univariadas, el panorama de los mecanismos de datos faltantes es ligeramente diferente. A primera vista, solo hay una variable en los datos. Sin embargo, el tiempo (que se da implícitamente) debe tratarse como una variable al determinar el mecanismo de datos faltantes de un conjunto de datos. Otra diferencia radica en que los algoritmos de imputación de series temporales no necesitan basarse únicamente en covariables para la estimación de valores faltantes, sino que también pueden utilizar las características de las series temporales.

En el contexto de series temporales univariadas, los mecanismos MCAR y MAR pueden presentar algunas similitudes desde el punto de vista de la imputación, dado que en ambos casos los métodos pueden aprovechar la información observada y la estructura temporal de la serie para estimar los valores faltantes. Sin embargo, ambos mecanismos difieren en el proceso que genera la ausencia: bajo MCAR, la probabilidad de que una observación esté ausente no depende de los datos, mientras que bajo MAR puede depender de información observada, como el tiempo o valores previos de la serie.

Por otro lado, en el caso de datos faltantes que no faltan al azar (MNAR), la probabilidad de que falte una observación puede depender del momento en que se encuentra esa observación en la serie, así como del valor de la propia observación.

En la práctica, no es posible verificar con certeza cuál es el mecanismo de generación de los datos faltantes únicamente a partir de los datos observados. Por este motivo, la clasificación en MCAR, MAR y MNAR suele basarse en supuestos teóricos y conocimiento del contexto en el que se generaron los datos.

No obstante, esta distinción resulta fundamental, ya que los diferentes métodos de imputación se basan en supuestos implícitos sobre el mecanismo de faltantes. En consecuencia, la elección de la técnica más adecuada requiere considerar qué supuesto resulta más plausible en cada situación.

3.4. Métodos de imputación

La existencia de valores faltantes introduce diversas dificultades en el análisis, ya que puede afectar la estimación de parámetros, distorsionar la identificación de patrones y limitar la aplicación de ciertos métodos que requieren series completas. En consecuencia, su tratamiento constituye una etapa fundamental dentro del preprocesamiento de los datos. Entre las distintas estrategias disponibles, la imputación se presenta como una de las más utilizadas.

Se denomina imputación al proceso que utiliza la información procedente de la muestra para asignar un valor a aquellos registros con valor ausente, ya sea porque se carece de información o porque se detecta que algunos de los valores obtenidos no se corresponden con el comportamiento esperado. Existen diversos métodos de imputación que difieren tanto en la información que utilizan como en

la forma en que generan los valores imputados. La elección del método más adecuado dependerá de las características de la serie, la estructura de los datos faltantes y el objetivo del análisis.

La imputación de datos faltantes es más sencilla cuando estos ocurren completamente al azar (MCAR). Esto se debe a que en el caso de MNAR, las observaciones faltantes pueden formar fragmentos lo suficientemente grandes como para ocultar los componentes estructurales de las series temporales. Sin embargo, si la serie temporal presenta una estructura temporal bien definida, los métodos de imputación que aprovechan características como la estacionalidad, los ciclos y la autocorrelación pueden tener una ventaja sobre otros métodos más simples.

Una observación muy importante es que la eficiencia de cada técnica depende del conjunto de datos. Esto significa que cada técnica funciona de manera diferente dependiendo de la estructura de cada serie temporal; en otras palabras, no existe un método único que se adapte a todos los tipos de datos. Esto debe tomarse seriamente en cuenta al intentar elegir un método apropiado para la imputación de múltiples datos en series temporales. Por lo tanto, es necesario analizar las características específicas de la serie temporal con datos faltantes y, a partir de ese análisis, seleccionar el procedimiento de imputación que mejor se adapte a dicha estructura.

A continuación, se describen los métodos de imputación que serán evaluados en cada situación.

3.4.1. Valor aleatorio

Para reemplazar cada valor faltante en la serie temporal, se selecciona aleatoriamente uno de los valores observados de la serie (todos con igual probabilidad de ser seleccionados). El procedimiento se repite para cada dato faltante, lo que puede resultar en diferentes imputaciones para distintos valores faltantes, incluso dentro de la misma brecha.

A diferencia de métodos determinísticos, la imputación aleatoria permite preservar, al menos parcialmente, la variabilidad de los datos, evitando la subestimación de la varianza que suele ocurrir en enfoques más simples, como la imputación por la media.

Entre sus ventajas, se destaca su simplicidad de implementación y su flexibilidad, ya que no requiere supuestos complejos sobre la estructura de los datos. Además, al introducir variabilidad en los valores imputados, permite reflejar en cierta medida la incertidumbre asociada a los datos faltantes.

Sin embargo, este método presenta importantes limitaciones, especialmente en el contexto de series temporales. En particular, no tiene en cuenta la dependencia temporal entre observaciones, como la autocorrelación o la estacionalidad, lo que puede generar imputaciones poco realistas. Asimismo, la naturaleza aleatoria del procedimiento puede introducir ruido artificial en la serie, afectando la coherencia de los datos imputados.

En resumen, este procedimiento puede resultar adecuado en contextos donde la serie no presenta una estructura temporal marcada, es decir, en ausencia de tendencias, estacionalidad o fuerte autocorrelación. Asimismo, su uso puede ser razonable cuando el porcentaje de datos faltantes es reducido o cuando se emplea como referencia en estudios comparativos. Sin embargo, su aplicabilidad es limitada en series con patrones temporales definidos, donde la preservación de la dinámica de la serie resulta fundamental.

3.4.2. Valor definido

La imputación por valor definido consiste en reemplazar los valores faltantes por un valor fijo previamente establecido. Este valor puede ser seleccionado con base en el conocimiento previo del fenómeno que se está modelando o por conveniencia en situaciones específicas.

Una de las principales características de este método es su naturaleza determinística, ya que, dado un conjunto de datos, siempre produce el mismo resultado. Además, se trata de un enfoque sumamente simple desde el punto de vista computacional, lo que facilita su implementación incluso en conjuntos de datos de gran tamaño. Sin embargo, esta simplicidad implica que el método no tiene en cuenta la estructura temporal de la serie ni las posibles relaciones entre las observaciones.

Este método presenta importantes limitaciones, ya que la imputación por un valor constante tiende a distorsionar la distribución de los datos, dado que introduce una concentración artificial de valores en el punto elegido. Esto puede afectar la estimación de parámetros, reducir la variabilidad de la serie y generar sesgos en el análisis. Además, al no considerar la dependencia temporal, los valores imputados pueden resultar inconsistentes con la dinámica de la serie. Por este motivo, la imputación por valor definido suele utilizarse en situaciones muy específicas o como punto de comparación, más que como una solución adecuada para preservar la información temporal de la serie.

3.4.3. Valor medio

El método de imputación por el valor medio es una técnica simple que consiste en reemplazar los valores faltantes en una serie temporal con el valor medio de los datos observados. El proceso es bastante directo: se calcula la media aritmética de los valores no faltantes de la serie, y este valor se utiliza para imputar todos los datos faltantes.

Dicho método se caracteriza por ser determinístico y de muy sencilla implementación, ya que solo requiere el cálculo de un estadístico resumen. Sin embargo, al igual que otros métodos simples, no tiene en cuenta la estructura temporal de la serie, ignorando posibles patrones como la tendencia, la estacionalidad o la autocorrelación.

Entre sus principales ventajas se destaca su simplicidad y rapidez de aplicación. Además, permite mantener el valor medio de la serie, lo cual puede resultar útil en ciertos análisis descriptivos donde la media es una medida de interés. Por otro lado, esta técnica presenta importantes desventajas. En particular, tiende a subestimar la variabilidad de los datos, ya que reemplaza múltiples valores por un mismo valor constante. Esto genera una reducción artificial de la varianza y puede distorsionar la distribución de la serie.

Estas limitaciones pueden afectar negativamente el desempeño de los modelos, ya que la alteración de la variabilidad y de la estructura temporal puede conducir a estimaciones sesgadas y a una menor precisión en las predicciones. Por este motivo, la imputación por la media suele considerarse como un método básico o de referencia, más que como una técnica adecuada cuando se busca preservar la dinámica temporal de la serie. Esta técnica es más adecuada para situaciones en las que la serie tiene pocos valores faltantes y los datos no presentan grandes variaciones a lo largo del tiempo.

Es importante destacar que este método constituye un caso particular de la imputación por valor definido, donde el valor elegido corresponde a la media de los datos observados.

3.4.4. Valor mediano

La imputación por la mediana consiste en reemplazar los valores faltantes de una serie por la mediana calculada a partir de las observaciones disponibles. Al igual que en el caso de la media, este método asigna un valor constante a todos los datos faltantes, sin considerar la posición temporal de las observaciones dentro de la serie, siendo también un caso particular de la imputación por valor definido.

Este método se caracteriza por ser determinístico y de fácil implementación, ya que requiere únicamente el cálculo de un estadístico resumen. Una de sus principales particularidades es su robustez frente a valores atípicos, dado que la mediana no se ve afectada por observaciones extremas en la misma medida que la media. Sin embargo, al igual que otros métodos simples, no tiene en cuenta la estructura temporal de la serie, ignorando patrones como la tendencia, la estacionalidad y la autocorrelación, pudiendo afectar negativamente el modelado y el pronóstico.

3.4.5. Valor modal

La imputación por la moda consiste en reemplazar los valores faltantes por el valor más frecuente entre las observaciones disponibles. Al igual que otros métodos basados en estadísticos resumen, este enfoque asigna un único valor constante a todos los datos faltantes, sin tener en cuenta la posición temporal de las observaciones dentro de la serie, siendo de igual manera un caso particular de imputación por valor definido.

En este caso, se trata de una técnica determinística y de sencilla implementación, ya que solo requiere identificar el valor con mayor frecuencia en la serie. Es particularmente útil en series temporales categóricas o discretas, donde ciertos valores ocurren repetidamente, y puede ser una opción efectiva si la serie tiene un valor dominante que se presenta con frecuencia. Sin embargo, en el contexto de series temporales continuas puede no ser informativa o incluso no estar claramente definida.

La imputación por la moda presenta varias limitaciones. En primer lugar, introduce una concentración artificial de valores en el valor modal, lo que puede distorsionar la distribución de los datos. Asimismo, no tiene en cuenta la variabilidad ni la estructura temporal de la serie, ignorando patrones como la tendencia, la estacionalidad o la autocorrelación. En el caso de series continuas, su uso puede resultar poco apropiado si no existe un valor claramente predominante. Estas limitaciones pueden afectar negativamente el modelado y el pronóstico.

3.4.6. Interpolación lineal

La interpolación lineal es un método de imputación que estima los valores faltantes utilizando la información de las observaciones vecinas, asumiendo que la evolución entre dos puntos consecutivos conocidos sigue una trayectoria lineal. En otras palabras, cuando se presenta un valor faltante entre dos observaciones disponibles, el método construye una recta que une dichos puntos y asigna al dato ausente el valor correspondiente sobre esa recta.

Formalmente, si y_t es un valor faltante ubicado entre dos observaciones conocidas y_{t_1} y y_{t_2}, con $t_1 < t < t_2$, la imputación se realiza como una combinación lineal de estos valores, proporcional a la distancia temporal entre ellos. De este modo, el valor imputado refleja una transición suave

y continua entre los puntos observados, respetando la estructura temporal de la serie. El valor imputado queda definido como:

$$\hat{y_t} = y_{t_1} + \frac{(t - t_1)(y_{t_2} - y_{t_1})}{t_2 - t_1} \tag{11}$$

Este método es particularmente adecuado cuando la serie presenta cambios graduales y relativamente suaves, sin variaciones abruptas en cortos períodos de tiempo. Su principal ventaja radica en su simplicidad y en su capacidad para preservar la continuidad de la serie, evitando saltos artificiales. Sin embargo, puede resultar inadecuado en presencia de patrones no lineales, como cambios bruscos, estacionalidad marcada o comportamientos altamente volátiles, ya que tiende a suavizar en exceso la dinámica real de los datos.

3.4.7. Interpolación spline

La interpolación spline es un método de imputación que estima los valores faltantes mediante funciones polinómicas definidas por tramos, en lugar de utilizar una única recta entre dos puntos. En este enfoque, la serie se aproxima mediante una sucesión de polinomios de bajo grado (habitualmente cúbicos) que se ajustan entre pares de observaciones consecutivas, garantizando que la función resultante sea suave en todo el dominio.

El proceso comienza dividiendo la serie en intervalos adecuados, generalmente entre puntos de datos consecutivos o en función de la distribución de los datos disponibles. Luego, para cada intervalo, se ajusta un polinomio spline que asegura la continuidad en los puntos de unión (nodos) y, dependiendo de las condiciones de borde especificadas, puede garantizar continuidad en las derivadas.

A diferencia de la interpolación lineal, que asume una evolución constante entre dos puntos, la interpolación spline permite capturar curvaturas en los datos. Esto se logra imponiendo condiciones de continuidad no solo en los valores de la función, sino también en sus derivadas, lo que genera transiciones más naturales entre los puntos observados. Como resultado, los valores imputados siguen trayectorias suaves que reflejan mejor la dinámica subyacente de la serie.

Dicho enfoque es especialmente útil en series temporales donde se esperan cambios graduales pero no necesariamente lineales, como en procesos con tendencias suaves o componentes estacionales. Entre sus ventajas se destacan su flexibilidad y su capacidad para modelar estructuras más complejas que la interpolación lineal. Sin embargo, es importante tener en cuenta que la precisión de la interpolación puede verse afectada por la elección de los intervalos y la adecuación de los polinomios spline a los datos disponibles. Además, puede presentar dificultades cuando los datos son muy ruidosos o cuando existen valores atípicos, ya que los splines pueden generar oscilaciones indeseadas (fenómeno conocido como sobreajuste local).

Mientras que la interpolación lineal impone una estructura rígida basada en cambios constantes entre observaciones, la interpolación spline introduce mayor flexibilidad al permitir curvaturas suaves, lo que puede resultar más adecuado en series con dinámica no lineal.

3.4.8. Interpolación de Stineman

La interpolación de Stineman es un método de imputación que construye una función suave entre observaciones conocidas, con el objetivo de evitar las oscilaciones indeseadas que pueden aparecer en otros métodos más flexibles, como los splines. A diferencia de la interpolación spline, que utiliza polinomios por tramos con condiciones de suavidad global, el método de Stineman se basa en pendientes locales calculadas a partir de los puntos vecinos, lo que le permite adaptarse de manera más controlada a la forma de la serie.

Este método combina la simplicidad de la interpolación lineal con una mayor capacidad para reflejar la curvatura de los datos. En lugar de imponer una recta entre dos puntos, ajusta la trayectoria utilizando información sobre la dirección y magnitud de los cambios en los valores adyacentes, generando transiciones suaves pero evitando cambios bruscos o sobreajustes. De esta manera, logra una interpolación que respeta la tendencia local sin introducir fluctuaciones artificiales.

El proceso comienza identificando los puntos de datos más cercanos a cada valor faltante en la serie. Estos puntos actúan como referencias para determinar la forma de la función de interpolación de Stineman. En lugar de asumir una relación lineal entre puntos adyacentes, Stineman ajusta una función no lineal que se adapta mejor a la estructura y las variaciones de los datos disponibles.

La función de interpolación se ajusta minimizando una medida de discrepancia, como el error cuadrático medio o una función de penalización que considera las diferencias locales entre puntos de datos. Este proceso garantiza que la interpolación captura adecuadamente las fluctuaciones locales y asegura una transición suave entre los puntos conocidos. Una vez ajustada esta función, se utiliza para calcular los valores faltantes en la serie temporal. Para cada punto de tiempo sin datos, se evalúa la función interpolada para obtener la imputación correspondiente.

La interpolación de Stineman resulta especialmente adecuada en series temporales donde se desea preservar la forma general de los datos sin asumir una estructura estrictamente lineal ni permitir excesiva flexibilidad. Entre sus ventajas se destacan su estabilidad numérica y su capacidad para evitar oscilaciones no realistas. Sin embargo, como desventaja, puede no capturar adecuadamente patrones complejos o altamente no lineales, y su uso es menos extendido en comparación con métodos más tradicionales.

La interpolación de Stineman puede interpretarse como un compromiso entre la rigidez de la interpolación lineal y la flexibilidad de los splines, ofreciendo una alternativa que prioriza la estabilidad y la forma global de la serie.

3.4.9. Media móvil simple

La imputación mediante media móvil simple es un método que estima los valores faltantes utilizando el promedio de un conjunto de observaciones vecinas de la serie temporal. A diferencia de métodos globales, como la imputación por la media total, este enfoque aprovecha información local de la serie, considerando únicamente valores cercanos al instante en el que ocurre el dato faltante. De esta manera, la imputación se adapta parcialmente a la dinámica temporal de los datos.

El procedimiento consiste en reemplazar cada observación faltante por el promedio de las k observaciones más próximas, donde k representa el tamaño de la ventana de la media móvil. En este trabajo, la imputación mediante media móvil simple se implementa utilizando una ventana centrada, considerando observaciones anteriores y posteriores al dato faltante. Sin embargo, pueden realizarse la

imputación únicamente con valores anteriores al dato faltante, únicamente posteriores o una combinación de ambos. Como resultado, el valor imputado refleja el comportamiento promedio reciente de la serie, suavizando fluctuaciones de corto plazo.

De esta manera, la estimación puede expresarse como:

$$\hat{y}_t = \frac{1}{k} \sum_{i=1}^{k} y_i \tag{12}$$

donde:

- $\hat{y}_t$ es el valor imputado,
- y_i las observaciones vecinas utilizadas,
- k es el tamaño de la ventana.

Este método resulta especialmente útil en series relativamente estables, con cambios suaves y sin variaciones abruptas, ya que permite preservar parcialmente la estructura temporal local. Entre sus principales ventajas se encuentran su simplicidad de implementación y su capacidad para reducir el impacto del ruido. No obstante, la media móvil tiende a suavizar excesivamente la serie, reduciendo su variabilidad natural y dificultando la representación de cambios bruscos, picos o puntos de inflexión. Además, la elección del tamaño de la ventana puede influir significativamente en los resultados: ventanas pequeñas generan imputaciones más sensibles a fluctuaciones locales, mientras que ventanas grandes producen estimaciones más estables pero menos adaptadas a la dinámica inmediata de la serie.

3.4.10. Media móvil lineal ponderada

La imputación mediante media móvil lineal ponderada es un método que estima los valores faltantes utilizando un promedio ponderado de las observaciones vecinas de la serie temporal. A diferencia de la media móvil simple, donde todas las observaciones consideradas tienen la misma importancia, en este enfoque se asignan pesos diferentes a cada valor de la ventana.

El procedimiento consiste en definir una ventana alrededor de la observación ausente y calcular un promedio ponderado de los valores disponibles dentro de dicha ventana. Los pesos varían de manera lineal según la distancia temporal respecto al dato faltante, de modo que las observaciones más próximas reciben un peso mayor y las más alejadas un peso menor. Esto permite que la imputación refleje de manera más precisa la dinámica local de la serie, especialmente cuando existen cambios graduales en el tiempo.

La estimación del valor faltante está dada por:

$$\hat{y}_t = \frac{\sum_{i=1}^{k} w_i y_i}{\sum_{i=1}^{k} w_i} \tag{13}$$

donde:

- $\hat{y}_t$ es el valor imputado,
- y_i las observaciones vecinas utilizadas,

- w_i son los pesos asignados a cada observación,
- k es el tamaño de la ventana.

Los pesos w_i suelen sumar uno para asegurar que la media ponderada esté normalizada y refleje adecuadamente la contribución relativa de cada valor observado en la imputación del valor faltante. Estos pesos pueden ser predefinidos, basados en la distancia temporal o calculados dinámicamente según la estructura de los datos y la distribución de los valores observados.

La estimación por media móvil simple es un caso particular, en el cual:

$$w_i = \frac{1}{k}, \quad \forall i \tag{14}$$

Por lo tanto, la media móvil lineal ponderada constituye una generalización de la media móvil simple.

Este método resulta adecuado en series temporales donde las observaciones cercanas presentan mayor similitud entre sí que las más distantes, situación frecuente en procesos con dependencia temporal moderada. Entre sus principales ventajas se destacan su simplicidad y su capacidad para adaptarse mejor a variaciones locales en comparación con la media móvil simple. Sin embargo, al igual que otros métodos basados en promedios, puede producir un efecto de suavización excesiva, reduciendo la variabilidad natural de la serie y dificultando la representación de cambios abruptos o valores extremos. Además, su desempeño depende de la elección del tamaño de la ventana y del esquema de ponderación utilizado.

3.4.11. Media móvil ponderada exponencial

La imputación mediante media móvil ponderada exponencial es un método que estima los valores faltantes utilizando un promedio ponderado de observaciones vecinas, asignando pesos que decrecen exponencialmente a medida que aumenta la distancia temporal respecto al dato faltante. De esta manera, las observaciones más cercanas tienen una influencia mayor sobre la imputación que las más alejadas, permitiendo capturar con mayor sensibilidad la estructura reciente de la serie temporal.

El procedimiento consiste en definir una ventana de observaciones alrededor del valor ausente y calcular un promedio ponderado utilizando pesos exponenciales. A diferencia de la media móvil lineal ponderada, donde los pesos disminuyen de manera lineal, en este enfoque la reducción es más rápida, concentrando la mayor parte de la información en las observaciones más próximas temporalmente. Esto resulta especialmente útil en series donde los valores recientes contienen información más relevante que los antiguos.

La expresión del valor imputado resulta igual a la imputación usando el método media móvil lineal ponderada. Sin embargo, en esta técnica, los pesos decrecen exponencialmente con la distancia temporal. Una forma habitual de representarlos es:

$$w_i = \alpha(1-\alpha)^{i-1}, \quad 0 < \alpha < 1 \tag{15}$$

donde α es el parámetro de suavizamiento, encargado de controlar la rapidez con la que disminuyen los pesos. Valores elevados de α otorgan mayor importancia a las observaciones más recientes, mientras que valores pequeños producen un suavizado más paulatino.

Este método resulta particularmente adecuado en series temporales donde la información más reciente refleja de manera más precisa el comportamiento actual del proceso. Entre sus principales ventajas se encuentran su capacidad para adaptarse rápidamente a cambios locales y su mayor sensibilidad frente a variaciones recientes de la serie. Sin embargo, puede verse afectado por valores atípicos cercanos al dato faltante, debido al alto peso asignado a las observaciones más próximas. Además, la elección del parámetro de suavizamiento influye significativamente en los resultados obtenidos.

3.4.12. Última observación trasladada hacia adelante

La imputación mediante última observación trasladada hacia adelante (*Last Observation Carried Forward*, LOCF) es un enfoque sencillo y directo que consiste en reemplazar cada valor faltante con el último valor observado disponible. De esta manera, se asume que el valor de la serie permanece constante hasta que se dispone de un nuevo dato observado.

El procedimiento consiste en recorrer la serie temporal y, ante la presencia de una observación faltante, asignarle el valor correspondiente a la observación válida más reciente. En consecuencia, cuando existen varios valores faltantes consecutivos, todos ellos son reemplazados por la misma observación previa conocida.

Este método resulta especialmente útil en series temporales con alta persistencia o cambios lentos en el tiempo, donde las observaciones consecutivas tienden a presentar valores similares. Entre sus principales ventajas se destacan su simplicidad computacional y la preservación de valores reales observados, evitando introducir valores artificiales intermedios. Sin embargo, presenta importantes limitaciones. La utilización repetida de una misma observación puede generar tramos artificialmente constantes, reduciendo la variabilidad de la serie y distorsionando su dinámica temporal. Además, el método puede producir sesgos significativos cuando la serie presenta tendencias, estacionalidad o cambios bruscos, ya que asume implícitamente estabilidad temporal entre observaciones consecutivas.

3.4.13. Siguiente observación trasladada hacia atrás

La imputación mediante próxima observación trasladada hacia atrás (*Next Observation Carried Backward*, NOCB) es un método que reemplaza cada valor faltante utilizando la primera observación disponible posterior al instante faltante. En este enfoque, se asume que el valor observado en el futuro inmediato puede utilizarse como aproximación para los datos ausentes anteriores.

El procedimiento consiste en recorrer la serie temporal e imputar cada observación faltante con el valor válido más cercano ubicado posteriormente en el tiempo, en contraposición al método LOCF. En consecuencia, cuando existen varios valores faltantes consecutivos, todos ellos son reemplazados por la misma observación futura conocida.

Este método resulta adecuado en contextos donde las observaciones futuras pueden considerarse representativas de los valores faltantes previos o cuando se desea evitar la propagación de valores antiguos hacia adelante. Entre sus principales ventajas se encuentran su simplicidad de implementación y la preservación de valores reales observados. Sin embargo, al igual que LOCF, puede generar tramos artificialmente constantes y reducir la variabilidad natural de la serie. Además, puede resultar poco realista en series con tendencia o cambios abruptos, ya que utiliza información futura

para estimar observaciones pasadas, lo que puede introducir distorsiones en la dinámica temporal del proceso.

3.4.14. División estacional

La imputación mediante división estacional es un método que estima los valores faltantes aprovechando la estructura estacional presente en la serie temporal. Asume que los datos tienen un patrón estacional recurrente y utiliza este patrón para inferir los valores faltantes, lo que permite una imputación más precisa cuando la serie temporal tiene una fuerte estacionalidad.

El enfoque de este método se basa en dividir la serie temporal según los ciclos estacionales identificados, y luego imputar los valores faltantes dentro de cada ciclo en función de los valores observados correspondientes a las mismas posiciones estacionales en otros ciclos. La idea principal es que los valores en una misma fase de la estacionalidad (por ejemplo, el mismo mes en diferentes años) tienden a ser similares, por lo que los valores faltantes en una parte del ciclo estacional pueden ser imputados usando datos de otras partes del mismo ciclo en años o periodos anteriores o posteriores.

Este método resulta especialmente útil en series temporales con patrones estacionales marcados y relativamente estables en el tiempo, ya que permite preservar la estructura periódica de los datos durante el proceso de imputación. Entre sus principales ventajas se destaca su capacidad para mantener la estacionalidad de la serie, evitando distorsiones que podrían producir métodos más simples. Sin embargo, su desempeño depende de una correcta estimación del componente estacional y puede verse afectado en series con estacionalidad débil, cambiante o difícil de identificar. Además, requiere que la serie sea de una longitud suficientemente grande para estimar adecuadamente los patrones estacionales.

3.4.15. Descomposición estacional

La imputación mediante descomposición estacional es un método que estima los valores faltantes aprovechando la estructura interna de la serie temporal a través de la separación de sus componentes principales. Este enfoque parte de la idea de que una serie temporal puede representarse como la combinación de distintos componentes, generalmente tendencia, estacionalidad y ruido, los cuales pueden analizarse por separado para facilitar la imputación de observaciones ausentes.

El procedimiento consiste en descomponer la serie temporal en sus componentes estructurales mediante técnicas de descomposición aditiva o multiplicativa. Una vez obtenidos estos componentes, la imputación se realiza sobre la serie ajustada, es decir, sobre aquella en la que se ha eliminado temporalmente el componente estacional y/o de tendencia. Posteriormente, los componentes extraídos son reincorporados para reconstruir la serie original imputada.

Luego de realizar la descomposición, la imputación de los valores faltantes no se efectúa directamente sobre la serie original, sino sobre una versión ajustada de la misma, en la que se han removido temporalmente algunos de sus componentes estructurales, principalmente la tendencia y la estacionalidad. El objetivo de este procedimiento es simplificar la dinámica de la serie antes de realizar la imputación, obteniendo una componente residual más estable y sencilla de modelar.

Una vez eliminados estos componentes, los valores faltantes de la serie ajustada se estiman mediante métodos auxiliares de imputación o interpolación, como interpolación lineal, medias móviles u otros

procedimientos de suavizamiento. Posteriormente, los componentes previamente removidos son reincorporados para reconstruir la serie temporal completa en su escala original. De esta manera, la imputación final conserva tanto la tendencia como los patrones estacionales presentes en la serie, evitando distorsionar su estructura temporal.

Este método resulta especialmente adecuado en series temporales que presentan patrones estacionales y tendencias claramente definidos, ya que permite preservar dichas estructuras durante la imputación. Entre sus principales ventajas se destacan su capacidad para mantener las características fundamentales de la serie y su flexibilidad para adaptarse a diferentes tipos de comportamiento temporal. Sin embargo, su desempeño depende de la calidad de la descomposición realizada y puede verse afectado cuando la serie presenta alta volatilidad, cambios estructurales o patrones estacionales poco estables. Además, requiere una cantidad suficiente de observaciones para estimar adecuadamente los componentes de la serie.

3.4.16. Suavizado de Kalman en un modelo estructural

Este enfoque captura la estructura interna de la serie, descomponiéndola en componentes como la tendencia, la estacionalidad y el ruido, lo que permite una imputación más precisa y coherente con la dinámica temporal subyacente de los datos. Una vez que la serie temporal se ha descompuesto en sus componentes estructurales, se reformula en un formato conocido como "espacio de estados". En este marco, los componentes de la serie (como la tendencia o la estacionalidad) se tratan como estados no observados que evolucionan a lo largo del tiempo. A partir de esta representación, entra en juego el filtro de Kalman, que es un algoritmo diseñado para calcular estos estados ocultos basándose en las observaciones disponibles, incluso cuando hay datos faltantes.

Como se mencionó anteriormente, el filtro de Kalman funciona en dos etapas: predicción y actualización. En la fase de predicción, el filtro utiliza el modelo estructural para calcular los valores futuros de la serie basándose en los datos pasados y los estados estimados previamente. Cuando falta un valor en la serie, el filtro de Kalman puede seguir realizando estas predicciones sin necesidad de observaciones en ese punto específico, utilizando solo la información estructural y las observaciones adyacentes. Después, cuando el filtro encuentra nuevas observaciones, ajusta las predicciones iniciales en función de estos nuevos datos, mejorando así la precisión de las imputaciones.

Sin embargo, el verdadero poder de esta técnica se despliega cuando se aplica el suavizado de Kalman. Mientras que el filtro de Kalman se enfoca en predecir hacia adelante (de pasado a presente), el suavizado de Kalman revisa estas predicciones considerando también la información futura. Esto es crucial cuando hay valores faltantes, ya que no solo se utiliza la información previa al valor perdido, sino también las observaciones posteriores, lo que permite refinar las imputaciones de manera mucho más precisa.

Al descomponer la serie en componentes estructurales, el modelo es capaz de capturar patrones que otros métodos de imputación más simples no podrían. Además, el uso del filtro de Kalman permite hacer imputaciones en puntos donde faltan datos de manera precisa, sin necesidad de realizar supuestos fuertes sobre el comportamiento de los datos. El suavizado de Kalman, al aprovechar información tanto pasada como futura, hace que las imputaciones sean mucho más exactas que si solo se consideraran los datos anteriores al valor faltante.

Entre sus principales ventajas se destacan su sólido fundamento estadístico, su capacidad para incorporar simultáneamente tendencia y estacionalidad, y el aprovechamiento eficiente de toda la información temporal disponible. Además, al utilizar información tanto pasada como futura, suele

producir imputaciones más precisas que métodos más simples de interpolación o suavizamiento. Sin embargo, requiere una correcta especificación del modelo estructural y una longitud suficiente de la serie temporal para estimar adecuadamente sus componentes. Asimismo, su implementación resulta considerablemente más compleja y su desempeño puede verse afectado cuando la serie presenta alta irregularidad, cambios estructurales abruptos o patrones difíciles de modelar.

3.4.17. Representación del espacio en estados de ARIMA y suavizado de Kalman

La imputación mediante representación en espacio de estados de modelos ARIMA y suavizado de Kalman es un método que combina la capacidad de modelado de los procesos ARIMA con las técnicas de estimación recursiva del filtro y suavizado de Kalman. Este enfoque permite estimar valores faltantes utilizando la estructura de dependencia temporal propia de los modelos ARIMA, incorporando además información tanto pasada como futura de la serie temporal.

Los modelos ARIMA describen la evolución de una serie temporal a partir de relaciones autorregresivas, diferenciación e incorporación de componentes de medias móviles. Aunque tradicionalmente estos modelos se expresan mediante ecuaciones de series temporales, también pueden reformularse en el marco de espacio de estados. En esta representación, la dinámica del modelo queda expresada mediante estados no observables que evolucionan en el tiempo y generan las observaciones de la serie. En el apartado siguiente se presentarán estos modelos con mayor detalle.

A partir de esta formulación, el filtro de Kalman puede utilizarse para estimar recursivamente los estados del modelo y manejar naturalmente la presencia de observaciones faltantes. Cuando ocurre un dato ausente, el algoritmo continúa realizando predicciones utilizando únicamente la estructura estimada del modelo ARIMA y las observaciones disponibles. Posteriormente, cuando se incorporan nuevas observaciones, las estimaciones son ajustadas mediante el mecanismo de actualización del filtro.

Sin embargo, al igual que en los modelos estructurales, el mayor potencial del método surge al aplicar el suavizado de Kalman. Mientras que el filtro utiliza únicamente información pasada para estimar los estados del sistema, el suavizado incorpora además observaciones futuras, refinando las estimaciones de los valores faltantes. Como consecuencia, las imputaciones obtenidas resultan más consistentes con la dinámica global de la serie temporal.

Este método resulta especialmente útil en series temporales con fuerte dependencia temporal, ya que los modelos ARIMA permiten capturar relaciones dinámicas complejas entre observaciones consecutivas. Entre sus principales ventajas se destacan su sólido fundamento estadístico, su capacidad para manejar naturalmente datos faltantes y la utilización eficiente de toda la información disponible en la serie. Además, al incorporar la estructura propia del modelo ARIMA, las imputaciones suelen preservar adecuadamente la dinámica temporal de los datos.

No obstante, el desempeño del método depende de una correcta especificación del modelo ARIMA subyacente. Una elección inadecuada de los órdenes autorregresivos, de diferenciación o de medias móviles puede afectar significativamente la calidad de las imputaciones. Asimismo, su implementación resulta más compleja que la de métodos simples de interpolación o suavizamiento y puede presentar dificultades en series con cambios estructurales abruptos o comportamientos no lineales.

3.5. Técnicas de modelado

En el análisis de series temporales, los modelos pueden clasificarse de manera general en deterministas y estocásticos. Los primeros describen la evolución de la serie mediante reglas completamente especificadas, sin incorporar un término aleatorio explícito. En cambio, los modelos estocásticos incluyen una componente de aleatoriedad que permite representar la incertidumbre inherente a los datos y describir con mayor realismo la variabilidad observada en fenómenos temporales. Este ruido representa la variabilidad y la incertidumbre que no pueden explicarse únicamente por los valores pasados de la serie. Como resultado, las predicciones generadas por modelos estocásticos son probabilísticas, proporcionando una distribución de posibles valores futuros.

Uno de los casos mas simples de procesos estocásticos son los procesos ruido blanco, los cuales son una secuencia de datos completamente aleatorios, con una media constante, varianza constante y ninguna autocorrelación significativa en ningún rezago. Si una serie se comporta como ruido blanco, cualquier intento de modelarla utilizando enfoques que asumen dependencias temporales resultará en un modelo que no tiene capacidad predictiva y simplemente se ajustará al ruido. Antes de aplicar modelos que asuman estructuras temporales, es fundamental verificar si la serie muestra autocorrelación significativa o si, por el contrario, se trata de una secuencia aleatoria, lo que indicaría que no hay patrones temporales que puedan ser aprovechados para la predicción.

Los modelos deterministas presentan ciertas limitaciones, ya que pueden ser una simplificación excesiva de la realidad, ignorando la aleatoriedad inherente a muchos sistemas reales, lo que puede llevar a grandes diferencias en las predicciones si no se conocen con precisión estas condiciones. En cambio, una de las principales dificultades de los modelos estocásticos es la necesidad de estimar un gran número de parámetros, lo que puede llevar a problemas de sobreajuste si el modelo es demasiado complejo para los datos disponibles. Además, la incorporación de términos aleatorios puede hacer que la interpretación de los modelos sea más compleja y menos intuitiva.

Dentro de los enfoques deterministas y estocásticos, se incluyen varios modelos fundamentales en la modelización de series temporales, como los modelos autorregresivos, los de media móvil, y sus combinaciones, como los modelos ARMA, ARIMA y SARIMA. A continuación, se ofrece una descripción de cada uno de ellos.

3.5.1. Procesos Autorregresivos (AR)

La idea principal de los procesos autorregresivos es que el valor actual de la serie puede explicarse a partir de una combinación lineal de observaciones pasadas y un término aleatorio que representa perturbaciones no explicadas por el modelo.

Un modelo autorregresivo de orden p, denotado como $AR(p)$, supone que cada observación depende linealmente de las p observaciones inmediatamente anteriores. De esta manera, la dinámica de la serie queda determinada por su propia historia reciente. Formalmente, un proceso AR(p) puede expresarse como:

$$Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + a_t \tag{16}$$

donde:

- Y_t representa el valor de la serie temporal en el instante t,
- c es una constante,

- ϕ_1, ϕ_2, ..., ϕ_p son los parámetros autorregresivos del modelo,
- a_t es un proceso ruido blanco, con media cero y varianza constante.

Los parámetros autorregresivos determinan la influencia que tienen las observaciones pasadas sobre el valor actual de la serie. En particular, valores elevados de estos coeficientes indican una fuerte dependencia temporal entre observaciones.

Estos modelos resultan especialmente útiles para describir series temporales con dependencia temporal persistente, donde los valores observados presentan correlación significativa con observaciones previas.

3.5.2. Procesos Promedio Móvil (MA)

Los procesos de media móvil constituyen otra clase fundamental de modelos estocásticos utilizados en series temporales. A diferencia de los modelos autorregresivos, donde el valor actual de la serie depende de observaciones pasadas, en los modelos de media móvil cada observación se expresa como una combinación lineal de errores pasados.

Un proceso de media móvil de orden q, denotado como $MA(q)$, supone que el valor observado en cada instante temporal depende de los errores ocurridos en los q períodos anteriores. La ecuación resulta:

$$Y_t = \mu + \theta_1 a_{t-1} + \theta_2 a_{t-2} + \cdots + \theta_q a_{t-q} \tag{17}$$

donde:

- Y_t representa el valor de la serie temporal en el instante t,
- μ es la media de la serie,
- $\theta_1, \theta_2, \ldots, \theta_q$, son los parámetros del proceso media móvil y determinan el efecto que ejercen los errores pasados sobre el valor actual de la serie,
- a_t representa un proceso ruido blanco, con media cero y varianza constante.

Una característica importante de los procesos $MA(q)$ es que son siempre estacionarios, ya que se define como una combinación lineal de procesos estacionarios. Además, son conocidos como procesos de memoria corta, ya que presentan una estructura de dependencia temporal de corto plazo, dado que la influencia de los errores desaparece completamente luego de q períodos. Esto implica que su función de autocorrelación se anula después del rezago q. Por lo tanto, debido a su estructura de memoria corta, los modelos de media móvil son apropiados para representar series temporales donde la influencia de los errores decrece rápidamente y desaparece tras un número finito de períodos.

3.5.3. Procesos Autorregresivos de Media Móvil (ARMA)

Los procesos ARMA intentan combinar las propiedades de los procesos autorregresivos y de los promedio móvil, permitiendo representar series temporales cuya dinámica depende tanto de observaciones pasadas como de sus errores pasados.

En un modelo $ARMA(p, q)$, el valor actual de la serie temporal se expresa como una combinación lineal de las p observaciones previas y de los q errores aleatorios pasados. Formalmente, se expresa como:

$$Y_t = c + \sum_{i=1}^{p} \phi_i Y_{t-i} + \sum_{j=1}^{q} \theta_j a_{t-j} \tag{18}$$

cuyos componentes ya fueron definidos anteriormente.

La componente autorregresiva permite modelar la dependencia entre observaciones sucesivas, mientras que la componente de media móvil incorpora el efecto de variaciones aleatorias recientes. Gracias a esta combinación, los modelos $ARMA(p, q)$ poseen una mayor flexibilidad para representar distintos patrones de dependencia temporal presentes en las series. Por lo tanto, resultan adecuados para series temporales estacionarias que presentan tanto persistencia temporal como efectos transitorios de corto plazo.

3.5.4. Procesos Autorregresivos Integrados de Media Móvil (ARIMA)

Cuando la serie no es estacionaria, se utiliza el modelo Autorregresivo Integrado de Media Móvil (ARIMA). El término "integrado" significa que se aplica una diferenciación de orden d para hacer la serie estacionaria antes de aplicar los componentes AR y MA, permitiendo así eliminar tendencias u otros patrones no estacionarios presentes en la serie. La notación de un modelo ARIMA es $ARIMA(p, d, q)$, donde d es el número de diferencias necesarias para lograr estacionariedad.

La idea principal de los modelos ARIMA consiste en diferenciar la serie temporal un determinado número de veces hasta alcanzar estacionariedad y, posteriormente, modelar la serie transformada mediante un modelo ARMA. De esta manera, el modelo combina tres componentes fundamentales:

- una componente autorregresiva (AR),
- una componente de integración (I),
- una componente de media móvil (MA).

3.5.5. Procesos Estacionales, Autorregresivos Integrados de Media Móvil (SARIMA)

Los modelos autorregresivos integrados, de media móvil y estacionales, conocidos como modelos $SARIMA(p, d, q)(P, D, Q)_s$, constituyen una extensión de los modelos $ARIMA(p, d, q)$ diseñada para representar series temporales que presentan comportamiento estacional. Estos modelos permiten incorporar simultáneamente dependencia temporal de corto plazo, tendencia y patrones periódicos que se repiten regularmente en el tiempo.

La principal diferencia respecto de los modelos ARIMA radica en la inclusión de componentes estacionales autorregresivos, de diferenciación y de media móvil. De esta manera, el modelo es capaz de capturar relaciones temporales tanto entre observaciones consecutivas como entre observaciones separadas por un período estacional fijo.

3.6. Modelos de pronóstico

A diferencia del análisis predictivo convencional, que puede hacer hincapié en las variables explicativas para predecir un resultado, el pronóstico de series temporales busca estimar el comportamiento futuro de una variable a partir de sus valores históricos. Se pueden categorizar a grandes rasgos los problemas de series temporales de la siguiente manera: si se quiere pronosticar un paso de tiempo hacia adelante en el futuro, que es el caso más común de problemas de series temporales, se denomina predicción de un paso o de un solo paso. Por otro lado, si se hace una predicción que se adelanta varios pasos de tiempo en el futuro, se denomina predicción de varios pasos.

Formalmente, si se quiere pronosticar el valor Y_{T+K}, con $k > 0$, para una serie $Y_1, Y_2, ..., Y_T$, se define $\widehat{Y}_{T+K}$ como un predictor lineal de la observación Y_{T+K}, obtenido como función de las T observaciones, con origen de predicción T y horizonte de predicción k.

A continuación, se describen los modelos de predicción que serán comparados en cada situación.

3.6.1. Modelos ARIMA Y SARIMA

Los modelos ARIMA y SARIMA, descriptos anteriormente, constituyen algunas de las herramientas más utilizadas para el pronóstico de series temporales. Estos modelos permiten describir la dependencia temporal presente en los datos y proyectar dicha estructura hacia períodos futuros.

Una vez ajustado el modelo a la serie observada, los pronósticos se obtienen de manera recursiva utilizando las relaciones definidas por el propio modelo. En particular, las predicciones para horizontes futuros se construyen a partir de los valores observados y de los valores pronosticados en períodos anteriores. De esta forma, es posible generar estimaciones para distintos horizontes de pronóstico y obtener intervalos de predicción asociados.

Es importante destacar que estos modelos requieren series completas para su estimación. Por este motivo, las observaciones faltantes son reemplazadas previamente mediante los distintos métodos de imputación considerados en este trabajo. Una vez completada la serie, el modelo se ajusta sobre los datos imputados y se generan pronósticos para los distintos horizontes de predicción analizados.

La especificación del modelo se realiza de forma automática mediante el procedimiento implementado en la función `auto.arima()` del paquete `forecast` de R. Este algoritmo selecciona los órdenes autorregresivos, de diferenciación y de media móvil que optimizan determinados criterios de información, considerando además la posible presencia de componentes estacionales.

3.6.2. Modelo ETS

El modelo ETS (*Error*, *Trend*, *Seasonal*) se basa en el marco de modelos de espacio de estados para el suavizado exponencial. Este enfoque permite descomponer la serie temporal en tres componentes fundamentales: el Error, la Tendencia y la Estacionalidad.

La principal característica de este enfoque es que permite representar explícitamente cada uno de estos componentes mediante estructuras aditivas o multiplicativas, dando lugar a diferentes especificaciones del modelo. De esta manera, los modelos ETS son capaces de adaptarse a una amplia

variedad de comportamientos observados en series temporales, incluyendo series con tendencia creciente o decreciente, patrones estacionales de distinta intensidad y variabilidad dependiente del nivel de la serie.

A diferencia de los modelos ARIMA, que describen la dependencia temporal a través de relaciones entre observaciones y errores pasados, los modelos ETS se basan en la descomposición de la serie en componentes no observados que evolucionan a lo largo del tiempo. Esta formulación permite modelar de manera flexible la tendencia y la estacionalidad, actualizando continuamente sus estimaciones a medida que se incorporan nuevas observaciones.

La especificación del modelo se realiza utilizando la función `ets()` del paquete `forecast` de R, la cual evalúa distintas combinaciones de componentes de error, tendencia y estacionalidad, seleccionando aquella que optimiza un criterio de información, generalmente el Criterio de Información de Akaike (AIC). Este procedimiento permite identificar de forma automática la estructura que mejor representa el comportamiento de la serie temporal entre un conjunto de modelos candidatos.

Al igual que los modelos ARIMA y SARIMA, requieren series completas para su estimación, por lo que los datos faltantes son imputados previamente mediante las técnicas consideradas en el estudio.

3.6.3. Modelo Prophet

Prophet es un procedimiento de pronóstico de código abierto propuesto por Taylor y Letham, desarrollado originalmente en Facebook para abordar problemas de previsión empresarial caracterizados por tendencias cambiantes, estacionalidades marcadas y presencia de valores faltantes o atípicos. Aunque fue diseñado principalmente para series temporales de frecuencia diaria, admite otras periodicidades y permite incorporar información sobre eventos y días festivos conocidos de antemano.

A diferencia de los modelos autorregresivos tradicionales, como ARIMA, o de los modelos de suavizado exponencial, como ETS, Prophet plantea el pronóstico como un problema de ajuste de curvas mediante un modelo de regresión aditiva basado en la estructura de los modelos aditivos generalizados (GAM). La serie se representa mediante la siguiente expresión:

$$y(t) = g(t) + s(t) + h(t) + \varepsilon_t,$$

donde $g(t)$ representa la tendencia de largo plazo, $s(t)$ captura los patrones estacionales periódicos, $h(t)$ recoge los efectos de eventos especiales o días festivos y ε_t representa el término de error, que se supone distribuido normalmente con media cero y varianza σ_ε^2).

El componente de tendencia puede especificarse mediante una función lineal por tramos o una función logística. Asimismo, el modelo permite detectar automáticamente puntos de cambio en la tendencia histórica. La estacionalidad se representa mediante series de Fourier, lo que proporciona flexibilidad para capturar patrones periódicos complejos. También admite una especificación multiplicativa de la estacionalidad, en la que la amplitud de las fluctuaciones estacionales depende del nivel de la tendencia. Esta alternativa resulta apropiada cuando las variaciones estacionales aumentan o disminuyen en proporción al nivel de la serie. Por otra parte, los efectos de eventos particulares pueden incorporarse mediante información específica sobre sus fechas y características.

Una característica relevante para esta investigación es que Prophet admite observaciones faltantes sin requerir una imputación previa. El ajuste se realiza a partir de los pares de tiempo y valor

correspondientes a las observaciones disponibles, por lo que no es necesario completar la serie para estimar el modelo. Esta característica permite utilizarlo como una alternativa frente a los enfoques basados en imputación previa, aunque no garantiza por sí sola un mejor desempeño predictivo.

En esta tesina se utilizó la implementación del paquete `prophet` para R, configurada con estacionalidad anual multiplicativa, sin estacionalidad semanal ni diaria y sin incorporar días festivos o eventos especiales. El resto de los hiperparámetros se mantuvo en sus valores predeterminados. A diferencia de ARIMA y ETS, que en este trabajo se ajustan sobre las series previamente completadas mediante los distintos métodos de imputación, Prophet se aplica directamente sobre las series con valores faltantes. Por este motivo, no constituye una estrategia de $forecast-after-imputation$, sino que se incorpora como un modelo de referencia benchmark$) para comparar el desempeño predictivo de los enfoques que requieren imputación previa con el de una alternativa que admite observaciones ausentes.

3.7. Evaluación del desempeño

La precisión de los pronósticos se evaluará utilizando observaciones que no hayan sido empleadas en la estimación de los modelos. Para ello, se aplicará un enfoque de evaluación fuera de la muestra (*out-of-sample*), dividiendo los datos disponibles en dos conjuntos: datos de entrenamiento (*training set*) y datos de prueba (*test set*). Por otro lado, el error de imputación será calculado comparando los valores imputados con los valores reales de la serie.

Los datos de entrenamiento se utilizarán para la estimación de los parámetros de cada método de predicción, mientras que los datos de prueba se reservarán exclusivamente para evaluar su desempeño. Siguiendo la práctica habitual en el análisis de series temporales, se separarán las últimas observaciones de cada serie para conformar el conjunto de prueba (por ejemplo, en series de frecuencia mensual se reservarán las últimas 12 observaciones).

3.7.1. Evaluación del desempeño de los métodos de imputación

En una primera instancia se evaluará el desempeño de los métodos de imputación comparando los valores imputados con los valores originales de la serie antes de la introducción de datos faltantes. Para ello se utilizarán métricas de error como el error cuadrático medio (RMSE), el error absoluto medio (MAE) y el error porcentual absoluto medio (MAPE), que permiten cuantificar la capacidad de cada método para reconstruir adecuadamente los valores faltantes.

3.7.2. Evaluación del desempeño del pronóstico posterior

En una segunda etapa se evaluará el impacto de los métodos de imputación sobre el desempeño de los modelos de pronóstico. Para ello se ajustarán distintos modelos de series temporales sobre las series imputadas y se generarán pronósticos para un horizonte determinado. Posteriormente, los valores pronosticados se compararán con los valores reales mediante métricas de error como RMSE, MAE y MAPE.

3.7.3. Métricas del error

Para evaluar el desempeño tanto de los métodos de imputación como de los modelos de pronóstico se utilizarán distintas métricas de error comúnmente empleadas en el análisis de series temporales.

En este contexto, el error se define como la diferencia entre un valor observado y el valor estimado o pronosticado por el modelo. En particular, se considerarán el error cuadrático medio (RMSE), el error absoluto medio (MAE) y el error porcentual absoluto medio (MAPE), cuyas expresiones se presentan a continuación.

- Error absoluto medio (MAE): Esta métrica es una medida de la diferencia entre dos valores, es decir, permite saber qué tan diferente es el valor predicho y el valor real u observado. Para que un error con valor positivo no cancele a un error con error negativo se usa el valor absoluto de la diferencia. Como interesa conocer el comportamiento del error de todas las observaciones y no solamente de una, entonces se obtiene el promedio de los valores absolutos de la diferencia.

$$MAE = \frac{\sum_{t=1}^{n} |\hat{y}_t - y_t|}{n_m} \tag{19}$$

- Error medio cuadrado (MSE) Esta métrica es muy útil para saber qué tan cerca es la línea de ajuste de la regresión a las observaciones. Al igual que en caso anterior se evita que un error con valor positivo anule a uno con valor negativo, pero en lugar de usar el valor absoluto, se eleva al cuadrado la diferencia. Siempre da un valor positivo y entre más cercano sea a cero es mejor.

$$MSE = \frac{\sum_{t=1}^{n} (\hat{y}_t - y_t)^2}{n_m} \tag{20}$$

* Raíz del error medio cuadrado (RMSE) Como la métrica anterior da el resultado en unidades cuadradas, para poder interpretarlo más fácilmente se saca la raíz cuadrada y de esta manera se obtiene el valor en las unidades originales.

$$RMSE = \sqrt{\frac{\sum_{t=1}^{n} (\hat{y}_t - y_t)^2}{n_m}} \tag{21}$$

* Porcentaje de error medio absoluto (MAPE) Esta es una métrica de la precisión, pero se presenta como si fuera un porcentaje, como ventaja tiene que es independiente de la escala y fácil de interpretar. Como desventaja es que puede producir valores no definidos, infinito o muy cercanos a cero. El calculo es sencillo, para cada observación se obtiene su porcentaje de error y luego se calcula la media de todos esos valores.

$$MAPE = \frac{100}{n_m} \sum_{t=1}^{n} \left| \frac{y_t - \hat{y}_t}{y_t} \right| \tag{22}$$

siendo y_t el valor observado, $\hat{y_t}$ el valor imputado o pronosticado y n_m la cantidad de valores perdidos o pronosticados.

4. Aplicación

Con el objetivo de evaluar el impacto de distintos métodos de imputación sobre el desempeño de modelos de pronóstico en series temporales univariadas, se plantea un procedimiento experimental basado en la introducción controlada de datos faltantes en series originalmente completas. Esta estrategia permite conocer en todo momento los valores reales de las observaciones eliminadas y, en consecuencia, evaluar la calidad de las imputaciones realizadas y su efecto sobre la precisión de los pronósticos. Al introducir los valores faltantes, no se consideraron los extremos de la serie, dado que su imputación requeriría extrapolar a partir de las observaciones disponibles, en lugar de interpolar utilizando información a ambos lados del valor faltante.

Se selecciona una serie temporal univariada completa, es decir, sin valores faltantes, y sobre esta se realiza un análisis exploratorio inicial con el fin de identificar sus principales características, tales como la presencia de tendencia, estacionalidad, posibles valores atípicos y estructura de autocorrelación. Asimismo, cada serie se divide en un conjunto de entrenamiento y un conjunto de prueba. El conjunto de entrenamiento se utiliza para realizar la imputación de los datos faltantes y ajustar los modelos de pronóstico, mientras que el conjunto de prueba permanece sin modificaciones y se emplea exclusivamente para evaluar la capacidad predictiva de los modelos.

A partir de las series de entrenamiento se generan artificialmente distintos escenarios de datos faltantes. Para ello se consideran diferentes porcentajes de observaciones ausentes y distintos mecanismos de generación de faltantes, reproduciendo situaciones que pueden presentarse en situaciones reales. En todos los casos, la introducción de valores faltantes se restringe al interior de la serie, preservando los extremos inicial y final para garantizar que el procedimiento corresponda a una imputación y no a un problema de pronóstico hacia adelante o hacia atrás.

Una vez generados los escenarios de datos faltantes, se aplican los diferentes métodos de imputación considerados para reconstruir las observaciones ausentes. Con el propósito de reducir el efecto del azar asociado a la ubicación de los datos faltantes, cada combinación de serie, mecanismo y porcentaje de faltantes se replica 100 veces utilizando distintas configuraciones de eliminación aleatoria. De esta manera, los resultados obtenidos corresponden al promedio de un elevado número de iteraciones, proporcionando estimaciones más estables del desempeño de cada método.

La calidad de las imputaciones se evalúa comparando los valores imputados con las observaciones originales eliminadas artificialmente. Para cuantificar la precisión de cada método se utilizan las métricas RMSE, MAE y MAPE, anteriormente definidas.

Luego, utilizando las series imputadas, se ajustan los modelos de pronóstico ARIMA/SARIMA y ETS, siguiendo el enfoque forecast-after-imputation. Adicionalmente, se ajusta Prophet directamente sobre la serie con valores faltantes, sin aplicar imputación previa. De este modo, Prophet se incorpora como un *benchmark* externo al esquema *forecast-after-imputation*, permitiendo comparar la estrategia de imputar y luego pronosticar con una alternativa que puede generar predicciones a partir de series incompletas. Los pronósticos se generan para horizontes de $h = 3, 6$ y 12 períodos hacia adelante. Finalmente, el desempeño predictivo de cada modelo se evalúa comparando los valores pronosticados con las observaciones reales del conjunto de prueba mediante las mismas métricas de error utilizadas para evaluar la imputación. Esto permite analizar no solo la capacidad de cada método para reconstruir los valores faltantes, sino también el impacto que dichas imputaciones tienen sobre la precisión de los pronósticos posteriores. El ajuste de los modelos ARIMA/SARIMA se realiza mediante la función `auto.arima()`, mientras que para los modelos ETS se utiliza la función

`ets()`, ambas pertenecientes al paquete `forecast` de R. Estas funciones permiten seleccionar automáticamente una especificación del modelo a partir de un conjunto de alternativas, utilizando un criterio de información para determinar la más adecuada. En el caso de `auto.arima()`, la búsqueda considera distintos órdenes autorregresivos y de media móvil, tanto estacionales como no estacionales, así como la necesidad de aplicar diferenciación estacional y no estacional. Por su parte, `ets()` selecciona automáticamente la combinación de componentes de error, tendencia y estacionalidad que mejor se ajusta a los datos, contemplando distintas estructuras dentro de la familia de modelos de suavizamiento exponencial.

El procedimiento completo puede resumirse en las siguientes etapas:

1 - Selección de la serie temporal. Se seleccionan series temporales univariadas completas, que servirán como referencia para la generación de los escenarios experimentales.

2 - Análisis exploratorio de la serie. Se estudian las principales características de cada serie, incluyendo tendencia, estacionalidad, autocorrelación y posibles valores atípicos. Asimismo, se define la partición entre conjunto de entrenamiento y conjunto de prueba.

3 - Generación de datos faltantes. Se introducen valores faltantes de forma artificial sobre el conjunto de entrenamiento, considerando distintos porcentajes y mecanismos de generación de faltantes.

4 - Aplicación de los métodos de imputación. Se imputan las observaciones faltantes mediante las técnicas consideradas en el estudio.

5 - Evaluación de la imputación. Se comparan los valores imputados con los valores originales mediante las métricas RMSE, MAE y MAPE.

6 - Ajuste de los modelos de pronóstico. Se ajustan los modelos ARIMA/SARIMA y ETS utilizando las series imputadas, mientras que Prophet se ajusta directamente sobre la serie con datos faltantes.

7 - Generación de pronósticos. Se obtienen predicciones para horizontes de $h = 3, 6$ y 12.

8 - Evaluación del pronóstico. Se comparan los pronósticos con las observaciones del conjunto de prueba utilizando las métricas RMSE, MAE y MAPE.

9 - Comparación de resultados. Se analizan conjuntamente los errores de imputación y de pronóstico para determinar el efecto que tienen los distintos métodos de imputación sobre el desempeño predictivo de cada modelo.

Caso de aplicación: Consumo de electricidad

En este trabajo se utilizó una serie temporal mensual de la demanda de electricidad en Argentina, cuya fuente primaria son los registros de CAMMESA y de la Secretaría de Energía de la Nación Argentina. La serie comprende observaciones mensuales desde enero de 2010 hasta diciembre de 2025, con un total de 192 observaciones, expresadas en miles de GWh.

4.1. Análisis descriptivo

Se realizó una partición de la serie temporal en dos subconjuntos. Las observaciones comprendidas entre enero de 2010 y diciembre de 2024 conformaron el conjunto de entrenamiento, sobre el cual se generaron los escenarios de datos faltantes, se aplicaron los métodos de imputación y se ajustaron los modelos de pronóstico. Las observaciones correspondientes a 2025 se reservaron como conjunto de prueba y se utilizaron exclusivamente para evaluar el desempeño predictivo fuera de muestra.

Como primera etapa, se realizó un análisis exploratorio de la serie con el objetivo de identificar sus principales características y evaluar los patrones que podrían resultar relevantes para el proceso de imputación y pronóstico. En primer lugar, se analizó gráficamente la evolución temporal de la serie, presentada en la Figura 1

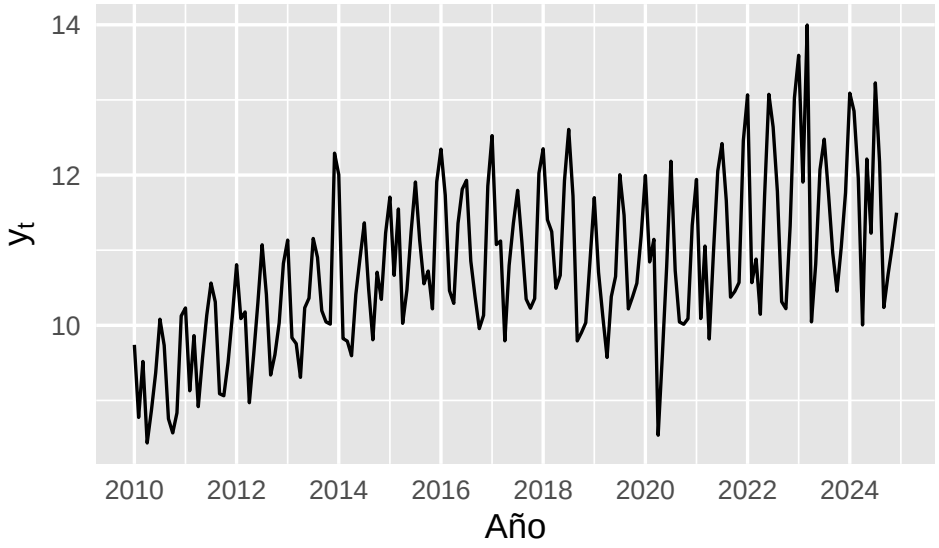


Figura 1: Demanda mensual de energía eléctrica en Argentina (2010–2024)

La Figura 1 muestra una tendencia general creciente de la demanda durante el período analizado, aunque con cambios en su evolución a lo largo del tiempo. Asimismo, se observa un patrón de fluctuaciones recurrentes compatible con una componente estacional y algunos movimientos de magnitud inusual, particularmente alrededor de 2020. Estas características sugieren que la serie no presenta un comportamiento estacionario en media y justifican un análisis más detallado de su estructura de dependencia temporal y estacionalidad.

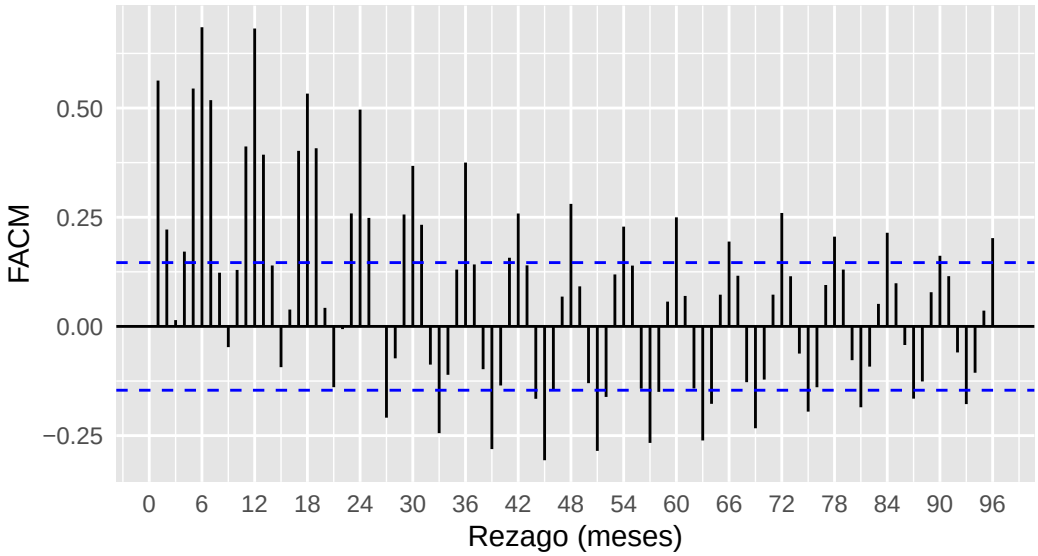


Figura 2: Función de autocorrelación muestral

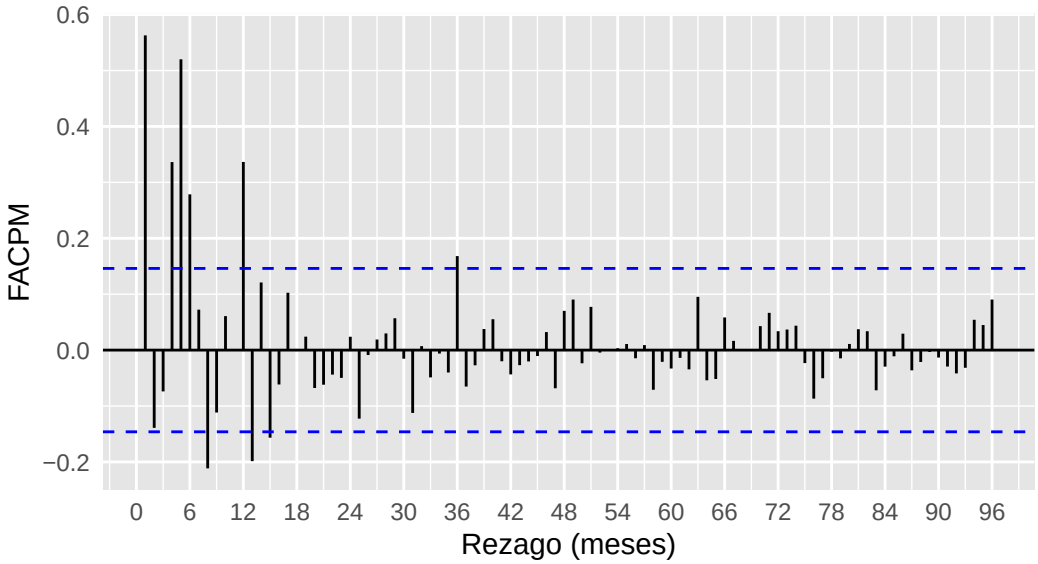


Figura 3: Función de autocorrelación parcial muestral

La función de autocorrelación muestral (Figura 2) presenta valores elevados en los primeros rezagos y un decaimiento gradual, comportamiento consistente con la persistencia temporal observada en la serie. Asimismo, se identifica una estructura periódica en las autocorrelaciones, compatible con la presencia de estacionalidad anual.

Por su parte, la función de autocorrelación parcial muestral (Figura 3) muestra asociaciones significativas principalmente en los primeros rezagos, lo que evidencia dependencia temporal de corto plazo. En conjunto, ambas funciones confirman la existencia de una estructura de dependencia temporal que deberá ser considerada tanto en la imputación como en el posterior modelado de la serie.

En ambos gráficos se observan picos significativos en rezagos múltiplos de 12 meses, lo que sugiere la presencia de un patrón estacional anual.

Estas características de tendencia, estacionalidad y cambios estructurales resultan especialmente relevantes en el contexto de la imputación, ya que distintos métodos pueden afectar de manera diferente la preservación de la estructura temporal de la serie.

En la Figura 4 se presenta el comportamiento estacional de la serie por año y mes.

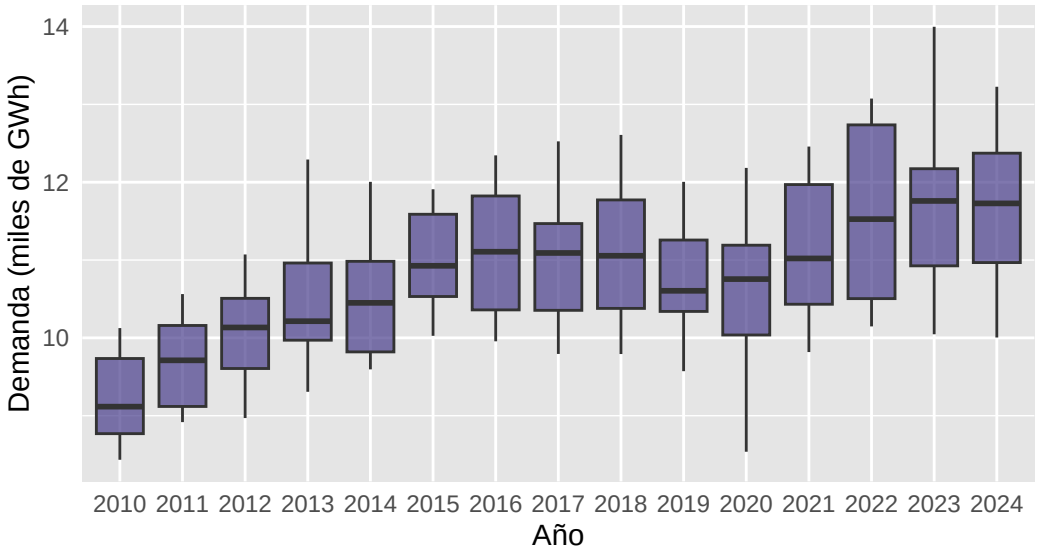


Figura 4: Distribución de la demanda mensual de energía eléctrica según año, Argentina, 2010–2024.

En la Figura 4 se observa que antes del 2015 la demanda fue aumentando con el paso de los años, entre 2015 y 2019 la demanda se mantuvo relativamente estable, mientras que en 2020 se produjo una caída marcada con mayor dispersión, asociada al impacto de la pandemia. A partir de 2021, la mediana anual comienza a incrementarse de forma sostenida, alcanzando máximos en 2023–2024. Asimismo, en los años más recientes se evidencia una mayor variabilidad intraanual, lo cual refleja la aparición de episodios extremos de consumo, como olas de calor e inviernos más intensos.

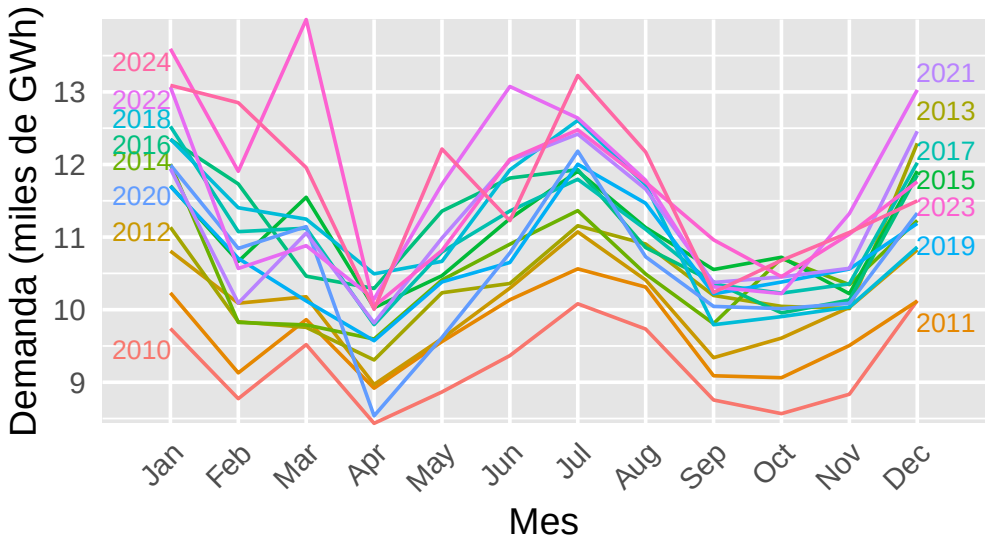


Figura 5: Evolución de la demanda mensual por año y mes

En la Figura 5 se observa que la serie tiene un patrón claramente estacional, donde en cada año se ven picos y valles recurrentes, consistentes con una demanda energética influenciada por factores climáticos, como el uso de sistemas de climatización durante períodos de temperaturas extremas. La amplitud de las fluctuaciones estacionales varía a lo largo del período, observándose valores mayores en los años más recientes

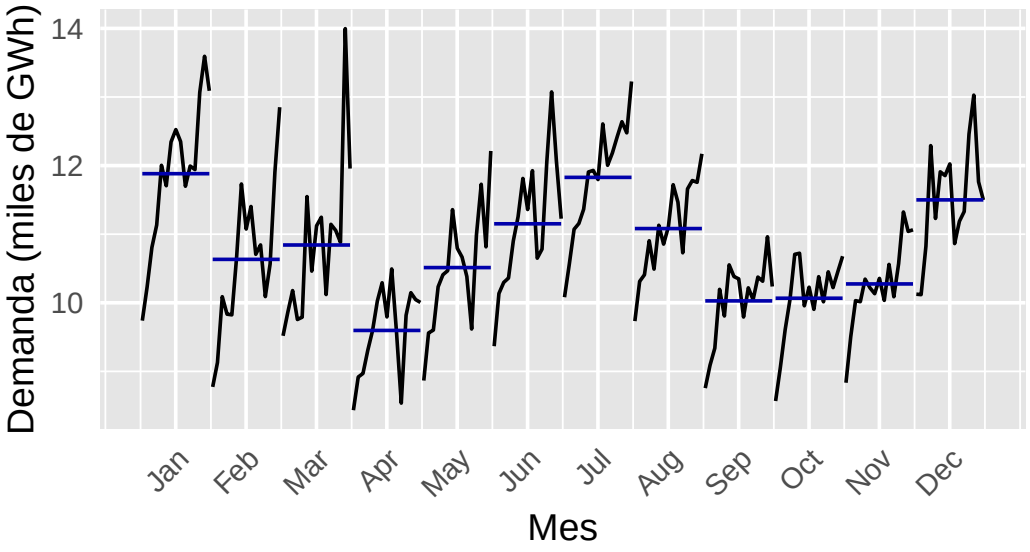


Figura 6: Gráfico estacional de la serie por mes

La Figura 6 confirma la presencia de un patrón estacional anual. Los mayores niveles medios de demanda se observan principalmente durante los meses de verano, mientras que abril presenta uno de los niveles más bajos. Este comportamiento evidencia que el nivel esperado de la serie varía sistemáticamente según el mes del año.

4.2. Resultados

4.2.1. Datos faltantes completamente al azar (MCAR)

Tabla 1: Desempeño de los métodos de imputación según RMSE, MAE y MAPE. Escenario MCAR con 10 % de datos faltantes.

Método	**RMSE**	**MAE**	**MAPE**
Valor aleatorio	1.922	1.603	15.046
Valor definido	10.846	10.798	100.000
Valor medio	1.055	0.867	8.049
Valor mediano	1.066	0.865	7.923
Valor modal	2.568	2.358	21.093
Interpolación lineal	0.762	0.598	5.524
Interpolación spline	0.871	0.653	6.079
Interpolación de Stineman	0.765	0.594	5.484
Media móvil simple	1.053	0.903	8.357
Media móvil lineal ponderada	0.969	0.827	7.648
Media móvil ponderada exponencial	0.893	0.755	6.983
Última observación trasladada hacia adelante	1.029	0.837	7.752
Siguiente observación trasladada hacia atrás	1.023	0.842	7.712
Descomposición estacional	**0.497**	**0.367**	**3.377**
División estacional	0.552	0.427	3.915
Suavizado de Kalman en un modelo estructural	0.515	0.398	3.685
Representación del espacio en estados de ARIMA y suavizado de Kalman	0.543	0.403	3.700

Tabla 2: Desempeño predictivo del modelo ARIMA según método de imputación y horizonte de pronóstico. Escenario MCAR con 10 % de datos faltantes.

	h=3			h=6			h=12		
Método	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**
Valor aleatorio	1.020	0.912	7.035	1.020	0.925	7.749	0.962	0.827	6.909
Valor definido	2.656	2.518	19.482	2.206	1.909	15.253	2.119	1.804	14.646
Valor medio	0.933	0.815	6.262	0.802	0.712	5.866	0.681	0.568	4.726
Valor mediano	0.946	0.822	6.311	0.811	0.715	5.873	0.696	0.578	4.805
Valor modal	1.290	1.154	8.864	1.198	1.052	8.636	1.121	0.942	7.769
Interpolación lineal	0.883	0.790	6.074	0.765	0.692	5.729	0.635	0.545	4.582
Interpolación spline	0.870	0.782	6.011	0.759	0.682	5.651	0.619	0.525	4.407
Interpolación de Stineman	0.875	0.784	6.030	0.760	0.688	5.705	0.633	0.540	4.533
Media móvil simple	0.934	0.830	6.392	0.827	0.747	6.200	0.714	0.617	5.213
Media móvil lineal ponderada	0.915	0.818	6.305	0.808	0.734	6.099	0.686	0.589	4.949
Media móvil ponderada exponencial	0.908	0.810	6.238	0.799	0.724	6.008	0.675	0.576	4.826
Última observación trasladada hacia adelante	0.841	0.771	5.966	0.766	0.703	5.873	0.660	0.573	4.840
Siguiente observación trasladada hacia atrás	0.939	0.836	6.423	0.805	0.716	5.917	0.670	0.559	4.679
Descomposición estacional	0.867	0.782	6.025	0.732	0.664	5.464	**0.601**	0.505	4.204
División estacional	**0.833**	**0.751**	**5.835**	**0.730**	0.662	5.467	0.607	0.511	4.257
Suavizado de Kalman en un modelo estructural	0.868	0.782	6.053	0.735	**0.655**	**5.354**	0.611	**0.496**	**4.094**
Representación del espacio en estados de ARIMA y suavizado de Kalman	0.854	0.778	6.034	0.739	0.669	5.508	0.612	0.509	4.231

Tabla 3: Desempeño predictivo del modelo ETS según método de imputación y horizonte de pronóstico. Escenario MCAR con 10 % de datos faltantes.

	h=3			h=6			h=12		
Método	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**
Valor aleatorio	1.045	0.897	6.879	0.882	0.747	6.108	0.722	0.570	4.697
Valor definido	2.569	2.428	18.786	2.146	1.861	14.890	1.975	1.674	13.581
Valor medio	1.104	0.924	7.051	0.898	0.740	5.972	0.721	0.542	4.385
Valor mediano	1.115	0.936	7.146	0.902	0.740	5.965	0.724	0.541	4.371
Valor modal	1.234	1.079	8.288	1.001	0.813	6.494	0.828	0.634	5.115
Interpolación lineal	1.078	0.921	7.042	0.868	0.722	5.834	0.690	0.524	4.245
Interpolación spline	1.066	0.926	7.100	0.857	0.718	5.809	0.681	0.519	4.220
Interpolación de Stineman	1.075	0.920	7.039	0.865	0.721	5.820	0.688	0.521	4.222
Media móvil simple	1.075	0.896	6.835	0.888	0.746	6.076	0.717	0.559	4.578
Media móvil lineal ponderada	1.085	0.909	6.934	0.891	0.744	6.034	0.716	0.553	4.508
Media móvil ponderada exponencial	1.089	0.917	6.997	0.887	0.739	5.983	0.712	0.544	4.423
Última observación trasladada hacia adelante	**0.996**	**0.846**	**6.468**	**0.833**	0.698	5.679	0.684	0.532	4.348
Siguiente observación trasladada hacia atrás	1.128	0.976	7.480	0.897	0.752	6.076	0.708	0.541	4.392
Descomposición estacional	1.085	0.916	7.012	0.861	0.700	5.614	0.677	0.495	3.985
División estacional	1.052	0.868	6.635	0.839	**0.680**	**5.468**	**0.659**	**0.478**	**3.856**
Suavizado de Kalman en un modelo estructural	1.087	0.901	6.886	0.865	0.696	5.579	0.680	0.491	3.939
Representación del espacio en estados de ARIMA y suavizado de Kalman	1.080	0.899	6.871	0.858	0.691	5.538	0.674	0.484	3.887

Los resultados de Prophet deben interpretarse como una referencia adicional y no como el resultado de una combinación entre método de imputación y modelo de pronóstico, dado que el modelo se ajusta directamente sobre la serie incompleta.

Tabla 4: Desempeño predictivo de Prophet como modelo de referencia sin imputación previa. Escenario MCAR con 10 % de datos faltantes.

	h=3			**h=6**			**h=12**		
Modelo	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**
Prophet	0.826	0.651	5.106	0.752	0.641	5.512	0.638	0.551	4.801

En términos de imputación en el escenario MCAR con 10 % de datos faltantes, la descomposición estacional presentó el menor error, con un RMSE de 0,497, seguida por el suavizado de Kalman en un modelo estructural (0,515), la representación en el espacio de estados de ARIMA con suavizado de Kalman (0,543) y la división estacional (0,552). En consecuencia, los métodos que incorporan la estructura temporal de la serie presentaron, en general, un mejor desempeño que los enfoques simples.

Al evaluar el desempeño predictivo mediante ARIMA, los resultados no reproducen exactamente este orden. Para un horizonte de 3 meses ($h = 3$), la división estacional obtuvo el menor RMSE (0,833), seguida por el método de última observación trasladada hacia adelante (0,841), mientras que la descomposición estacional alcanzó 0,867. Para $h = 6$, la división estacional volvió a presentar el menor error (0,730), aunque los métodos basados en Kalman mostraron valores muy próximos. En cambio, para $h = 12$, la descomposición estacional pasó a presentar el mejor desempeño, con un RMSE de 0,601, seguida por la división estacional (0,607).

Los resultados obtenidos con ETS muestran un comportamiento diferente. Para $h = 3$ y $h = 6$, el menor RMSE correspondió al método de última observación trasladada hacia adelante, con valores de 0,996 y 0,833, respectivamente. Para $h = 12$, en cambio, la división estacional presentó el menor RMSE (0,659). De este modo, el método con menor error de imputación no coincide necesariamente con el que produce los mejores pronósticos, y esta relación también depende del modelo y del horizonte considerados.

Por su parte, Prophet, ajustado directamente sobre la serie incompleta y sin realizar una imputación previa, presentó RMSE de 0,826, 0,752 y 0,638 para $h = 3$, $h = 6$ y $h = 12$, respectivamente. Para $h = 3$, Prophet obtuvo un desempeño ligeramente mejor que el mejor resultado de ARIMA (0,833) y claramente mejor que el obtenido con ETS (0,996). Para $h = 6$, su RMSE fue superior al mejor resultado de ARIMA (0,730), pero inferior al mejor resultado de ETS (0,833). Finalmente, para $h = 12$, Prophet presentó un RMSE de 0,638, superior al mejor resultado de ARIMA (0,601), pero inferior al obtenido con ETS (0,659).

En conjunto, este escenario muestra que con una proporción relativamente baja de datos faltantes la superioridad en términos de imputación no se traduce necesariamente en una ventaja predictiva posterior. Asimismo, Prophet constituye un *benchmark* competitivo, especialmente frente a ETS, aunque no supera sistemáticamente a los mejores resultados obtenidos mediante imputación previa y ARIMA.

Tabla 5: Desempeño de los métodos de imputación según RMSE, MAE y MAPE. Escenario MCAR con 25 % de datos faltantes.

Método	**RMSE**	**MAE**	**MAPE**
Valor aleatorio	1.925	1.590	15.012
Valor definido	10.830	10.779	100.000
Valor medio	1.066	0.865	8.063
Valor mediano	1.077	0.861	7.909
Valor modal	2.554	2.329	20.853
Interpolación lineal	0.840	0.657	6.079
Interpolación spline	0.956	0.705	6.554
Interpolación de Stineman	0.842	0.653	6.038
Media móvil simple	1.069	0.906	8.398
Media móvil lineal ponderada	0.992	0.834	7.729
Media móvil ponderada exponencial	0.928	0.772	7.149
Última observación trasladada hacia adelante	1.097	0.893	8.269
Siguiente observación trasladada hacia atrás	1.110	0.907	8.352
Descomposición estacional	0.580	0.422	3.882
División estacional	0.608	0.453	4.175
Suavizado de Kalman en un modelo estructural	**0.542**	**0.412**	**3.818**
Representación del espacio en estados de ARIMA y suavizado de Kalman	0.589	0.427	3.914

Tabla 6: Desempeño predictivo del modelo ARIMA según método de imputación y horizonte de pronóstico. Escenario MCAR con 25 % de datos faltantes.

	h=3			h=6			h=12		
Método	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**
Valor aleatorio	1.255	1.090	8.310	1.213	1.074	8.971	1.104	0.959	8.054
Valor definido	4.367	4.280	33.388	3.754	3.522	28.702	3.559	3.348	27.759
Valor medio	1.170	1.039	7.973	1.107	0.985	8.139	0.990	0.837	6.937
Valor mediano	1.211	1.072	8.225	1.139	1.009	8.314	1.017	0.853	7.051
Valor modal	1.853	1.705	13.124	1.569	1.345	10.818	1.420	1.151	9.291
Interpolación lineal	0.985	0.875	6.712	0.925	0.819	6.845	0.795	0.676	5.693
Interpolación spline	0.938	0.836	6.423	0.879	0.761	6.358	0.760	0.631	5.299
Interpolación de Stineman	0.973	0.870	6.675	0.909	0.806	6.740	0.779	0.665	5.608
Media móvil simple	1.126	0.992	7.596	1.179	1.057	8.918	1.081	0.942	7.973
Media móvil lineal ponderada	1.090	0.952	7.292	1.144	1.019	8.606	1.043	0.904	7.650
Media móvil ponderada exponencial	1.049	0.920	7.048	1.056	0.938	7.861	0.953	0.817	6.876
Última observación trasladada hacia adelante	0.972	0.867	6.675	1.029	0.915	7.741	0.945	0.816	6.911
Siguiente observación trasladada hacia atrás	1.085	0.962	7.384	1.065	0.944	7.895	0.974	0.834	6.993
Descomposición estacional	0.904	0.811	6.228	0.778	0.686	5.633	0.651	0.533	4.418
División estacional	**0.798**	**0.691**	**5.400**	0.765	0.662	5.499	0.659	0.531	4.418
Suavizado de Kalman en un modelo estructural	0.881	0.785	6.081	**0.756**	**0.644**	**5.228**	**0.649**	**0.503**	**4.112**
Representación del espacio en estados de ARIMA y suavizado de Kalman	0.869	0.753	5.873	0.816	0.703	5.818	0.699	0.564	4.683

Tabla 7: Desempeño predictivo del modelo ETS según método de imputación y horizonte de pronóstico. Escenario MCAR con 25 % de datos faltantes.

	h=3			h=6			h=12		
Método	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**
Valor aleatorio	1.213	1.066	8.166	1.022	0.870	7.097	0.858	0.698	5.742
Valor definido	4.358	4.274	33.340	3.757	3.530	28.775	3.591	3.376	28.007
Valor medio	1.204	1.040	7.943	0.998	0.843	6.838	0.826	0.648	5.269
Valor mediano	1.231	1.070	8.185	1.014	0.851	6.874	0.844	0.656	5.308
Valor modal	1.647	1.509	11.652	1.342	1.115	8.853	1.168	0.950	7.676
Interpolación lineal	1.178	1.053	8.073	0.961	0.823	6.676	0.779	0.616	5.022
Interpolación spline	1.267	1.182	9.127	1.013	0.870	7.006	0.827	0.657	5.323
Interpolación de Stineman	1.192	1.073	8.232	0.967	0.825	6.682	0.782	0.613	4.980
Media móvil simple	1.153	0.988	7.536	1.006	0.866	7.130	0.844	0.694	5.754
Media móvil lineal ponderada	1.164	0.998	7.608	0.997	0.852	6.981	0.829	0.673	5.543
Media móvil ponderada exponencial	1.156	1.002	7.653	0.975	0.836	6.831	0.805	0.651	5.352
Última observación trasladada hacia adelante	**0.970**	**0.848**	**6.486**	0.884	0.761	6.266	0.769	0.623	5.151
Siguiente observación trasladada hacia atrás	1.306	1.191	9.168	1.039	0.894	7.250	0.843	0.680	5.548
Descomposición estacional	1.179	1.051	8.076	0.936	0.779	6.240	0.743	0.556	4.466
División estacional	1.026	0.868	6.757	**0.844**	**0.689**	**5.611**	**0.690**	**0.512**	4.178
Suavizado de Kalman en un modelo estructural	1.091	0.929	7.127	0.873	0.710	5.697	0.701	0.518	**4.175**
Representación del espacio en estados de ARIMA y suavizado de Kalman	1.092	0.938	7.231	0.879	0.718	5.780	0.706	0.527	4.271

Tabla 8: Desempeño predictivo de Prophet como modelo de referencia sin imputación previa. Escenario MCAR con 25 % de datos faltantes.

	h=3			h=6			h=12		
Modelo	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**
Prophet	0.858	0.670	5.239	0.782	0.652	5.554	0.635	0.538	4.659

En el escenario de faltantes MCAR con 25 % de datos faltantes, en términos de imputación, el suavizado de Kalman en un modelo estructural presentó el menor error, con un RMSE de 0,542, seguido por la descomposición estacional (0,580), la representación en el espacio de estados de ARIMA con suavizado de Kalman (0,589) y la división estacional (0,608). Estos resultados muestran nuevamente una ventaja de los métodos que incorporan la estructura temporal de la serie frente a los enfoques simples.

Al analizar el desempeño predictivo con ARIMA, el ranking de los métodos no coincide exactamente con el obtenido en la etapa de imputación. Para $h = 3$, la división estacional presentó el menor RMSE, con un valor de 0,798, seguida por la representación en el espacio de estados de ARIMA con suavizado de Kalman (0,869) y el suavizado de Kalman en un modelo estructural (0,881). Para $h = 6$, el suavizado de Kalman en un modelo estructural presentó el menor RMSE (0,756), al igual que para $h = 12$, con un RMSE de 0,649, seguido muy de cerca por la descomposición estacional (0,651) y la división estacional (0,659).

En el caso de ETS, la relación entre imputación y pronóstico vuelve a diferir. Para $h = 3$, el método de última observación trasladada hacia adelante presentó el menor RMSE entre los métodos considerados (0,970), mientras que para $h = 6$ el menor valor correspondió la división estacional (0,844). De igual manera, para $h = 12$, el menor RMSE se obtuvo al utilizar la división estacional (0,690), seguido por el suavizado de Kalman en un modelo estructural (0,701) y la representación del espacio en estados de ARIMA y suavizado de Kalman (0,706).

Por lo tanto, al igual que en los escenarios anteriores, el menor error de imputación no garantiza el mejor desempeño predictivo posterior. En particular, aunque el suavizado de Kalman en un modelo estructural fue el método con mejor desempeño de imputación, la división estacional obtuvo mejores resultados con ARIMA para los horizontes de tres y seis meses, mientras que para horizontes más largos las diferencias entre varios métodos estructurales se reducen.

Finalmente, Prophet, que se ajusta directamente sobre la serie incompleta y no requiere imputación previa, obtuvo RMSE de 0,858, 0,782 y 0,635 para $h = 3$, $h = 6$ y $h = 12$, respectivamente. Para $h = 3$, este resultado es inferior al mejor desempeño de ARIMA (0,798), pero superior al de ETS (1,013), misma relación que se observa al analizar el caso de $h = 6$. Para $h = 12$, en cambio, Prophet alcanza un RMSE de 0,635, ligeramente inferior al mejor resultado de ARIMA (0,649) y también inferior al mejor resultado de ETS (0,664).

En conjunto, este escenario refuerza la ausencia de una correspondencia directa entre precisión de imputación y desempeño predictivo. Además, muestra que el efecto de la imputación sobre el pronóstico depende tanto del modelo utilizado como del horizonte considerado, mientras que Prophet constituye un benchmark competitivo, especialmente para horizontes de mayor extensión.

Tabla 9: Desempeño de los métodos de imputación según RMSE, MAE y MAPE. Escenario MCAR con 40 % de datos faltantes.

Método	**RMSE**	**MAE**	**MAPE**
Valor aleatorio	1.903	1.570	14.764
Valor definido	10.847	10.793	100.000
Valor medio	1.093	0.884	8.215
Valor mediano	1.109	0.884	8.105
Valor modal	2.534	2.295	20.480
Interpolación lineal	0.924	0.730	6.735
Interpolación spline	1.146	0.819	7.566
Interpolación de Stineman	0.933	0.732	6.744
Media móvil simple	1.091	0.919	8.488
Media móvil lineal ponderada	1.027	0.857	7.915
Media móvil ponderada exponencial	0.982	0.809	7.467
Última observación trasladada hacia adelante	1.161	0.944	8.718
Siguiente observación trasladada hacia atrás	1.156	0.940	8.646
Descomposición estacional	0.664	0.494	4.546
División estacional	0.638	0.474	4.373
Suavizado de Kalman en un modelo estructural	**0.568**	**0.432**	**3.990**
Representación del espacio en estados de ARIMA y suavizado de Kalman	0.613	0.450	4.130

Tabla 10: Desempeño predictivo del modelo ARIMA según método de imputación y horizonte de pronóstico. Escenario MCAR con 40 % de datos faltantes.

	h=3			h=6			h=12		
Método	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**
Valor aleatorio	1.509	1.304	9.912	1.365	1.193	9.865	1.231	1.055	8.770
Valor definido	6.190	6.125	47.925	5.498	5.323	43.893	5.313	5.158	43.230
Valor medio	1.403	1.222	9.328	1.269	1.099	9.008	1.134	0.942	7.749
Valor mediano	1.452	1.268	9.681	1.301	1.124	9.183	1.163	0.959	7.850
Valor modal	2.411	2.273	17.551	1.987	1.702	13.534	1.804	1.481	11.877
Interpolación lineal	1.162	1.030	7.881	1.167	1.024	8.581	1.071	0.903	7.562
Interpolación spline	1.283	1.144	8.812	1.296	1.125	9.438	1.185	0.995	8.366
Interpolación de Stineman	1.162	1.040	7.981	1.173	1.024	8.583	1.071	0.894	7.472
Media móvil simple	1.283	1.104	8.394	1.282	1.131	9.536	1.166	1.017	8.624
Media móvil lineal ponderada	1.244	1.072	8.156	1.257	1.109	9.359	1.144	0.996	8.442
Media móvil ponderada exponencial	1.200	1.040	7.924	1.224	1.082	9.129	1.120	0.973	8.232
Última observación trasladada hacia adelante	1.155	1.019	7.809	1.233	1.084	9.215	1.141	0.985	8.384
Siguiente observación trasladada hacia atrás	1.271	1.126	8.611	1.235	1.087	9.103	1.121	0.967	8.112
Descomposición estacional	1.022	0.909	6.968	0.888	0.770	6.354	**0.738**	0.607	5.055
División estacional	**0.871**	**0.738**	**5.834**	0.860	0.707	5.861	0.751	0.583	4.835
Suavizado de Kalman en un modelo estructural	0.996	0.869	6.770	**0.851**	**0.702**	**5.682**	0.743	**0.567**	**4.627**
Representación del espacio en estados de ARIMA y suavizado de Kalman	0.959	0.817	6.429	0.923	0.766	6.346	0.803	0.634	5.261

Tabla 11: Desempeño predictivo del modelo ETS según método de imputación y horizonte de pronóstico. Escenario MCAR con 40 % de datos faltantes.

	h=3			h=6			h=12		
Método	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**
Valor aleatorio	1.414	1.245	9.512	1.219	1.048	8.564	1.055	0.870	7.160
Valor definido	6.160	6.096	47.694	5.472	5.313	43.833	5.289	5.150	43.180
Valor medio	1.396	1.236	9.447	1.155	0.978	7.892	0.976	0.772	6.236
Valor mediano	1.430	1.277	9.774	1.182	0.996	8.018	1.002	0.785	6.325
Valor modal	2.191	2.074	16.062	1.817	1.565	12.477	1.633	1.387	11.239
Interpolación lineal	1.333	1.218	9.355	1.101	0.952	7.735	0.914	0.741	6.048
Interpolación spline	1.508	1.435	11.113	1.204	1.041	8.361	0.992	0.794	6.407
Interpolación de Stineman	1.366	1.260	9.688	1.113	0.961	7.779	0.920	0.738	5.997
Media móvil simple	1.254	1.089	8.298	1.132	0.986	8.159	0.979	0.830	6.916
Media móvil lineal ponderada	1.272	1.116	8.516	1.118	0.969	7.972	0.956	0.800	6.619
Media móvil ponderada exponencial	1.286	1.143	8.740	1.109	0.960	7.865	0.945	0.778	6.403
Última observación trasladada hacia adelante	1.053	0.914	6.981	1.013	0.865	7.166	0.913	0.742	6.168
Siguiente observación trasladada hacia atrás	1.555	1.452	11.207	1.232	1.067	8.631	1.025	0.843	6.859
Descomposición estacional	1.323	1.226	9.462	1.054	0.894	7.173	0.846	0.652	5.246
División estacional	**0.938**	**0.793**	**6.300**	0.891	**0.715**	5.893	0.783	0.589	4.859
Suavizado de Kalman en un modelo estructural	1.067	0.924	7.159	**0.883**	0.723	**5.826**	**0.743**	**0.561**	**4.545**
Representación del espacio en estados de ARIMA y suavizado de Kalman	1.188	1.037	8.091	1.002	0.814	6.586	0.844	0.644	5.245

Tabla 12: Desempeño predictivo de Prophet como modelo de referencia sin imputación previa. Escenario MCAR con 40 % de datos faltantes.

	h=3			h=6			h=12		
Modelo	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**
Prophet	0.919	0.724	5.628	0.803	0.673	5.676	0.638	0.524	4.489

Para un 40 % de datos faltantes bajo el mecanismo MCAR, los métodos que aprovechan la estructura temporal de la serie presentaron, en general, menores errores de imputación que los enfoques simples. El suavizado de Kalman en un modelo estructural obtuvo el menor RMSE de imputación (0,568), seguido por la representación en el espacio de estados de ARIMA con suavizado de Kalman (0,613), la división estacional (0,638) y la descomposición estacional (0,664). En contraste, los métodos basados en valores constantes presentaron errores sustancialmente mayores.

Sin embargo, este orden no se reproduce exactamente al evaluar el desempeño predictivo. Para ARIMA y un horizonte de tres meses ($h = 3$), la división estacional presentó el menor RMSE entre los métodos basados en la estructura temporal considerados (0,871), mientras que el suavizado de Kalman en un modelo estructural alcanzó 0,996. Para $h = 12$, en cambio, ambos métodos mostraron desempeños similares, con RMSE de 0,751 y 0,743, respectivamente.

Un comportamiento similar se observa con ETS: para $h = 3$, la división estacional presentó un RMSE de 0,938, inferior al obtenido mediante el suavizado de Kalman en un modelo estructural (1,067), mientras que para $h = 12$ los resultados fueron 0,783 y 0,743, respectivamente.

En cuanto a Prophet, que se ajusta directamente sobre la serie con datos faltantes y, por lo tanto, no requiere una etapa previa de imputación, se obtuvieron RMSE de 0,919, 0,803 y 0,638 para $h = 3$, $h = 6$ y $h = 12$, respectivamente. Para el horizonte de corto plazo, su desempeño fue inferior al mejor resultado obtenido con ARIMA (0,871), aunque superior al mejor resultado de ETS (0,938). En cambio, para $h = 6$ y $h = 12$, Prophet presentó menores errores que los obtenidos con ARIMA y ETS a partir de las series imputadas.

En conjunto, estos resultados muestran que el método con menor error de imputación no necesariamente produce los mejores pronósticos posteriores. Asimismo, la comparación con Prophet sugiere que, a medida que aumenta el horizonte de pronóstico, un modelo que trabaja directamente con la serie incompleta puede alcanzar un desempeño competitivo o incluso superior al obtenido mediante estrategias de imputación previa.

4.2.2. Datos faltantes completamente al azar en bloques (MCAR en bloques)

Tabla 13: Desempeño de los métodos de imputación según RMSE, MAE y MAPE. Escenario MCAR en bloques con 10 % de datos faltantes.

Método	**RMSE**	**MAE**	**MAPE**
Valor aleatorio	1.949	1.621	15.240
Valor definido	10.844	10.801	100.000
Valor medio	1.065	0.877	8.125
Valor mediano	1.080	0.874	7.996
Valor modal	2.558	2.363	21.125
Interpolación lineal	1.070	0.898	8.257
Interpolación spline	1.993	1.588	14.643
Interpolación de Stineman	1.126	0.936	8.603
Media móvil simple	1.142	0.970	8.947
Media móvil lineal ponderada	1.127	0.957	8.825
Media móvil ponderada exponencial	1.133	0.962	8.872
Última observación trasladada hacia adelante	1.182	0.979	9.014
Siguiente observación trasladada hacia atrás	1.221	1.016	9.349
Descomposición estacional	0.555	0.431	3.944
División estacional	0.528	0.412	3.783
Suavizado de Kalman en un modelo estructural	**0.519**	**0.406**	**3.745**
Representación del espacio en estados de ARIMA y suavizado de Kalman	0.532	0.409	3.748

Tabla 14: Desempeño predictivo del modelo ARIMA según método de imputación y horizonte de pronóstico. Escenario MCAR en bloques con 10 % de datos faltantes.

	h=3			h=6			h=12		
Método	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**
Valor aleatorio	1.079	0.974	7.499	1.032	0.932	7.753	0.965	0.840	7.060
Valor definido	1.801	1.661	12.796	1.660	1.448	11.718	1.792	1.550	12.715
Valor medio	0.973	0.876	6.741	0.829	0.740	6.075	0.698	0.582	4.831
Valor mediano	0.979	0.878	6.753	0.833	0.742	6.084	0.702	0.588	4.878
Valor modal	1.207	1.099	8.466	1.105	0.965	7.879	1.103	0.916	7.528
Interpolación lineal	0.966	0.882	6.800	0.834	0.756	6.256	0.721	0.617	5.182
Interpolación spline	1.122	1.012	7.802	1.041	0.902	7.373	0.986	0.821	6.869
Interpolación de Stineman	0.984	0.898	6.919	0.850	0.765	6.311	0.735	0.625	5.235
Media móvil simple	0.950	0.869	6.702	0.859	0.786	6.519	0.769	0.662	5.568
Media móvil lineal ponderada	0.966	0.888	6.852	0.861	0.786	6.513	0.749	0.643	5.403
Media móvil ponderada exponencial	0.969	0.887	6.837	0.862	0.785	6.502	0.762	0.659	5.545
Última observación trasladada hacia adelante	0.947	0.857	6.595	0.826	0.745	6.157	0.732	0.630	5.310
Siguiente observación trasladada hacia atrás	0.994	0.898	6.916	0.853	0.757	6.215	0.765	0.639	5.312
Descomposición estacional	0.875	0.784	6.042	0.740	0.665	5.451	0.612	0.505	4.185
División estacional	**0.821**	**0.749**	**5.806**	**0.722**	0.662	5.458	**0.607**	0.507	4.220
Suavizado de Kalman en un modelo estructural	0.862	0.783	6.053	0.732	**0.655**	**5.352**	0.610	**0.491**	**4.043**
Representación del espacio en estados de ARIMA y suavizado de Kalman	0.862	0.783	6.057	0.734	0.663	5.440	0.612	0.505	4.190

Tabla 15: Desempeño predictivo del modelo ETS según método de imputación y horizonte de pronóstico. Escenario MCAR en bloques con 10 % de datos faltantes.

	h=3			h=6			h=12		
Método	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**
Valor aleatorio	1.099	0.939	7.178	0.908	0.760	6.161	0.735	0.572	4.668
Valor definido	1.524	1.360	10.478	1.402	1.227	10.152	1.265	1.095	9.141
Valor medio	1.151	0.979	7.485	0.927	0.762	6.128	0.740	0.554	4.465
Valor mediano	1.144	0.974	7.442	0.921	0.760	6.115	0.735	0.554	4.472
Valor modal	1.362	1.208	9.274	1.085	0.876	6.954	0.881	0.666	5.331
Interpolación lineal	1.171	1.000	7.642	0.941	0.776	6.237	0.745	0.565	4.567
Interpolación spline	1.408	1.265	9.727	1.119	0.919	7.316	0.892	0.676	5.414
Interpolación de Stineman	1.197	1.031	7.887	0.959	0.788	6.326	0.759	0.571	4.607
Media móvil simple	1.126	0.943	7.193	0.921	0.766	6.204	0.739	0.571	4.651
Media móvil lineal ponderada	1.139	0.959	7.320	0.928	0.769	6.213	0.742	0.571	4.643
Media móvil ponderada exponencial	1.160	0.982	7.494	0.941	0.778	6.276	0.752	0.577	4.681
Última observación trasladada hacia adelante	1.160	0.988	7.550	0.937	0.770	6.191	0.748	0.563	4.548
Siguiente observación trasladada hacia atrás	1.212	1.044	7.991	0.968	0.794	6.370	0.768	0.575	4.633
Descomposición estacional	1.084	0.904	6.911	0.863	0.698	5.593	0.677	0.493	3.967
División estacional	1.080	0.891	6.807	0.857	0.686	5.497	0.675	**0.482**	**3.870**
Suavizado de Kalman en un modelo estructural	1.091	0.902	6.884	0.868	0.695	5.569	0.684	0.491	3.942
Representación del espacio en estados de ARIMA y suavizado de Kalman	**1.080**	**0.890**	**6.797**	**0.856**	**0.686**	**5.497**	**0.670**	0.483	3.884

Tabla 16: Desempeño predictivo de Prophet como modelo de referencia sin imputación previa. Escenario MCAR en bloques con 10 % de datos faltantes.

	h=3			h=6			h=12		
Modelo	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**
Prophet	0.836	0.650	5.103	0.753	0.640	5.502	0.632	0.546	4.756

En el caso de 10 % de datos faltantes bajo el mecanismo MCAR en bloques, los métodos que aprovechan la estructura de la serie presentaron, en general, menores errores de imputación que los enfoques simples. El suavizado de Kalman en un modelo estructural obtuvo el menor RMSE de imputación (0,519), seguido por la división estacional (0,528) y la representación del espacio en estados de ARIMA y suavizado de Kalman (0,532).

Sin embargo, este orden no se replica al evaluar el desempeño predictivo. En el caso del modelo ARIMA y un horizonte de tres meses ($h = 3$), la división estacional presentó el menor RMSE (0,821), seguido por el suavizado de Kalman en un modelo estructural y por la representación del espacio en estados de ARIMA y suavizado de Kalman, que alcanzaron 0,862. Para $h = 12$, en cambio, los tres métodos mostraron desempeños similares, con RMSE de 0,607, 0,610 y 0,612, respectivamente.

En el caso del modelo ETS, para $h = 3$, la representación del espacio en estados de ARIMA y suavizado de Kalman presentó un RMSE de 1,080, al igual que el método de división estacional, siendo levemente inferior al obtenido mediante la descomposición estacional (1,084), mientras que para $h = 12$ los resultados fueron 0,670, 0,675 y 0,677, respectivamente.

Con respecto al modelo Prophet, se obtuvieron RMSE de 0,836, 0,753 y 0,632 para $h = 3$, $h = 6$ y $h = 12$, respectivamente. Para el horizonte de corto plazo, su desempeño fue inferior al mejor resultado obtenido con ARIMA (0,821), aunque superior al mejor resultado de ETS (1,080). Para $h = 6$ y $h = 12$, Prophet presentó mayores errores que los obtenidos con ARIMA, pero menores que los obtenidos con el modelo ETS a partir de las series imputadas.

En conjunto, estos resultados muestran que el método con menor error de imputación no necesariamente produce los mejores pronósticos posteriores, al igual que en escenarios anteriores. De igual manera, la comparación con Prophet sugiere que al aumentar el horizonte de pronóstico, un modelo que trabaja con la serie incompleta puede alcanzar un desempeño similar o incluso superior al obtenido mediante estrategias de imputación previa.

Tabla 17: Desempeño de los métodos de imputación según RMSE, MAE y MAPE. Escenario MCAR en bloques con 25 % de datos faltantes.

Método	**RMSE**	**MAE**	**MAPE**
Valor aleatorio	1.905	1.571	14.668
Valor definido	10.887	10.839	100.000
Valor medio	1.055	0.853	7.838
Valor mediano	1.077	0.857	7.767
Valor modal	2.604	2.396	21.390
Interpolación lineal	1.125	0.924	8.478
Interpolación spline	2.378	1.833	16.849
Interpolación de Stineman	1.180	0.966	8.851
Media móvil simple	1.165	0.967	8.890
Media móvil lineal ponderada	1.156	0.958	8.807
Media móvil ponderada exponencial	1.165	0.967	8.883
Última observación trasladada hacia adelante	1.228	1.001	9.181
Siguiente observación trasladada hacia atrás	1.247	1.025	9.425
Descomposición estacional	0.675	0.518	4.730
División estacional	0.583	0.436	3.972
Suavizado de Kalman en un modelo estructural	**0.567**	**0.433**	**3.967**
Representación del espacio en estados de ARIMA y suavizado de Kalman	0.598	0.448	4.084

Tabla 18: Desempeño predictivo del modelo ARIMA según método de imputación y horizonte de pronóstico. Escenario MCAR en bloques con 25 % de datos faltantes.

	h=3			h=6			h=12		
Método	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**
Valor aleatorio	1.302	1.129	8.599	1.237	1.089	9.067	1.130	0.975	8.153
Valor definido	2.492	2.430	18.975	2.460	2.248	18.314	2.773	2.561	21.300
Valor medio	1.151	1.029	7.891	1.083	0.967	7.977	0.976	0.825	6.824
Valor mediano	1.178	1.055	8.092	1.104	0.983	8.094	0.995	0.837	6.914
Valor modal	1.574	1.438	11.062	1.451	1.253	10.134	1.371	1.132	9.205
Interpolación lineal	1.141	1.023	7.855	1.117	0.996	8.289	1.008	0.854	7.116
Interpolación spline	1.337	1.181	9.109	1.348	1.160	9.634	1.245	1.024	8.504
Interpolación de Stineman	1.150	1.041	8.001	1.118	1.004	8.347	1.014	0.860	7.147
Media móvil simple	1.200	1.052	8.032	1.175	1.041	8.665	1.075	0.917	7.646
Media móvil lineal ponderada	1.185	1.042	7.956	1.161	1.029	8.553	1.061	0.899	7.486
Media móvil ponderada exponencial	1.177	1.045	7.998	1.158	1.036	8.637	1.051	0.898	7.499
Última observación trasladada hacia adelante	1.162	1.044	8.025	1.144	1.013	8.446	1.047	0.886	7.407
Siguiente observación trasladada hacia atrás	1.240	1.123	8.616	1.155	1.027	8.456	1.053	0.887	7.316
Descomposición estacional	0.978	0.863	6.627	0.833	0.724	5.898	0.690	0.547	4.495
División estacional	**0.758**	**0.677**	**5.272**	**0.753**	0.665	5.508	**0.647**	0.529	4.394
Suavizado de Kalman en un modelo estructural	0.897	0.803	6.223	0.777	**0.663**	**5.360**	0.662	**0.506**	**4.109**
Representación del espacio en estados de ARIMA y suavizado de Kalman	0.883	0.799	6.220	0.781	0.680	5.576	0.659	0.527	4.341

Tabla 19: Desempeño predictivo del modelo ETS según método de imputación y horizonte de pronóstico. Escenario MCAR en bloques con 25 % de datos faltantes.

	h=3			h=6			h=12		
Método	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**
Valor aleatorio	1.278	1.127	8.628	1.064	0.896	7.260	0.891	0.709	5.786
Valor definido	1.532	1.313	10.023	1.410	1.228	10.251	1.275	1.117	9.392
Valor medio	1.279	1.116	8.522	1.042	0.873	7.037	0.856	0.665	5.369
Valor mediano	1.295	1.135	8.683	1.053	0.883	7.108	0.863	0.672	5.430
Valor modal	1.473	1.338	10.293	1.197	1.003	8.055	1.000	0.785	6.368
Interpolación lineal	1.367	1.210	9.256	1.100	0.923	7.424	0.893	0.695	5.617
Interpolación spline	1.524	1.393	10.711	1.232	1.039	8.324	1.019	0.803	6.479
Interpolación de Stineman	1.392	1.236	9.464	1.120	0.939	7.551	0.910	0.708	5.717
Media móvil simple	1.297	1.119	8.531	1.076	0.912	7.404	0.887	0.708	5.779
Media móvil lineal ponderada	1.334	1.159	8.844	1.096	0.924	7.476	0.903	0.713	5.799
Media móvil ponderada exponencial	1.368	1.196	9.135	1.113	0.935	7.543	0.914	0.716	5.805
Última observación trasladada hacia adelante	1.309	1.142	8.724	1.073	0.897	7.239	0.883	0.687	5.572
Siguiente observación trasladada hacia atrás	1.402	1.249	9.565	1.123	0.941	7.565	0.914	0.712	5.745
Descomposición estacional	1.176	1.013	7.760	0.941	0.776	6.237	0.745	0.557	4.490
División estacional	**1.013**	**0.862**	**6.669**	**0.825**	**0.679**	**5.497**	**0.664**	**0.489**	**3.964**
Suavizado de Kalman en un modelo estructural	1.123	0.947	7.253	0.895	0.727	5.827	0.711	0.517	4.152
Representación del espacio en estados de ARIMA y suavizado de Kalman	1.100	0.929	7.134	0.878	0.710	5.699	0.696	0.507	4.085

Tabla 20: Desempeño predictivo de Prophet como modelo de referencia sin imputación previa. Escenario MCAR en bloques con 25 % de datos faltantes.

	h=3			h=6			h=12		
Modelo	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**
Prophet	0.885	0.688	5.358	0.767	0.644	5.474	0.627	0.529	4.564

En el escenario MCAR en bloques con un 25 % de datos faltantes, los métodos que incorporan

la estructura temporal de la serie presentaron los menores errores de imputación. El suavizado de Kalman en un modelo estructural obtuvo el menor RMSE (0,567), seguido por la división estacional (0,583) y la representación en el espacio de estados de ARIMA con suavizado de Kalman (0,598). En contraste, los métodos simples mostraron errores más elevados, mientras que la interpolación spline presentó un RMSE particularmente alto (2,378), lo que refleja las dificultades de algunos métodos para reconstruir series con faltantes agrupados en bloques.

Al evaluar el desempeño predictivo con ARIMA, el orden de los métodos difiere del observado en la imputación. La división estacional obtuvo los menores RMSE para los tres horizontes, con valores de 0,758, 0,753 y 0,647 para $h = 3$, $h = 6$ y $h = 12$, respectivamente. Por lo tanto, aunque el suavizado de Kalman en un modelo estructural fue el método más preciso para reconstruir los valores faltantes, la división estacional condujo a mejores pronósticos. Con ETS se observa un patrón similar: la división estacional presentó los menores errores para los tres horizontes, con RMSE de 1,013, 0,825 y 0,664, respectivamente.

En consecuencia, este escenario muestra que una mejor reconstrucción de los datos no garantiza un mejor desempeño predictivo posterior. La diferencia se mantiene para los distintos horizontes, aunque los errores disminuyen a medida que aumenta el horizonte de pronóstico en varios de los métodos evaluados.

Por otro lado, los valores de RMSE obtenidos con el modelo Prophet son 0,885, 0,767 y 0,627 para $h = 3$, $h = 6$ y $h = 12$, respectivamente. Para los dos primeros horizontes, sus errores fueron superiores a los mejores resultados de ARIMA (0,758 y 0,753), aunque inferiores a los de ETS (1,013 y 0,825). Para $h = 12$, en cambio, Prophet obtuvo un menor RMSE que ambos modelos: 0,627 frente a 0,647 para ARIMA y 0,664 para ETS. Esto indica que el modelo de referencia sin imputación previa puede resultar competitivo, especialmente para horizontes más largos.

Tabla 21: Desempeño de los métodos de imputación según RMSE, MAE y MAPE. Escenario MCAR en bloques con 40 % de datos faltantes.

Método	**RMSE**	**MAE**	**MAPE**
Valor aleatorio	1.868	1.538	14.443
Valor definido	10.855	10.805	100.000
Valor medio	1.059	0.857	7.930
Valor mediano	1.078	0.858	7.833
Valor modal	2.558	2.340	20.929
Interpolación lineal	1.083	0.882	8.150
Interpolación spline	2.695	2.006	18.570
Interpolación de Stineman	1.142	0.925	8.541
Media móvil simple	1.126	0.933	8.621
Media móvil lineal ponderada	1.115	0.922	8.516
Media móvil ponderada exponencial	1.125	0.928	8.566
Última observación trasladada hacia adelante	1.179	0.960	8.852
Siguiente observación trasladada hacia atrás	1.229	1.009	9.328
Descomposición estacional	0.764	0.596	5.484
División estacional	0.622	0.462	4.236
Suavizado de Kalman en un modelo estructural	**0.567**	**0.433**	**3.992**
Representación del espacio en estados de ARIMA y suavizado de Kalman	0.606	0.452	4.127

Tabla 22: Desempeño predictivo del modelo ARIMA según método de imputación y horizonte de pronóstico. Escenario MCAR en bloques con 40 % de datos faltantes.

	h=3			h=6			h=12		
Método	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**
Valor aleatorio	1.498	1.292	9.821	1.360	1.184	9.804	1.223	1.050	8.736
Valor definido	2.999	2.939	23.057	3.147	2.975	24.653	3.663	3.473	29.240
Valor medio	1.385	1.241	9.499	1.242	1.093	8.948	1.121	0.935	7.676
Valor mediano	1.422	1.278	9.792	1.272	1.117	9.130	1.151	0.953	7.797
Valor modal	1.850	1.731	13.363	1.677	1.457	11.722	1.643	1.386	11.258
Interpolación lineal	1.279	1.126	8.594	1.225	1.088	9.066	1.114	0.955	7.974
Interpolación spline	1.720	1.546	11.979	1.681	1.467	12.290	1.598	1.344	11.287
Interpolación de Stineman	1.288	1.122	8.547	1.226	1.078	8.953	1.118	0.947	7.865
Media móvil simple	1.379	1.208	9.211	1.297	1.148	9.559	1.177	1.016	8.502
Media móvil lineal ponderada	1.358	1.186	9.041	1.277	1.131	9.418	1.154	0.995	8.319
Media móvil ponderada exponencial	1.333	1.165	8.878	1.264	1.123	9.365	1.143	0.991	8.303
Última observación trasladada hacia adelante	1.304	1.148	8.774	1.264	1.111	9.286	1.151	0.987	8.279
Siguiente observación trasladada hacia atrás	1.350	1.190	9.090	1.255	1.102	9.109	1.145	0.971	8.057
Descomposición estacional	1.120	0.995	7.633	0.962	0.836	6.838	0.804	0.653	5.386
División estacional	**0.881**	**0.762**	**6.025**	0.874	0.710	5.881	0.758	0.585	4.846
Suavizado de Kalman en un modelo estructural	0.991	0.881	6.844	**0.852**	**0.705**	**5.687**	**0.739**	**0.564**	**4.586**
Representación del espacio en estados de ARIMA y suavizado de Kalman	0.985	0.860	6.776	0.903	0.742	6.108	0.777	0.600	4.952

Tabla 23: Desempeño predictivo del modelo ETS según método de imputación y horizonte de pronóstico. Escenario MCAR en bloques con 40 % de datos faltantes.

	h=3			h=6			h=12		
Método	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**
Valor aleatorio	1.449	1.282	9.800	1.248	1.068	8.731	1.067	0.882	7.261
Valor definido	1.628	1.406	10.722	1.500	1.318	10.963	1.342	1.175	9.825
Valor medio	1.440	1.280	9.792	1.184	0.999	8.050	0.996	0.785	6.332
Valor mediano	1.454	1.298	9.937	1.195	1.009	8.120	1.006	0.796	6.420
Valor modal	1.485	1.338	10.275	1.253	1.057	8.543	1.074	0.856	6.969
Interpolación lineal	1.436	1.273	9.722	1.181	1.004	8.124	0.982	0.786	6.386
Interpolación spline	1.549	1.396	10.739	1.359	1.168	9.554	1.218	1.007	8.331
Interpolación de Stineman	1.453	1.289	9.852	1.189	1.010	8.171	0.988	0.790	6.418
Media móvil simple	1.410	1.231	9.387	1.204	1.025	8.356	1.019	0.828	6.786
Media móvil lineal ponderada	1.423	1.242	9.462	1.197	1.018	8.275	1.009	0.818	6.677
Media móvil ponderada exponencial	1.443	1.262	9.620	1.202	1.023	8.299	1.007	0.816	6.659
Última observación trasladada hacia adelante	1.338	1.170	8.922	1.139	0.969	7.891	0.959	0.776	6.358
Siguiente observación trasladada hacia atrás	1.489	1.333	10.206	1.210	1.029	8.310	1.004	0.804	6.517
Descomposición estacional	1.311	1.158	8.867	1.062	0.888	7.141	0.856	0.666	5.386
División estacional	**0.967**	**0.825**	**6.530**	**0.888**	**0.709**	**5.824**	0.762	**0.566**	4.650
Suavizado de Kalman en un modelo estructural	1.104	0.957	7.395	0.917	0.745	5.976	**0.761**	0.569	**4.590**
Representación del espacio en estados de ARIMA y suavizado de Kalman	1.080	0.938	7.320	0.916	0.746	6.040	0.763	0.573	4.659

Tabla 24: Desempeño predictivo de Prophet como modelo de referencia sin imputación previa. Escenario MCAR en bloques con 40 % de datos faltantes.

	h=3			h=6			h=12		
Modelo	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**
Prophet	0.959	0.752	5.836	0.810	0.675	5.656	0.641	0.524	4.465

Cuando la proporción de datos faltantes en bloques aumenta al 40 %, el suavizado de Kalman en

un modelo estructural vuelve a presentar el menor error de imputación, con un RMSE de 0,567. Le siguen la representación en el espacio de estados de ARIMA con suavizado de Kalman (0,606) y la división estacional (0,622). Por su parte, la interpolación spline presenta un error considerablemente mayor (2,695), lo que evidencia sus dificultades en este escenario de faltantes agrupados. En términos generales, los métodos que aprovechan la estructura temporal mostraron una mejor capacidad de reconstrucción que los enfoques simples.

Los resultados predictivos con ARIMA no reproducen exactamente este orden. Para $h = 3$, la división estacional obtuvo el menor RMSE (0,881), mientras que para $h = 6$ y $h = 12$ el mejor desempeño correspondió al suavizado de Kalman en un modelo estructural, con valores de 0,852 y 0,739, respectivamente. Con ETS, la división estacional presentó los menores errores para $h = 3$ y $h = 6$, con RMSE de 0,967 y 0,888. Para $h = 12$, el menor error correspondió al suavizado de Kalman en un modelo estructural (0,761), aunque la división estacional alcanzó un valor prácticamente idéntico (0,762).

Estos resultados muestran que la relación entre el error de imputación y el desempeño predictivo continúa dependiendo del modelo utilizado y del horizonte de pronóstico. En particular, el suavizado de Kalman en un modelo estructural, que fue el mejor método de imputación, no fue el más preciso en todos los horizontes. La división estacional presentó una ventaja en los pronósticos de corto plazo con ARIMA y en los de corto y mediano plazo con ETS.

En cuanto a Prophet, sus RMSE fueron 0,959, 0,810 y 0,641 para $h = 3$, $h = 6$ y $h = 12$, respectivamente. Para $h = 3$, su error fue ligeramente inferior al mejor resultado de ETS (0,967), aunque superior al de ARIMA (0,881). En los horizontes de seis y doce meses, Prophet superó a los mejores resultados de ambos modelos que requieren imputación previa. Por lo tanto, en este escenario de elevada pérdida de información agrupada, Prophet constituye una alternativa competitiva, particularmente para horizontes más largos.

4.2.3. Datos faltantes no al azar (MNAR)

Tabla 25: Desempeño de los métodos de imputación según RMSE, MAE y MAPE. Escenario MNAR con 10 % de datos faltantes.

Método	**RMSE**	**MAE**	**MAPE**
Valor aleatorio	1.976	1.632	13.660
Valor definido	11.885	11.835	100.000
Valor medio	1.607	1.350	10.906
Valor mediano	1.722	1.457	11.759
Valor modal	3.573	3.401	28.086
Interpolación lineal	1.101	0.872	7.117
Interpolación spline	1.177	0.830	6.848
Interpolación de Stineman	1.116	0.873	7.134
Media móvil simple	1.408	1.225	10.054
Media móvil lineal ponderada	1.327	1.143	9.356
Media móvil ponderada exponencial	1.252	1.066	8.713
Última observación trasladada hacia adelante	1.212	1.022	8.502
Siguiente observación trasladada hacia atrás	1.420	1.138	9.369
Descomposición estacional	0.788	0.548	4.465
División estacional	0.838	0.607	4.949
Suavizado de Kalman en un modelo estructural	**0.774**	**0.547**	**4.456**
Representación del espacio en estados de ARIMA y suavizado de Kalman	0.787	0.562	4.578

Tabla 26: Desempeño predictivo del modelo ARIMA según método de imputación y horizonte de pronóstico. Escenario MNAR con 10 % de datos faltantes.

	h=3			h=6			h=12		
Método	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**
Valor aleatorio	1.332	1.166	8.918	1.183	1.020	8.341	1.099	0.899	7.375
Valor definido	3.363	3.219	24.983	2.777	2.418	19.281	2.631	2.298	18.682
Valor medio	1.331	1.161	8.880	1.087	0.906	7.271	0.969	0.757	6.107
Valor mediano	1.415	1.227	9.384	1.184	0.992	7.996	1.059	0.836	6.776
Valor modal	2.022	1.831	14.061	1.656	1.400	11.255	1.497	1.190	9.573
Interpolación lineal	1.062	0.938	7.171	0.866	0.751	6.099	0.743	0.604	4.939
Interpolación spline	1.028	0.931	7.145	0.837	0.727	5.913	0.713	0.582	4.777
Interpolación de Stineman	1.068	0.951	7.280	0.868	0.752	6.096	0.743	0.603	4.927
Media móvil simple	1.175	1.011	7.703	0.985	0.834	6.742	0.858	0.686	5.594
Media móvil lineal ponderada	1.148	0.988	7.527	0.950	0.802	6.465	0.810	0.647	5.269
Media móvil ponderada exponencial	1.119	0.967	7.374	0.924	0.785	6.347	0.783	0.631	5.149
Última observación trasladada hacia adelante	0.986	0.859	6.561	0.843	0.729	5.942	0.740	0.609	5.003
Siguiente observación trasladada hacia atrás	1.198	1.096	8.440	0.954	0.825	6.675	0.804	0.641	5.225
Descomposición estacional	0.965	0.845	6.469	**0.796**	0.690	5.605	**0.659**	0.523	4.278
División estacional	**0.935**	0.809	6.231	0.799	0.689	5.615	0.678	0.526	4.307
Suavizado de Kalman en un modelo estructural	0.967	0.826	6.343	0.802	0.681	5.521	0.671	**0.510**	**4.147**
Representación del espacio en estados de ARIMA y suavizado de Kalman	0.940	**0.808**	**6.209**	0.799	**0.680**	**5.521**	0.672	0.523	4.272

Tabla 27: Desempeño predictivo del modelo ETS según método de imputación y horizonte de pronóstico. Escenario MNAR con 10 % de datos faltantes.

	h=3			h=6			h=12		
Método	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**
Valor aleatorio	1.254	1.107	8.492	1.006	0.826	6.600	0.811	0.609	4.886
Valor definido	3.398	3.264	25.319	2.803	2.455	19.585	2.586	2.268	18.435
Valor medio	1.304	1.161	8.902	1.032	0.845	6.714	0.835	0.617	4.908
Valor mediano	1.330	1.190	9.132	1.054	0.862	6.852	0.857	0.636	5.063
Valor modal	1.799	1.668	12.852	1.421	1.158	9.120	1.194	0.929	7.401
Interpolación lineal	1.202	1.072	8.231	0.949	0.786	6.271	0.760	0.565	4.517
Interpolación spline	1.176	1.064	8.194	0.926	0.773	6.186	0.742	0.560	4.493
Interpolación de Stineman	1.198	1.072	8.229	0.945	0.782	6.242	0.759	0.564	4.509
Media móvil simple	1.246	1.084	8.281	0.995	0.820	6.552	0.805	0.601	4.811
Media móvil lineal ponderada	1.233	1.078	8.244	0.981	0.809	6.456	0.792	0.592	4.738
Media móvil ponderada exponencial	1.231	1.085	8.304	0.977	0.806	6.429	0.787	0.584	4.664
Última observación trasladada hacia adelante	**1.111**	**0.965**	**7.379**	0.905	0.745	5.967	0.743	0.557	4.464
Siguiente observación trasladada hacia atrás	1.277	1.158	8.908	0.993	0.827	6.603	0.785	0.593	4.745
Descomposición estacional	1.152	1.017	7.821	0.912	0.751	5.997	0.719	0.528	4.228
División estacional	1.124	0.975	7.501	**0.892**	**0.734**	**5.881**	**0.704**	**0.508**	**4.068**
Suavizado de Kalman en un modelo estructural	1.147	0.995	7.647	0.910	0.744	5.947	0.717	0.518	4.146
Representación del espacio en estados de ARIMA y suavizado de Kalman	1.142	0.992	7.620	0.907	0.739	5.910	0.716	0.519	4.152

Tabla 28: Desempeño predictivo de Prophet como modelo de referencia sin imputación previa. Escenario MNAR con 10 % de datos faltantes.

	h=3			h=6			h=12		
Modelo	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**
Prophet	0.958	0.726	5.597	0.813	0.671	5.608	0.643	0.525	4.486

En el escenario MNAR con un 10 % de datos faltantes, el suavizado de Kalman en un modelo estructural presentó el menor error de imputación, con un RMSE de 0,774. A continuación, se ubicaron la representación en el espacio de estados de ARIMA con suavizado de Kalman (0,787) y la descomposición estacional (0,788), obteniendo resultados muy similares. Los métodos basados en valores constantes, como el reemplazo por un valor definido o por la moda, mostraron errores considerablemente superiores. De este modo, los métodos que aprovechan la estructura temporal volvieron a destacarse en la reconstrucción de las observaciones faltantes.

Sin embargo, el ranking cambia al considerar los pronósticos. Con ARIMA, el método que utiliza la división estacional obtuvo el menor RMSE para $h = 3$, con un valor de 0,935. Tanto para $h = 6$ como para $h = 12$, la descomposición estacional presentó el menor error (0,796 y 0,659 respectivamente). Por su parte, con ETS, LOCF presentó el menor error para $h = 3$, con un valor de 1,111. Para $h = 6$ y $h = 12$, el mejor desempeño correspondió a la división estacional, con valores de RMSE iguales a 0,892 y 0,704 respectivamente.

La comparación evidencia que el método con mejor precisión de imputación no es necesariamente el más conveniente para el pronóstico posterior. En este caso, el suavizado de Kalman en un modelo estructural fue la mejor alternativa para reconstruir los datos, pero los métodos de división estacional y descomposición estacional obtuvieron los mejores resultados en varios de los escenarios predictivos. Asimismo, el método seleccionado varió según el horizonte y el modelo utilizado.

Prophet presentó RMSE de 0,958, 0,813 y 0,643 para $h = 3$, $h = 6$ y $h = 12$, respectivamente. Para los horizontez de tres y seis meses, su error fue superior a los mejores resultados de ARIMA (0,935 y 0,796), pero inferior a ETS (1,111 y 0,892). En cambio, para el horizonte de doce meses, Prophet presentó errores inferiores a los mejores resultados de ARIMA (0,659) y de con ETS (0,704). Así, su desempeño fue especialmente competitivo frente a ETS, aunque no superó sistemáticamente a ARIMA.

Tabla 29: Desempeño de los métodos de imputación según RMSE, MAE y MAPE. Escenario MNAR con 25 % de datos faltantes.

Método	**RMSE**	**MAE**	**MAPE**
Valor aleatorio	1.917	1.565	13.223
Valor definido	11.698	11.650	100.000
Valor medio	1.568	1.311	10.754
Valor mediano	1.650	1.386	11.363
Valor modal	3.382	3.213	26.964
Interpolación lineal	1.235	0.994	8.220
Interpolación spline	1.256	0.931	7.784
Interpolación de Stineman	1.236	0.990	8.189
Media móvil simple	1.427	1.228	10.201
Media móvil lineal ponderada	1.377	1.174	9.730
Media móvil ponderada exponencial	1.333	1.124	9.305
Última observación trasladada hacia adelante	1.329	1.109	9.287
Siguiente observación trasladada hacia atrás	1.453	1.176	9.788
Descomposición estacional	0.885	0.668	5.505
División estacional	0.824	0.608	5.029
Suavizado de Kalman en un modelo estructural	**0.732**	**0.533**	**4.429**
Representación del espacio en estados de ARIMA y suavizado de Kalman	0.741	0.539	4.477

Tabla 30: Desempeño predictivo del modelo ARIMA según método de imputación y horizonte de pronóstico. Escenario MNAR con 25 % de datos faltantes.

	h=3			h=6			h=12		
Método	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**
Valor aleatorio	1.836	1.639	12.527	1.528	1.305	10.553	1.358	1.113	9.044
Valor definido	5.773	5.686	44.463	4.974	4.744	38.961	4.716	4.506	37.605
Valor medio	1.905	1.703	13.021	1.535	1.283	10.270	1.352	1.070	8.591
Valor mediano	1.968	1.762	13.480	1.584	1.326	10.605	1.398	1.102	8.838
Valor modal	2.835	2.709	20.962	2.305	1.974	15.633	2.108	1.767	14.194
Interpolación lineal	1.494	1.359	10.420	1.217	1.020	8.168	1.056	0.837	6.743
Interpolación spline	1.414	1.314	10.135	1.165	0.996	8.023	1.013	0.818	6.636
Interpolación de Stineman	1.486	1.357	10.424	1.206	1.013	8.114	1.044	0.828	6.671
Media móvil simple	1.663	1.427	10.835	1.394	1.172	9.488	1.240	1.016	8.283
Media móvil lineal ponderada	1.620	1.403	10.674	1.364	1.152	9.333	1.217	0.999	8.150
Media móvil ponderada exponencial	1.602	1.415	10.801	1.343	1.141	9.235	1.195	0.981	7.987
Última observación trasladada hacia adelante	1.488	1.292	9.833	1.279	1.080	8.744	1.148	0.931	7.582
Siguiente observación trasladada hacia atrás	1.684	1.547	11.888	1.393	1.200	9.721	1.233	1.015	8.259
Descomposición estacional	1.327	1.193	9.149	1.048	0.867	6.903	0.865	0.667	5.357
División estacional	1.234	1.055	8.086	1.027	0.827	6.593	0.842	0.621	4.992
Suavizado de Kalman en un modelo estructural	**1.179**	**0.998**	**7.664**	**0.974**	**0.776**	**6.181**	**0.804**	**0.586**	**4.696**
Representación del espacio en estados de ARIMA y suavizado de Kalman	1.189	1.032	7.919	1.010	0.815	6.489	0.840	0.630	5.068

Tabla 31: Desempeño predictivo del modelo ETS según método de imputación y horizonte de pronóstico. Escenario MNAR con 25 % de datos faltantes.

	h=3			h=6			h=12		
Método	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**
Valor aleatorio	1.733	1.592	12.231	1.373	1.117	8.799	1.167	0.899	7.145
Valor definido	5.943	5.817	45.386	5.162	4.898	40.142	4.993	4.731	39.394
Valor medio	1.779	1.639	12.590	1.407	1.143	8.995	1.197	0.914	7.238
Valor mediano	1.828	1.688	12.974	1.445	1.175	9.237	1.234	0.948	7.512
Valor modal	2.771	2.649	20.491	2.262	1.950	15.471	2.062	1.736	13.960
Interpolación lineal	1.461	1.334	10.242	1.149	0.955	7.609	0.951	0.724	5.776
Interpolación spline	1.407	1.313	10.121	1.094	0.920	7.349	0.890	0.690	5.547
Interpolación de Stineman	1.452	1.331	10.224	1.140	0.949	7.565	0.943	0.721	5.763
Media móvil simple	1.568	1.396	10.668	1.252	1.026	8.152	1.057	0.803	6.397
Media móvil lineal ponderada	1.553	1.394	10.663	1.238	1.018	8.091	1.044	0.792	6.309
Media móvil ponderada exponencial	1.532	1.383	10.595	1.217	1.002	7.962	1.023	0.775	6.173
Última observación trasladada hacia adelante	1.352	1.198	9.150	1.106	0.915	7.303	0.947	0.722	5.775
Siguiente observación trasladada hacia atrás	1.630	1.517	11.683	1.255	1.042	8.274	1.029	0.797	6.363
Descomposición estacional	1.362	1.243	9.563	1.066	0.875	6.949	0.860	0.642	5.115
División estacional	1.263	1.118	8.604	1.010	0.824	6.567	0.809	0.582	4.640
Suavizado de Kalman en un modelo estructural	**1.256**	**1.108**	**8.533**	**1.000**	**0.814**	**6.486**	**0.799**	**0.579**	**4.612**
Representación del espacio en estados de ARIMA y suavizado de Kalman	1.267	1.124	8.663	1.009	0.818	6.512	0.800	0.580	4.628

Tabla 32: Desempeño predictivo de Prophet como modelo de referencia sin imputación previa. Escenario MNAR con 25 % de datos faltantes.

	h=3			h=6			h=12		
Modelo	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**
Prophet	1.164	0.938	7.194	0.928	0.743	6.029	0.723	0.544	4.465

Al aumentar la proporción de faltantes MNAR al 25 %, el suavizado de Kalman en un modelo

estructural volvió a presentar el menor error de imputación, con un RMSE de 0,732. Le siguieron la representación en el espacio de estados de ARIMA con suavizado de Kalman (0,741) y la división estacional (0,824). En contraste, los métodos simples conservaron errores elevados, especialmente el reemplazo por un valor definido y la moda. Estos resultados indican que los métodos basados en la estructura temporal mantuvieron una ventaja en la reconstrucción de los datos bajo este mecanismo de ausencia.h

Al considerar el desempeño predictivo con ARIMA, el suavizado de Kalman en un modelo estructural obtuvo el menor RMSE tanto para los tres casos, con un RMSE de 1,179 para $h = 3$, de 0,974 para $h = 6$ y para $h = 12$ el valor resultó igual a 0,804. En los tres distintos horizontes, el segundo metodo con menor valor de RMSE fue la representación del espacio en estados de ARIMA y suavizado de Kalman, con valores iguales a 1,189, 1,010 y 0,840 respectivamente.

Con respecto al modelo ETS, el suavizado de Kalman en un modelo estructural volvió a presentar los mejores resultados para los tres horizontes analizados, con un valor de RMSE igual a 1,256 para $h = 3$, de 1 para $h = 6$ y de 0,799 para $h = 12$. Los métodos de división estacional y de representación del espacio en estados de ARIMA y suavizado de Kalman le siguen en el orden de mejor desempeño predictivo, obteniendo resultados similares entre sí.

De esta manera, a diferencia de los escenarios anteriores, se observa una correspondencia unívoca entre la calidad de la imputación y la precisión del pronóstico. El método de suavizado de Kalman en un modelo estructural fue el mejor método tanto de imputación, como para los tres horizontes.

En cuanto a Prophet, se obtuvieron RMSE de 1,164, 0,928 y 0,723 para $h = 3$, $h = 6$ y $h = 12$, respectivamente. Su error fue inferior a los mejores resultados obtenidos tanto con ARIMA como con ETS. Por lo tanto, este modelo de referencia sin imputación previa mantuvo un desempeño competitivo, en particular frente a ambos modelos de pronóstico considerados.

Tabla 33: Desempeño de los métodos de imputación según RMSE, MAE y MAPE. Escenario MNAR con 40 % de datos faltantes.

Método	**RMSE**	**MAE**	**MAPE**
Valor aleatorio	1.852	1.516	12.960
Valor definido	11.517	11.472	100.000
Valor medio	1.538	1.267	10.524
Valor mediano	1.584	1.311	10.895
Valor modal	3.197	3.030	25.817
Interpolación lineal	1.308	1.055	8.824
Interpolación spline	1.427	1.085	9.178
Interpolación de Stineman	1.311	1.055	8.831
Media móvil simple	1.395	1.176	9.877
Media móvil lineal ponderada	1.368	1.143	9.580
Media móvil ponderada exponencial	1.349	1.117	9.354
Última observación trasladada hacia adelante	1.370	1.138	9.622
Siguiente observación trasladada hacia atrás	1.464	1.193	10.054
Descomposición estacional	1.060	0.822	6.845
División estacional	0.854	0.636	5.339
Suavizado de Kalman en un modelo estructural	**0.726**	**0.544**	**4.590**
Representación del espacio en estados de ARIMA y suavizado de Kalman	0.740	0.546	4.604

Tabla 34: Desempeño predictivo del modelo ARIMA según método de imputación y horizonte de pronóstico. Escenario MNAR con 40 % de datos faltantes.

	h=3			h=6			h=12		
Método	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**
Valor aleatorio	2.200	2.031	15.608	1.783	1.511	12.065	1.591	1.270	10.163
Valor definido	8.186	8.108	63.545	7.234	7.025	58.126	6.933	6.752	56.795
Valor medio	2.229	2.055	15.787	1.785	1.508	11.993	1.577	1.231	9.794
Valor mediano	2.270	2.099	16.136	1.817	1.535	12.203	1.609	1.258	10.000
Valor modal	3.271	3.166	24.565	2.702	2.372	18.890	2.503	2.202	17.874
Interpolación lineal	1.670	1.519	11.646	1.403	1.213	9.819	1.257	1.043	8.493
Interpolación spline	1.671	1.574	12.165	1.450	1.265	10.250	1.325	1.088	8.840
Interpolación de Stineman	1.660	1.517	11.641	1.397	1.211	9.815	1.249	1.042	8.494
Media móvil simple	1.858	1.652	12.612	1.530	1.294	10.413	1.355	1.104	8.934
Media móvil lineal ponderada	1.823	1.638	12.528	1.506	1.283	10.325	1.339	1.093	8.837
Media móvil ponderada exponencial	1.795	1.632	12.504	1.494	1.285	10.358	1.334	1.092	8.835
Última observación trasladada hacia adelante	1.680	1.503	11.491	1.439	1.236	9.971	1.306	1.059	8.562
Siguiente observación trasladada hacia atrás	1.833	1.688	12.972	1.514	1.310	10.579	1.359	1.121	9.083
Descomposición estacional	1.609	1.472	11.299	1.275	1.058	8.404	1.095	0.853	6.815
División estacional	1.557	1.381	10.628	1.269	1.024	8.130	1.039	0.780	6.250
Suavizado de Kalman en un modelo estructural	**1.359**	**1.172**	**9.017**	**1.099**	**0.871**	**6.898**	**0.921**	**0.683**	**5.462**
Representación del espacio en estados de ARIMA y suavizado de Kalman	1.395	1.227	9.449	1.146	0.920	7.317	0.967	0.734	5.915

Tabla 35: Desempeño predictivo del modelo ETS según método de imputación y horizonte de pronóstico. Escenario MNAR con 40 % de datos faltantes.

	h=3			h=6			h=12		
Método	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**
Valor aleatorio	2.139	1.988	15.304	1.713	1.419	11.201	1.505	1.189	9.466
Valor definido	8.642	8.490	66.350	7.622	7.296	60.059	7.397	7.058	58.961
Valor medio	2.146	2.009	15.469	1.709	1.403	11.014	1.497	1.179	9.353
Valor mediano	2.198	2.060	15.869	1.749	1.437	11.274	1.537	1.217	9.671
Valor modal	3.280	3.177	24.654	2.715	2.394	19.080	2.522	2.226	18.076
Interpolación lineal	1.535	1.387	10.616	1.226	1.041	8.372	1.037	0.838	6.788
Interpolación spline	1.515	1.406	10.815	1.197	1.024	8.244	0.996	0.802	6.509
Interpolación de Stineman	1.543	1.404	10.757	1.226	1.041	8.368	1.031	0.836	6.782
Media móvil simple	1.742	1.562	11.941	1.396	1.148	9.113	1.210	0.932	7.424
Media móvil lineal ponderada	1.706	1.537	11.756	1.366	1.129	8.981	1.180	0.912	7.276
Media móvil ponderada exponencial	1.644	1.481	11.330	1.317	1.099	8.775	1.135	0.886	7.092
Última observación trasladada hacia adelante	1.535	1.351	10.300	1.266	1.051	8.394	1.107	0.858	6.875
Siguiente observación trasladada hacia atrás	1.729	1.602	12.318	1.348	1.149	9.210	1.133	0.908	7.310
Descomposición estacional	1.535	1.406	10.797	1.206	1.004	7.993	1.010	0.777	6.203
División estacional	1.581	1.402	10.803	1.286	1.030	8.169	1.056	0.783	6.257
Suavizado de Kalman en un modelo estructural	**1.379**	**1.218**	**9.380**	**1.104**	**0.885**	**7.010**	**0.913**	**0.670**	**5.331**
Representación del espacio en estados de ARIMA y suavizado de Kalman	1.404	1.246	9.607	1.118	0.894	7.091	0.921	0.679	5.431

Tabla 36: Desempeño predictivo de Prophet como modelo de referencia sin imputación previa. Escenario MNAR con 40 % de datos faltantes.

	h=3			h=6			h=12		
Modelo	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**	**RMSE**	**MAE**	**MAPE**
Prophet	1.367	1.165	8.956	1.069	0.842	6.693	0.841	0.605	4.843

En el escenario MNAR con un 40 % de datos faltantes, el suavizado de Kalman en un modelo

estructural obtuvo el menor RMSE de imputación (0,726), seguido por la representación en el espacio de estados de ARIMA con suavizado de Kalman (0,740) y por la división estacional (0,854). Los enfoques simples también mostraron errores importantes, especialmente el reemplazo por un valor definido y la moda. En conjunto, los métodos temporales mantuvieron un mejor desempeño relativo para reconstruir las observaciones ausentes.

Los resultados de ARIMA muestran que el método más conveniente no cambia según el horizonte, siendo el suavizado de Kalman en un modelo estructural el que mejor resultados obtuvo. Para $h = 3$, el RMSE resultó igual a 1,359; para $h = 6$, igual a 1,099; y para $h = 12$, presentó un valor de 0,921. De igual manera, en el caso de ETS, el suavizado de Kalman en un modelo estructural obtuvo los menores RMSE para $h = 3$, $h = 6$ y $h = 12$, con valores de 1,379, 1,104 y 0,913, respectivamente. Para ambos modelos de pronóstico y para todos los horizontes planteados, el segundo método de imputación con menores valores de RMSE fue la representación del espacio en estados de ARIMA y suavizado de Kalman.

Estos resultados muestran que, al igual que en el caso de un 25 % de datos faltantes, los métodos que mejor reconstruyen los datos son también los que producen los pronósticos más precisos.

Finalmente, Prophet obtuvo RMSE de 1,367, 1,069 y 0,841 para $h = 3$, $h = 6$ y $h = 12$, respectivamente. Para los dos primeros horizontes, sus errores fueron ligeramente superiores a los mejores resultados de ARIMA (1,359 y 1,099), mientras que para $h = 12$ Prophet obtuvo un RMSE menor al mejor resultado de ARIMA (0,921). En comparación con ETS, Prophet presentó menores errores en los tres horizontes. En consecuencia, incluso con un 40 % de datos faltantes, ajustar un modelo directamente sobre la serie incompleta puede constituir una alternativa competitiva frente a la imputación previa, aunque no necesariamente supera a los mejores resultados de ARIMA.

4.3. Comparación entre mecanismos MCAR, MAR y MNAR

Para facilitar la comparación entre la calidad de la imputación y el desempeño predictivo posterior, se sintetizan los métodos que obtuvieron el menor RMSE promedio en cada escenario. Las Tabla 37 y Tabla 38 presentan los resultados de los modelos ARIMA y ETS, respectivamente, para horizontes de tres, seis y doce meses.

Tabla 37: Métodos con menor RMSE promedio de imputación y pronóstico con ARIMA.

		ARIMA		
Escenario	**Imputación**	**h=3**	**h=6**	**h=12**
MCAR, 10 %	Descomp. est. (0,497)	División est. (0,833)	División est. (0,730)	Descomp. est. (0,601)
MCAR, 25 %	Kalman estruct. (0,542)	División est. (0,798)	Kalman estruct. (0,756)	Kalman estruct. (0,649)
MCAR, 40 %	Kalman estruct. (0,568)	División est. (0,871)	Kalman estruct. (0,851)	Descomp. est. (0,738)
MCAR en bloques, 10 %	Kalman estruct. (0,519)	División est. (0,821)	División est. (0,722)	División est. (0,607)
MCAR en bloques, 25 %	Kalman estruct. (0,567)	División est. (0,758)	División est. (0,753)	División est. (0,647)
MCAR en bloques, 40 %	Kalman estruct. (0,567)	División est. (0,881)	Kalman estruct. (0,852)	Kalman estruct. (0,739)
MNAR, 10 %	Descomp. est. (0,576)	LOCF (0,855)	LOCF / Descomp. est. (0,727)	Descomp. est. (0,592)
MNAR, 25 %	Descomp. est. (0,707)	LOCF (0,901)	Descomp. est. (0,767)	Descomp. est. (0,623)
MNAR, 40 %	Descomp. est. (0,771)	LOCF (0,916)	Descomp. est. (0,778)	Descomp. est. (0,643)

Tabla 38: Métodos con menor RMSE promedio de imputación y pronóstico con ETS.

		ETS		
Escenario	**Imputación**	**h=3**	**h=6**	**h=12**
MCAR, 10 %	Descomp. est. (0,497)	LOCF (0,996)	LOCF (0,833)	División est. (0,659)
MCAR, 25 %	Kalman estruct. (0,542)	LOCF (0,970)	División est. (0,844)	División est. (0,690)
MCAR, 40 %	Kalman estruct. (0,568)	División est. (0,938)	Kalman estruct. (0,883)	Kalman estruct. (0,743)
MCAR en bloques, 10 %	Kalman estruct. (0,519)	División est. / Kalman-ARIMA (1,080)	Kalman-ARIMA (0,856)	Kalman-ARIMA (0,670)
MCAR en bloques, 25 %	Kalman estruct. (0,567)	División est. (1,013)	División est. (0,825)	División est. (0,664)
MCAR en bloques, 40 %	Kalman estruct. (0,567)	División est. (0,967)	División est. (0,888)	Kalman estruct. (0,761)
MNAR, 10 %	Descomp. est. (0,576)	LOCF (1,055)	LOCF (0,847)	Kalman estruct. (0,668)
MNAR, 25 %	Descomp. est. (0,707)	LOCF (1,060)	LOCF (0,862)	LOCF / Descomp. est. (0,700)
MNAR, 40 %	Descomp. est. (0,771)	LOCF (1,075)	LOCF (0,883)	División est. (0,707)

La comparación de los resultados muestra que no existe una correspondencia sistemática entre el método con menor error de imputación y el que alcanza el mejor desempeño predictivo. En los escenarios MCAR, el suavizado de Kalman en un modelo estructural se destaca en términos de imputación para los porcentajes de pérdida de información más elevados, pero no domina de manera uniforme los pronósticos posteriores. En varios casos, la división estacional presenta menores errores con ARIMA o ETS, mientras que LOCF resulta competitivo para determinados horizontes. Por su parte, bajo el mecanismo MNAR, la descomposición estacional presenta los menores errores de imputación, aunque LOCF obtiene mejores resultados predictivos en varios escenarios de corto plazo. Estos patrones indican que la selección de un método de imputación debería considerar no solo su capacidad para reconstruir los valores faltantes, sino también el modelo de pronóstico y el horizonte de interés.

5. Conclusiones

Los resultados obtenidos permiten analizar el desempeño de los distintos métodos de imputación tanto desde la perspectiva de la reconstrucción de los valores faltantes como desde su impacto sobre el desempeño de los modelos de pronóstico.

En términos generales, los métodos basados en la estructura temporal de la serie, como la descomposición estacional y los enfoques basados en suavizado de Kalman, presentan los menores errores de imputación en la mayoría de los escenarios analizados. Esto sugiere que incorporar explícitamente la dinámica temporal de la serie mejora la capacidad de reconstrucción de los datos faltantes.

Sin embargo, al analizar el desempeño de pronóstico posterior, las diferencias entre métodos tienden a reducirse. En algunos casos, métodos que presentan errores de imputación relativamente bajos no necesariamente producen los mejores resultados de forecasting. Este hallazgo constituye uno de los principales aportes del trabajo, ya que evidencia que minimizar el error de imputación no garantiza maximizar la capacidad predictiva de los modelos ajustados sobre las series imputadas.

Asimismo, se observa que las diferencias entre métodos tienden a incrementarse a medida que aumenta el horizonte de pronóstico. Mientras que para horizontes cortos varios métodos presentan desempeños similares, en horizontes más largos los enfoques que preservan mejor la estructura temporal de la serie muestran ventajas más claras.

Al comparar los modelos de pronóstico utilizados, se observa que tanto ARIMA como ETS presentan comportamientos consistentes respecto al ranking relativo de los métodos de imputación, aunque las magnitudes de error difieren entre ambos enfoques. Esto sugiere que el impacto de la imputación depende no solo de la calidad de reconstrucción de los datos, sino también de las características del modelo predictivo utilizado.

6. Bibliografía

Arrioja, N. *Métricas en regresión*. https://medium.com/@nicolasarrioja/métricas-en-regresión-5e5d4259430b

Benavides, I. F., Santacruz, M., Romero-Leiton, J. P., Barreto, C., & Selvaraj, J. J. (2023). Assessing methods for multiple imputation of systematic missing data in marine fisheries time series with a new validation algorithm. *Aquaculture and Fisheries*, *8*(5), 587-599. https://doi.org/https://doi.org/10.1016/j.aaf.2021.12.013

Hyndman, R. J., & Athanasopoulos, G. (2018). *Forecasting: Principles and Practice*. OTexts.

Mandeville, P. B. (2010). Tema 24: Observaciones perdidas. *Ciencia UANL*, *13*(3), 313-324.

Moritz, S., Sardá, A., Bartz-Beielstein, T., Zaefferer, M., & Stork, J. (2015). Comparison of different methods for univariate time series imputation in R. *arXiv*.

Niako, N., Melgarejo, J. D., Maestre, G. E., & Vatcheva, K. P. (2024). Effects of missing data imputation methods on univariate blood pressure time series data analysis and forecasting with ARIMA and LSTM. *BMC Medical Research Methodology*, *24*(1), 320. https://doi.org/10.1186/s12874-024-02448-3

Peña, D. (2010). *Análisis de Series Temporales*. Alianza Editorial.

Q2B Studio. *Manejo de datos faltantes en R: guía de imputación con MICE*. https://www.q2bstudio.com/nuestro-blog/25440/manejo-de-datos-faltantes-en-r-guia-de-imputacion-con-mice

Román Radío, G. (2017). *Los valores perdidos en el muestreo de poblaciones finitas: Técnicas de imputación* [Trabajo Fin de Máster, Universidad de Vigo]. http://eio.usc.es/pub/mte/descargas/Proyectos_FinMaster/Proyecto_1468.pdf

Tamplin, L. (2025). *Evaluación de métodos de imputación de datos faltantes en series temporales univariadas* [Tesis de grado]. Universidad Nacional de Rosario.

Taylor, S. J., & Letham, B. (2023). *prophet: Automatic Forecasting Procedure*. https://cran.r-project.org/web/packages/prophet/

Taylor, S., & Letham, B. (2017). *Forecasting at scale*. https://doi.org/10.7287/peerj.preprints.3190v2

Wu, S.-F., Chang, C.-Y., & Lee, S.-J. (2015). Time series forecasting with missing values. *2015 1st International Conference on Industrial Networks and Intelligent Systems (INISCom)*.

Xian, X., Wang, L., Wu, X., & Tang, X. (2023). Comparison of SARIMA model, Holt-Winters model and ETS model in predicting the incidence of foodborne disease. *BMC Infectious Diseases*, *23*(1), 803.

7. Anexo