



UNR Universidad
Nacional de Rosario

UNIVERSIDAD NACIONAL DE ROSARIO
Facultad de Ciencias Económicas y Estadística

Imputación de Datos Faltantes en Series Temporales Univariadas: Evaluación Basada en Desempeño de Pronóstico

Tesina de grado

Carrera: Licenciatura en Estadística
Alumno: Sánchez Travella, Joaquín
Directora: Mag. Méndez, Fernanda

Año 2026

Agradecimientos

Resumen

Las series temporales univariadas constituyen una herramienta fundamental para el análisis y la predicción de fenómenos que evolucionan a lo largo del tiempo en múltiples áreas de aplicación. Sin embargo, en la práctica es frecuente la presencia de datos faltantes, lo que puede afectar tanto la calidad del análisis como el desempeño de los modelos predictivos. En este contexto, la imputación de valores faltantes surge como una estrategia clave para completar las series o estimar valores faltantes y permitir la aplicación de métodos de modelado y pronóstico.

El presente trabajo tiene como objetivo evaluar y comparar distintos métodos de imputación de datos faltantes en series temporales univariadas, incorporando como criterio principal el desempeño de pronóstico posterior, bajo el enfoque conocido como *forecast-after-imputation*. A diferencia de gran parte de la literatura existente, que se centra en la calidad de los datos imputados, este estudio analiza el impacto de las distintas técnicas de imputación sobre la capacidad predictiva de los modelos ajustados a partir de las series completas.

Para ello, se propone un esquema de simulación basado en series temporales completas a las que se les introducen valores faltantes de manera artificial, considerando distintos mecanismos de ausencia, patrones de observaciones faltantes y niveles de pérdida de información. Sobre estos datos incompletos se aplican diversos métodos de imputación, que incluyen tanto enfoques simples como técnicas más avanzadas adaptadas a la estructura temporal de los datos. Posteriormente, se ajustan modelos de series temporales y se evalúa su desempeño mediante métricas de error de pronóstico, tales como RMSE (*Root Mean Square Error*), MAE (*Mean Absolute Error*) y MAPE (*Mean Absolute Percentage Error*), considerando distintos horizontes de predicción y un enfoque de evaluación fuera de muestra.

Los resultados obtenidos permiten analizar cómo la elección del método de imputación influye en la precisión de los pronósticos, evidenciando que no existe una técnica universalmente superior en todos los escenarios considerados, sino que su desempeño depende de las características de la serie y del tipo de datos faltantes. En particular, se identifican escenarios en los que ciertos métodos resultan más adecuados cuando el objetivo principal es mejorar la capacidad predictiva.

En conclusión, este trabajo aporta una perspectiva integral para la evaluación de métodos de imputación en series temporales univariadas, integrando el proceso completo desde la imputación hasta el pronóstico. Asimismo, proporciona recomendaciones prácticas orientadas a la selección de técnicas en función del objetivo de predicción, contribuyendo al desarrollo de estrategias más robustas para el análisis y la predicción en presencia de datos faltantes.

Palabras clave: Series temporales univariadas, datos faltantes, imputación, pronóstico, desempeño.

Tabla de contenidos

1	Introducción	6
2	Objetivos	8
2.1	Objetivo general	8
2.2	Objetivos específicos	8
3	Metodología	9
3.1	Conceptos básicos de series de tiempo	9
3.1.1	Tendencia	10
3.1.2	Componente estacional	10
3.1.3	Componente ciclo	11
3.1.4	Componente aleatorio	11
3.2	Autocorrelación	12
3.2.1	Función de autocorrelación	12
3.2.2	Función de autocorrelación parcial	12
3.3	Datos faltantes en series temporales	13
3.3.1	Tipos de datos faltantes	13
3.4	Métodos de imputación	14
3.4.1	Valor aleatorio	15
3.4.2	Valor definido	16
3.4.3	Valor medio	16
3.4.4	Valor mediano	17
3.4.5	Valor modal	17
3.4.6	Interpolación lineal	17
3.4.7	Interpolación spline	18
3.4.8	Interpolación de Stineman	19
3.4.9	Media móvil simple	19
3.4.10	Media móvil lineal ponderada	20
3.4.11	Media móvil ponderada exponencial	21
3.4.12	Última observación trasladada hacia adelante	22
3.4.13	Siguiente observación trasladada hacia atrás	22
3.4.14	División estacional	23
3.4.15	Descomposición estacional	23
3.4.16	Suavizado de Kalman en un modelo estructural	24
3.4.17	Representación del espacio en estados de ARIMA y suavizado de Kalman	25
3.5	Técnicas de modelado	26
3.5.1	Procesos Autorregresivos (AR)	26
3.5.2	Procesos Promedio Móvil (MA)	27
3.5.3	Procesos Autorregresivos de Media Móvil (ARMA)	27
3.5.4	Procesos Autorregresivos Integrados de Media Móvil (ARIMA)	28
3.5.5	Procesos Estacionales, Autorregresivos Integrados de Media Móvil (SARIMA)	28
3.6	Modelos de pronóstico	29
3.6.1	Modelos ARIMA Y SARIMA	29
3.6.2	Modelo ETS	29
3.6.3	Modelo Prophet	30

3.7	Evaluación del desempeño	31
3.7.1	Evaluación del desempeño de los métodos de imputación	31
3.7.2	Evaluación del desempeño del pronóstico posterior	32
3.7.3	Métricas del error	32
4	Aplicación	33
	Caso de aplicación: Consumo de electricidad	34
4.1	Análisis descriptivo	35
4.2	Resultados	39
5	Conclusiones	45
6	Bibliografía	46
7	Anexo	47

1. Introducción

Las series temporales desempeñan un papel fundamental en el análisis y la predicción de fenómenos que evolucionan a lo largo del tiempo, siendo ampliamente utilizadas en diversas áreas como la economía, la meteorología, la salud y los negocios. A través de ellas es posible identificar patrones, tendencias y comportamientos recurrentes que permiten anticipar escenarios futuros y apoyar la toma de decisiones. Sin embargo, en la práctica, es frecuente que los datos observados presenten valores faltantes debido a múltiples causas, tales como errores en dispositivos de medición, fallas en sensores, restricciones en la recolección de datos o eventos imprevistos.

La presencia de datos faltantes constituye un desafío relevante, ya que un tratamiento inadecuado de estos valores puede generar sesgos en las estimaciones, afectar la inferencia y disminuir la precisión de los modelos predictivos. En este contexto, la imputación de datos surge como una estrategia clave para el tratamiento de valores ausentes, permitiendo estimar valores plausibles y preservar, en la medida de lo posible, la estructura temporal de la serie. Este aspecto resulta particularmente relevante en el análisis de series temporales, donde muchos métodos de modelado y pronóstico requieren series completas para su correcta implementación.

Existen diversos métodos de imputación para series temporales univariadas, que van desde técnicas simples —como la imputación por media, interpolación o el método de último valor observado— hasta enfoques más complejos basados en la estructura temporal de la serie o en modelos estadísticos, como el suavizamiento de Kalman o los modelos ARIMA. No obstante, no existe un método de imputación que resulte óptimo en todos los contextos, ya que su desempeño depende de las características de la serie, del mecanismo de generación de los datos faltantes y de la estructura temporal subyacente.

En la mayoría de los estudios, la evaluación de los métodos de imputación se centra exclusivamente en la precisión de los valores reconstruidos, comparando los datos imputados con los valores reales mediante distintas métricas de error. Sin embargo, en muchos contextos aplicados, la imputación no constituye un objetivo en sí mismo, sino un paso previo para tareas posteriores, como el modelado y el pronóstico de series temporales. En consecuencia, resulta relevante analizar no solo qué tan bien un método de imputación logra aproximar los valores faltantes, sino también cómo afecta el desempeño de los modelos de pronóstico ajustados sobre las series imputadas.

Esta perspectiva permite evaluar si los métodos que presentan menor error de imputación son también aquellos que generan mejores predicciones, cuestión que no siempre ha sido abordada de manera sistemática en la literatura. En este sentido, se identifica un vacío en relación con la evaluación conjunta de la imputación y el desempeño predictivo, particularmente en el contexto de series temporales univariadas.

Como antecedente directo, este trabajo se apoya en la tesina de Tamplin (2025), en la cual se evaluaron distintos métodos de imputación mediante simulaciones de datos faltantes y métricas de precisión como RMSE, MAE y MAPE. La presente tesina propone extender dicho enfoque incorporando un criterio adicional de evaluación basado en el desempeño de pronóstico posterior (*forecast-after-imputation*), integrando así ambas dimensiones en un mismo marco metodológico.

En este marco, el objetivo del trabajo es analizar el desempeño de distintos métodos de imputación no solo en función de su capacidad de reconstrucción, sino también en función de su impacto sobre la calidad de los pronósticos generados a partir de las series imputadas. De este modo, se busca aportar

evidencia empírica que permita orientar la selección de métodos de imputación en situaciones donde el interés principal radica en la predicción.

La estructura del trabajo se organiza en siete capítulos, incluyendo la presente introducción. En el Capítulo 2 se presentan los objetivos de la tesina, mientras que en el Capítulo 3 se describe la metodología empleada. En el Capítulo 4 se desarrollan los experimentos de simulación, en los que se utilizan series temporales completas a las que se les introducen valores faltantes de manera controlada, con el objetivo de evaluar el efecto que distintos métodos de imputación tienen tanto sobre la reconstrucción de los datos como sobre el desempeño de los modelos de pronóstico. En el Capítulo 5 se presentan las conclusiones del trabajo y se proponen posibles líneas de investigación futura. Finalmente, en los Capítulos 6 y 7 se incluyen las referencias bibliográficas y los anexos, respectivamente.

2. Objetivos

2.1. Objetivo general

El objetivo principal de la tesina es analizar y comparar distintos métodos de imputación de datos faltantes en series temporales univariadas, considerando como criterio principal de evaluación el impacto de dichas técnicas sobre el desempeño de los modelos de pronóstico.

2.2. Objetivos específicos

- Revisar la literatura sobre métodos de imputación de datos faltantes en series temporales univariadas y su relación con tareas de pronóstico.
- Seleccionar un conjunto representativo de métodos de imputación que incluya técnicas simples, métodos basados en la estructura temporal de la serie y enfoques basados en modelos.
- Diseñar un esquema de simulación que contemple distintos mecanismos de datos faltantes (MCAR, MAR temporal y MNAR), así como diferentes patrones de ausencia (dispersos y en bloques) y niveles de pérdida de información.
- Construir un *pipeline* de procesamiento reproducible que integre de forma secuencial la generación de datos faltantes, la aplicación de técnicas de imputación, el ajuste de modelos de series temporales y la generación de predicciones.
- Comparar la eficacia de los métodos mediante el uso de métricas de error de imputación (RMSE, MAE y MAPE) en conjunto con métricas de desempeño de pronóstico para horizontes de tiempo de corto y mediano plazo ($h=1, 3, 6$ y 12).
- Validar el desempeño de los métodos mediante su aplicación a series temporales reales.
- Derivar recomendaciones prácticas fundamentadas en los resultados obtenidos, que permitan identificar qué técnicas de imputación resultan más adecuadas según la estructura de la serie y el objetivo específico de mejorar la predicción.

3. Metodología

3.1. Conceptos básicos de series de tiempo

Una serie temporal se define como una secuencia de observaciones ordenadas en el tiempo calendario, resultado de registrar los valores de una variable en intervalos generalmente regulares a lo largo del tiempo. Estos intervalos de tiempo definen la periodicidad (diaria, mensual, anual, etc.). Una característica fundamental de las series temporales es la dependencia entre sus observaciones, lo que implica que el orden en que estas ocurren resulta relevante para su análisis. En consecuencia, los métodos estadísticos basados en el supuesto de independencia entre observaciones no son directamente aplicables, por lo que se requieren enfoques específicos que tengan en cuenta la estructura temporal de los datos.

Formalmente, una serie temporal se define como un conjunto de variables aleatorias indexadas en el tiempo, $Y_1, \dots, Y_T$. En este sentido, una serie temporal observada se denota por $y_1, \dots, y_T$, donde el subíndice i indica el tiempo al que pertenece la observación y_i . El primer valor observado y_1 puede interpretarse como una realización de la variable aleatoria Y_1 . Del mismo modo, y_2 es una realización de Y_2 y así sucesivamente. Las variables aleatorias $Y_1, Y_2, \dots, Y_T$ no necesariamente son idénticamente distribuidas.

Los fenómenos observados mediante series temporales pueden clasificarse en dos clases. Los primeros son los que toman valores estables en el tiempo alrededor de un nivel constante, sin mostrar una tendencia a crecer o a decrecer a largo plazo. Estos procesos se denominan estacionarios. Por otro lado, existen los procesos no estacionarios, que son aquellos que pueden mostrar tendencia, estacionalidad y otros efectos evolutivos en el tiempo. En las series estacionarias, la media y varianza se mantienen constantes en el tiempo y la covarianza entre observaciones depende únicamente del rezago y no del tiempo en sí, mientras que en las no estacionarias, estas características cambian a través del tiempo.

Para un proceso $\{Y_t : t = 0, \pm 1, \pm 2, \dots\}$ se define:

- La función media del proceso:

$$E(Y_t) = \mu_t \quad (1)$$

- La función varianza del proceso:

$$\sigma_t^2 = E(Y_t - \mu_t)^2 \quad (2)$$

- La función covarianza entre Y_{t_1} y Y_{t_2} :

$$\gamma(t_1, t_2) = E(Y_{t_1} - \mu_{t_1})(Y_{t_2} - \mu_{t_2}) \quad (3)$$

En un proceso estacionario resulta:

$$\mu_t = \mu, \quad \forall t \quad (4)$$

$$\sigma_t^2 = \sigma^2, \quad \forall t \quad (5)$$

$$\gamma(t_1, t_2) = \gamma(t_1 + k, t_2 + k), \quad \forall t_1, t_2 \text{ y } k \quad (6)$$

En este contexto, resulta útil descomponer una serie temporal en sus principales componentes no observables, ya que estos permiten interpretar y modelar su comportamiento a lo largo del tiempo. En particular, la presencia de tendencia, estacionalidad, ciclos y un componente aleatorio está estrechamente relacionada con la noción de no estacionariedad, dado que estos elementos introducen cambios sistemáticos en la media o en la estructura de dependencia de la serie. A continuación, se presentan definiciones más precisas de estos componentes, fundamentales para el análisis y modelado de series temporales.

3.1.1. Tendencia

La tendencia representa el comportamiento a largo plazo de una serie temporal, reflejando la evolución sostenida de la variable a lo largo del tiempo. Este componente describe la dirección general en la que se desplazan los datos, pudiendo manifestarse como un crecimiento, decrecimiento o estabilidad en el nivel medio de la serie. La tendencia no necesariamente es lineal, ya que puede presentar formas más complejas, como curvaturas o cambios en la pendiente, asociados a transformaciones estructurales del fenómeno analizado.

La presencia de tendencia implica que la media de la serie no permanece constante en el tiempo, lo que constituye una fuente de no estacionariedad. La identificación y modelado de la tendencia resultan fundamentales, ya que permiten separar el comportamiento estructural de largo plazo de otras fluctuaciones de menor escala. En muchos contextos aplicados, la tendencia se asocia a factores como crecimiento económico, cambios tecnológicos o evolución demográfica, entre otros.

3.1.2. Componente estacional

La estacionalidad se refiere a la existencia de patrones que se repiten de manera sistemática en intervalos de tiempo fijos y conocidos. Estos patrones suelen estar asociados a factores externos recurrentes, como las estaciones del año, los meses, los días de la semana o incluso las horas dentro del día. A diferencia de otros componentes, la estacionalidad presenta una periodicidad constante, lo que permite su identificación mediante herramientas descriptivas y su modelado a través de métodos específicos.

Se dice que una serie es estacional cuando su valor esperado no es constante, pero varía con una pauta cíclica. En concreto, si:

$$E(y_t) = E(y_{t+s}) \quad (7)$$

se dice que la serie tiene una estacionalidad de periodo s . El periodo estacional, s , define el número de observaciones que forma el ciclo estacional. Por ejemplo, $s = 12$ para series mensuales, $s = 4$ para series trimestrales, etc. Se supone que el valor de s es fijo en la serie. Es importante notar que puede existir más de un tipo de estacionalidad en una serie.

Desde una perspectiva analítica, la estacionalidad introduce variaciones sistemáticas en la serie que dependen del momento dentro del ciclo temporal considerado. Esto implica que observaciones correspondientes a un mismo período dentro de distintos ciclos (por ejemplo, el mismo mes en diferentes años) tienden a presentar comportamientos similares. La adecuada identificación de este componente es esencial, ya que su omisión puede distorsionar el análisis de la tendencia y afectar la precisión de los modelos de pronóstico.

3.1.3. Componente ciclo

Los ciclos corresponden a fluctuaciones de la serie temporal que se desarrollan en horizontes de mediano y largo plazo, pero que no presentan una periodicidad fija ni conocida. A diferencia de la estacionalidad, cuya duración es constante, los ciclos pueden variar en su extensión, intensidad y forma, lo que dificulta su identificación y modelado. Este componente refleja cambios en la dinámica subyacente del fenómeno que no responden a patrones regulares, sino a procesos más complejos.

En muchos casos, los ciclos se asocian a fenómenos económicos, como expansiones y recesiones, aunque también pueden aparecer en otros contextos. Su duración suele ser mayor a la de los efectos estacionales y, en general, no existe un período predeterminado que permita anticipar su repetición. Desde el punto de vista del análisis de series temporales, los ciclos representan una fuente adicional de variabilidad que puede influir en la estructura de dependencia de la serie y en su comportamiento a largo plazo.

3.1.4. Componente aleatorio

El componente aleatorio, también denominado irregular o ruido, recoge la variabilidad de la serie temporal que no puede ser explicada por los componentes sistemáticos como la tendencia, la estacionalidad o los ciclos. Este componente representa fluctuaciones impredecibles originadas por factores no observados, errores de medición o variaciones inherentes al fenómeno bajo estudio.

En términos estadísticos, suele modelarse como un proceso estocástico con media cero y varianza constante, aunque en la práctica puede presentar estructuras más complejas, como heterocedasticidad o dependencia temporal. A diferencia de los componentes anteriores, el componente aleatorio no presenta una estructura sistemática identificable, lo que limita la capacidad de modelado determinístico. Sin embargo, su correcta caracterización es fundamental, ya que determina el nivel de incertidumbre asociado al análisis y establece un límite natural a la precisión de los pronósticos.

Las irregularidades pueden tener un impacto significativo en la precisión de los modelos de series temporales y en las previsiones, ya que pueden ocultar las tendencias subyacentes y los patrones de estacionalidad en los datos.

En conjunto, la identificación y análisis de estos componentes permiten comprender la estructura subyacente de una serie temporal, facilitando tanto su modelado como la formulación de pronósticos más precisos.

Una serie temporal, $Y_1, Y_2, \dots, Y_T$, puede descomponerse en sus componentes fundamentales mediante modelos de descomposición. En particular, el modelo aditivo se expresa como:

$$Y_t = T_t + E_t + C_t + A_t \quad (8)$$

donde: T_t representa la tendencia, E_t la componente estacional, C_t los ciclos y A_t la componente aleatoria.

Por otro lado, el modelo multiplicativo se define como:

$$Y_t = T_t \times E_t \times C_t \times A_t \quad (9)$$

el cual resulta más adecuado cuando la magnitud de las variaciones estacionales o cíclicas depende del nivel de la serie.

3.2. Autocorrelación

La autocorrelación es una medida fundamental en el análisis de series temporales que permite cuantificar el grado de dependencia existente entre observaciones de una misma serie en distintos momentos del tiempo. A diferencia de los datos independientes, en una serie temporal los valores suelen estar relacionados con sus propios valores pasados, lo que implica que la información contenida en una observación puede aportar conocimiento sobre observaciones futuras o pasadas. Esta dependencia temporal constituye una de las características distintivas de las series temporales y es clave para su modelado.

El estudio de la autocorrelación resulta esencial en la práctica, ya que proporciona información relevante sobre la estructura interna de la serie y orienta la selección de modelos adecuados para su análisis y pronóstico. En particular, muchas metodologías de modelado de series temporales se basan explícitamente en la forma en que las observaciones se correlacionan a lo largo del tiempo, lo que convierte a la autocorrelación en una herramienta central dentro del análisis estadístico de datos temporales.

3.2.1. Función de autocorrelación

La función de autocorrelación constituye una herramienta fundamental para el análisis de la dependencia temporal en una serie. Esta función describe cómo se correlacionan las observaciones de la serie con sus propios valores pasados en función del rezago considerado. En particular, permite analizar el grado de asociación lineal entre observaciones separadas por distintos intervalos de tiempo, proporcionando una visión global de la estructura de dependencia de la serie.

Para cada rezago k , la función de autocorrelación mide la intensidad de la relación lineal entre Y_t y Y_{t+k} , tomando valores comprendidos entre -1 y 1. Valores cercanos a 1 indican una fuerte correlación positiva, mientras que valores próximos a -1 reflejan una correlación negativa. Por su parte, valores cercanos a cero sugieren ausencia de dependencia lineal significativa para ese rezago. En el caso de series temporales estacionarias, la función de autocorrelación depende únicamente del rezago y no del tiempo, lo que simplifica su análisis e interpretación.

Formalmente, la autocorrelación para un rezago k se calcula utilizando la siguiente fórmula:

$$\rho_k = \frac{\sum_{t=k+1}^T (y_t - \bar{y})(y_{t-k} - \bar{y})}{\sum_{t=1}^T (y_t - \bar{y})^2} \quad (10)$$

3.2.2. Función de autocorrelación parcial

La función de autocorrelación parcial constituye una herramienta complementaria a la función de autocorrelación, permitiendo analizar la dependencia directa entre observaciones de una serie temporal. Mientras que la autocorrelación mide la relación total entre y_t y y_{t+h} , la autocorrelación parcial evalúa la relación entre estas dos observaciones una vez eliminada la influencia de los valores intermedios comprendidos entre ambos momentos.

En otras palabras, la autocorrelación parcial mide el grado de dependencia lineal “pura” entre dos observaciones separadas por un rezago h , controlando por los efectos de los rezagos menores. Esto

permite aislar la contribución específica de cada rezago en la estructura de dependencia de la serie, evitando la superposición de efectos indirectos presentes en la función de autocorrelación.

El análisis de la función de autocorrelación parcial resulta especialmente útil en la identificación de modelos de series temporales, en particular en la determinación del orden de los modelos autorregresivos. De este modo, junto con la función de autocorrelación, constituye una herramienta fundamental en el análisis exploratorio y en el proceso de modelado de series temporales.

3.3. Datos faltantes en series temporales

En el desarrollo teórico de numerosos modelos y técnicas estadísticas, a menudo no se consideran ciertas situaciones que surgen en la práctica, entre las cuales se destaca la presencia de datos faltantes, también denominados valores perdidos o incompletos. Esta problemática es especialmente frecuente en el análisis de series temporales, donde es habitual encontrar observaciones ausentes dentro de la secuencia de datos.

Desde un punto de vista metodológico, no todos los datos faltantes presentan las mismas características ni tienen el mismo impacto sobre el análisis. En particular, la forma en que se generan los valores ausentes, conocida como mecanismo de faltantes, resulta fundamental para determinar el enfoque más adecuado para su tratamiento. Ignorar este aspecto puede conducir a la aplicación de métodos inapropiados y, en consecuencia, a conclusiones erróneas.

En este sentido, la literatura estadística distingue tres mecanismos principales de generación de datos faltantes: faltantes completamente al azar (MCAR), faltantes al azar (MAR) y faltantes no al azar (MNAR). Cada uno de estos mecanismos implica distintos supuestos sobre la relación entre la ausencia de datos y la información observada o no observada, lo que influye directamente en la elección y el desempeño de los métodos de imputación.

3.3.1. Tipos de datos faltantes

Hay varios tipos de observaciones faltantes:

- Datos faltantes completamente al azar (Missing Completely at Random, MCAR). Los datos faltantes siguen un patrón aleatorio; la probabilidad de que un valor esté perdido es independiente tanto del valor de esta variable como del valor de otras variables del conjunto de datos. La ausencia de información no procede de ninguna variable presente en la matriz de datos, ya que la base de datos se interpreta como una matriz en donde los renglones son las unidades de observación y las columnas representan a las variables de interés. Hay que señalar que, en la práctica, la hipótesis de este supuesto no siempre es satisfactoria porque la falta de respuesta se asocia a características personales.
- Datos faltantes al azar (Missing at Random, MAR). La probabilidad de que una respuesta sea dato faltante es independiente de los valores de la variable pero es dependiente de los valores de otras variables del conjunto de datos. En suma, la ausencia de datos está asociada a variables presentes en la matriz de datos. Por ejemplo, este supuesto, es usual en las encuestas de hogares que estudian el nivel socioeconómico, donde la falta de respuesta en la variable ingreso en las familias está correlacionada con sus ingresos y por lo tanto no se cumple el supuesto. En cambio, cuando la omisión ocurre en la categoría ocupacional, la falta de información no

necesariamente está correlacionada con el nivel de ingresos de las personas y por lo tanto sí se cumple el supuesto.

- Datos no faltantes al azar (Missing not at random, MNAR). La probabilidad de que una respuesta a una variable sea dato faltante es dependiente de los valores de la variable. Por ejemplo, en el estudio de las variables peso y edad; los sujetos con mayores valores de peso tienen un porcentaje de datos faltantes más elevado en esta variable para aquellos individuos con la misma edad. Este tipo de dato faltante también se denomina no ignorable.

Para series temporales univariadas, el panorama de los mecanismos de datos faltantes es ligeramente diferente. A primera vista, solo hay una variable en los datos. Sin embargo, el tiempo (que se da implícitamente) debe tratarse como una variable al determinar el mecanismo de datos faltantes de un conjunto de datos. Otra diferencia radica en que los algoritmos de imputación de series temporales no necesitan basarse únicamente en covariables para la estimación de valores faltantes, sino que también pueden utilizar las características de las series temporales.

En este contexto, los mecanismos MCAR y MAR tienden a presentar comportamientos similares en la práctica, ya que ambos permiten que los valores faltantes sean estimados a partir de la estructura temporal observada. En el caso de datos faltantes completamente al azar (MCAR), la probabilidad de que una observación esté ausente es independiente tanto del instante temporal como del valor de la serie. Por su parte, en el caso MAR, la ausencia puede depender de información observable, incluyendo el tiempo o patrones de la serie.

Por otro lado, en el caso de datos faltantes que no faltan al azar (MNAR), la probabilidad de que falte una observación puede depender del momento en que se encuentra esa observación en la serie, así como del valor de la propia observación.

En la práctica, no es posible verificar con certeza cuál es el mecanismo de generación de los datos faltantes únicamente a partir de los datos observados. Por este motivo, la clasificación en MCAR, MAR y MNAR suele basarse en supuestos teóricos y conocimiento del contexto en el que se generaron los datos.

No obstante, esta distinción resulta fundamental, ya que los diferentes métodos de imputación se basan en supuestos implícitos sobre el mecanismo de faltantes. En consecuencia, la elección de la técnica más adecuada requiere considerar qué supuesto resulta más plausible en cada situación.

3.4. Métodos de imputación

La existencia de valores faltantes introduce diversas dificultades en el análisis, ya que puede afectar la estimación de parámetros, distorsionar la identificación de patrones y limitar la aplicación de ciertos métodos que requieren series completas. En consecuencia, su tratamiento constituye una etapa fundamental dentro del preprocesamiento de los datos. Entre las distintas estrategias disponibles, la imputación se presenta como una de las más utilizadas.

Se denomina imputación al proceso que utiliza la información procedente de la muestra para asignar un valor a aquellos registros con valor ausente, ya sea porque se carece de información o porque se detecta que algunos de los valores obtenidos no se corresponden con el comportamiento esperado. Existen diversos métodos de imputación que difieren tanto en la información que utilizan como en la forma en que generan los valores imputados. La elección del método más adecuado dependerá de las características de la serie, la estructura de los datos faltantes y el objetivo del análisis.

La imputación de datos faltantes es más sencilla cuando estos ocurren completamente al azar (MCAR). Esto se debe a que en el caso de MNAR, las observaciones faltantes pueden formar fragmentos lo suficientemente grandes como para ocultar los componentes estructurales de las series temporales. Sin embargo, si la serie temporal presenta una estructura temporal bien definida, los métodos de imputación que aprovechan características como la estacionalidad, los ciclos y la autocorrelación pueden tener una ventaja sobre otros métodos más simples.

Una observación muy importante es que la eficiencia de cada técnica depende del conjunto de datos. Esto significa que cada técnica funciona de manera diferente dependiendo de la estructura de cada serie temporal; en otras palabras, no existe un método único que se adapte a todos los tipos de datos. Esto debe tomarse seriamente en cuenta al intentar elegir un método apropiado para la imputación de múltiples datos en series temporales. Por lo tanto, es necesario analizar las características específicas de la serie temporal con datos faltantes y, a partir de ese análisis, seleccionar el procedimiento de imputación que mejor se adapte a dicha estructura.

A continuación, se describen los métodos de imputación que serán evaluados en cada situación.

3.4.1. Valor aleatorio

Para reemplazar cada valor faltante en la serie temporal, se selecciona aleatoriamente uno de los valores observados de la serie (todos con igual probabilidad de ser seleccionados). El procedimiento se repite para cada dato faltante, lo que puede resultar en diferentes imputaciones para distintos valores faltantes, incluso dentro de la misma brecha.

A diferencia de métodos determinísticos, la imputación aleatoria permite preservar, al menos parcialmente, la variabilidad de los datos, evitando la subestimación de la varianza que suele ocurrir en enfoques más simples, como la imputación por la media.

Entre sus ventajas, se destaca su simplicidad de implementación y su flexibilidad, ya que no requiere supuestos complejos sobre la estructura de los datos. Además, al introducir variabilidad en los valores imputados, permite reflejar en cierta medida la incertidumbre asociada a los datos faltantes.

Sin embargo, este método presenta importantes limitaciones, especialmente en el contexto de series temporales. En particular, no tiene en cuenta la dependencia temporal entre observaciones, como la autocorrelación o la estacionalidad, lo que puede generar imputaciones poco realistas. Asimismo, la naturaleza aleatoria del procedimiento puede introducir ruido artificial en la serie, afectando la coherencia de los datos imputados.

En resumen, este procedimiento puede resultar adecuado en contextos donde la serie no presenta una estructura temporal marcada, es decir, en ausencia de tendencias, estacionalidad o fuerte autocorrelación. Asimismo, su uso puede ser razonable cuando el porcentaje de datos faltantes es reducido o cuando se emplea como referencia en estudios comparativos. Sin embargo, su aplicabilidad es limitada en series con patrones temporales definidos, donde la preservación de la dinámica de la serie resulta fundamental.

3.4.2. Valor definido

La imputación por valor definido consiste en reemplazar los valores faltantes por un valor fijo previamente establecido. Este valor puede ser seleccionado con base en el conocimiento previo del fenómeno que se está modelando o por conveniencia en situaciones específicas.

Una de las principales características de este método es su naturaleza determinística, ya que, dado un conjunto de datos, siempre produce el mismo resultado. Además, se trata de un enfoque sumamente simple desde el punto de vista computacional, lo que facilita su implementación incluso en conjuntos de datos de gran tamaño. Sin embargo, esta simplicidad implica que el método no tiene en cuenta la estructura temporal de la serie ni las posibles relaciones entre las observaciones.

Este método presenta importantes limitaciones, ya que la imputación por un valor constante tiende a distorsionar la distribución de los datos, dado que introduce una concentración artificial de valores en el punto elegido. Esto puede afectar la estimación de parámetros, reducir la variabilidad de la serie y generar sesgos en el análisis. Además, al no considerar la dependencia temporal, los valores imputados pueden resultar inconsistentes con la dinámica de la serie. Por este motivo, la imputación por valor definido suele utilizarse en situaciones muy específicas o como punto de comparación, más que como una solución adecuada para preservar la información temporal de la serie.

3.4.3. Valor medio

El método de imputación por el valor medio es una técnica simple que consiste en reemplazar los valores faltantes en una serie temporal con el valor medio de los datos observados. El proceso es bastante directo: se calcula la media aritmética de los valores no faltantes de la serie, y este valor se utiliza para imputar todos los datos faltantes.

Dicho método se caracteriza por ser determinístico y de muy sencilla implementación, ya que solo requiere el cálculo de un estadístico resumen. Sin embargo, al igual que otros métodos simples, no tiene en cuenta la estructura temporal de la serie, ignorando posibles patrones como la tendencia, la estacionalidad o la autocorrelación.

Entre sus principales ventajas se destaca su simplicidad y rapidez de aplicación. Además, permite mantener el valor medio de la serie, lo cual puede resultar útil en ciertos análisis descriptivos donde la media es una medida de interés. Por otro lado, esta técnica presenta importantes desventajas. En particular, tiende a subestimar la variabilidad de los datos, ya que reemplaza múltiples valores por un mismo valor constante. Esto genera una reducción artificial de la varianza y puede distorsionar la distribución de la serie.

Estas limitaciones pueden afectar negativamente el desempeño de los modelos, ya que la alteración de la variabilidad y de la estructura temporal puede conducir a estimaciones sesgadas y a una menor precisión en las predicciones. Por este motivo, la imputación por la media suele considerarse como un método básico o de referencia, más que como una técnica adecuada cuando se busca preservar la dinámica temporal de la serie. Esta técnica es más adecuada para situaciones en las que la serie tiene pocos valores faltantes y los datos no presentan grandes variaciones a lo largo del tiempo.

Es importante destacar que este método constituye un caso particular de la imputación por valor definido, donde el valor elegido corresponde a la media de los datos observados.

3.4.4. Valor mediano

La imputación por la mediana consiste en reemplazar los valores faltantes de una serie por la mediana calculada a partir de las observaciones disponibles. Al igual que en el caso de la media, este método asigna un valor constante a todos los datos faltantes, sin considerar la posición temporal de las observaciones dentro de la serie, siendo también un caso particular de la imputación por valor definido.

Este método se caracteriza por ser determinístico y de fácil implementación, ya que requiere únicamente el cálculo de un estadístico resumen. Una de sus principales particularidades es su robustez frente a valores atípicos, dado que la mediana no se ve afectada por observaciones extremas en la misma medida que la media. Sin embargo, al igual que otros métodos simples, no tiene en cuenta la estructura temporal de la serie, ignorando patrones como la tendencia, la estacionalidad y la autocorrelación, pudiendo afectar negativamente el modelado y el pronóstico.

3.4.5. Valor modal

La imputación por la moda consiste en reemplazar los valores faltantes por el valor más frecuente entre las observaciones disponibles. Al igual que otros métodos basados en estadísticos resumen, este enfoque asigna un único valor constante a todos los datos faltantes, sin tener en cuenta la posición temporal de las observaciones dentro de la serie, siendo de igual manera un caso particular de imputación por valor definido.

En este caso, se trata de una técnica determinística y de sencilla implementación, ya que solo requiere identificar el valor con mayor frecuencia en la serie. Es particularmente útil en series temporales categóricas o discretas, donde ciertos valores ocurren repetidamente, y puede ser una opción efectiva si la serie tiene un valor dominante que se presenta con frecuencia. Sin embargo, en el contexto de series temporales continuas puede no ser informativa o incluso no estar claramente definida.

La imputación por la moda presenta varias limitaciones. En primer lugar, introduce una concentración artificial de valores en el valor modal, lo que puede distorsionar la distribución de los datos. Asimismo, no tiene en cuenta la variabilidad ni la estructura temporal de la serie, ignorando patrones como la tendencia, la estacionalidad o la autocorrelación. En el caso de series continuas, su uso puede resultar poco apropiado si no existe un valor claramente predominante. Estas limitaciones pueden afectar negativamente el modelado y el pronóstico.

3.4.6. Interpolación lineal

La interpolación lineal es un método de imputación que estima los valores faltantes utilizando la información de las observaciones vecinas, asumiendo que la evolución entre dos puntos consecutivos conocidos sigue una trayectoria lineal. En otras palabras, cuando se presenta un valor faltante entre dos observaciones disponibles, el método construye una recta que une dichos puntos y asigna al dato ausente el valor correspondiente sobre esa recta.

Formalmente, si y_t es un valor faltante ubicado entre dos observaciones conocidas y_{t_1} y y_{t_2} , con $t_1 < t < t_2$, la imputación se realiza como una combinación lineal de estos valores, proporcional a la distancia temporal entre ellos. De este modo, el valor imputado refleja una transición suave

y continua entre los puntos observados, respetando la estructura temporal de la serie. El valor imputado queda definido como:

$$\hat{y}_t = y_{t_1} + \frac{(t - t_1)(y_{t_2} - y_{t_1})}{t_2 - t_1} \quad (11)$$

Este método es particularmente adecuado cuando la serie presenta cambios graduales y relativamente suaves, sin variaciones abruptas en cortos períodos de tiempo. Su principal ventaja radica en su simplicidad y en su capacidad para preservar la continuidad de la serie, evitando saltos artificiales. Sin embargo, puede resultar inadecuado en presencia de patrones no lineales, como cambios bruscos, estacionalidad marcada o comportamientos altamente volátiles, ya que tiende a suavizar en exceso la dinámica real de los datos.

3.4.7. Interpolación spline

La interpolación spline es un método de imputación que estima los valores faltantes mediante funciones polinómicas definidas por tramos, en lugar de utilizar una única recta entre dos puntos. En este enfoque, la serie se aproxima mediante una sucesión de polinomios de bajo grado (habitualmente cúbicos) que se ajustan entre pares de observaciones consecutivas, garantizando que la función resultante sea suave en todo el dominio.

El proceso comienza dividiendo la serie en intervalos adecuados, generalmente entre puntos de datos consecutivos o en función de la distribución de los datos disponibles. Luego, para cada intervalo, se ajusta un polinomio spline que asegura la continuidad en los puntos de unión (nodos) y, dependiendo de las condiciones de borde especificadas, puede garantizar continuidad en las derivadas.

A diferencia de la interpolación lineal, que asume una evolución constante entre dos puntos, la interpolación spline permite capturar curvaturas en los datos. Esto se logra imponiendo condiciones de continuidad no solo en los valores de la función, sino también en sus derivadas, lo que genera transiciones más naturales entre los puntos observados. Como resultado, los valores imputados siguen trayectorias suaves que reflejan mejor la dinámica subyacente de la serie.

Dicho enfoque es especialmente útil en series temporales donde se esperan cambios graduales pero no necesariamente lineales, como en procesos con tendencias suaves o componentes estacionales. Entre sus ventajas se destacan su flexibilidad y su capacidad para modelar estructuras más complejas que la interpolación lineal. Sin embargo, es importante tener en cuenta que la precisión de la interpolación puede verse afectada por la elección de los intervalos y la adecuación de los polinomios spline a los datos disponibles. Además, puede presentar dificultades cuando los datos son muy ruidosos o cuando existen valores atípicos, ya que los splines pueden generar oscilaciones indeseadas (fenómeno conocido como sobreajuste local).

Mientras que la interpolación lineal impone una estructura rígida basada en cambios constantes entre observaciones, la interpolación spline introduce mayor flexibilidad al permitir curvaturas suaves, lo que puede resultar más adecuado en series con dinámica no lineal.

3.4.8. Interpolación de Stineman

La interpolación de Stineman es un método de imputación que construye una función suave entre observaciones conocidas, con el objetivo de evitar las oscilaciones indeseadas que pueden aparecer en otros métodos más flexibles, como los splines. A diferencia de la interpolación spline, que utiliza polinomios por tramos con condiciones de suavidad global, el método de Stineman se basa en pendientes locales calculadas a partir de los puntos vecinos, lo que le permite adaptarse de manera más controlada a la forma de la serie.

Este método combina la simplicidad de la interpolación lineal con una mayor capacidad para reflejar la curvatura de los datos. En lugar de imponer una recta entre dos puntos, ajusta la trayectoria utilizando información sobre la dirección y magnitud de los cambios en los valores adyacentes, generando transiciones suaves pero evitando cambios bruscos o sobreajustes. De esta manera, logra una interpolación que respeta la tendencia local sin introducir fluctuaciones artificiales.

El proceso comienza identificando los puntos de datos más cercanos a cada valor faltante en la serie. Estos puntos actúan como referencias para determinar la forma de la función de interpolación de Stineman. En lugar de asumir una relación lineal entre puntos adyacentes, Stineman ajusta una función no lineal que se adapta mejor a la estructura y las variaciones de los datos disponibles.

La función de interpolación se ajusta minimizando una medida de discrepancia, como el error cuadrático medio o una función de penalización que considera las diferencias locales entre puntos de datos. Este proceso garantiza que la interpolación capture adecuadamente las fluctuaciones locales y asegura una transición suave entre los puntos conocidos. Una vez ajustada esta función, se utiliza para calcular los valores faltantes en la serie temporal. Para cada punto de tiempo sin datos, se evalúa la función interpolada para obtener la imputación correspondiente.

La interpolación de Stineman resulta especialmente adecuada en series temporales donde se desea preservar la forma general de los datos sin asumir una estructura estrictamente lineal ni permitir excesiva flexibilidad. Entre sus ventajas se destacan su estabilidad numérica y su capacidad para evitar oscilaciones no realistas. Sin embargo, como desventaja, puede no capturar adecuadamente patrones complejos o altamente no lineales, y su uso es menos extendido en comparación con métodos más tradicionales.

La interpolación de Stineman puede interpretarse como un compromiso entre la rigidez de la interpolación lineal y la flexibilidad de los splines, ofreciendo una alternativa que prioriza la estabilidad y la forma global de la serie.

3.4.9. Media móvil simple

La imputación mediante media móvil simple es un método que estima los valores faltantes utilizando el promedio de un conjunto de observaciones vecinas de la serie temporal. A diferencia de métodos globales, como la imputación por la media total, este enfoque aprovecha información local de la serie, considerando únicamente valores cercanos al instante en el que ocurre el dato faltante. De esta manera, la imputación se adapta parcialmente a la dinámica temporal de los datos.

El procedimiento consiste en reemplazar cada observación faltante por el promedio de las k observaciones más próximas, donde k representa el tamaño de la ventana de la media móvil. En este trabajo, la imputación mediante media móvil simple se implementa utilizando una ventana centrada, considerando observaciones anteriores y posteriores al dato faltante. Sin embargo, pueden realizarse la

imputación únicamente con valores anteriores al dato faltante, únicamente posteriores o una combinación de ambos. Como resultado, el valor imputado refleja el comportamiento promedio reciente de la serie, suavizando fluctuaciones de corto plazo.

De esta manera, la estimación puede expresarse como:

$$\hat{y}_t = \frac{1}{k} \sum_{i=1}^k y_i \quad (12)$$

donde:

- $\hat{y}_t$ es el valor imputado,
- y_i las observaciones vecinas utilizadas,
- k es el tamaño de la ventana.

Este método resulta especialmente útil en series relativamente estables, con cambios suaves y sin variaciones abruptas, ya que permite preservar parcialmente la estructura temporal local. Entre sus principales ventajas se encuentran su simplicidad de implementación y su capacidad para reducir el impacto del ruido. No obstante, la media móvil tiende a suavizar excesivamente la serie, reduciendo su variabilidad natural y dificultando la representación de cambios bruscos, picos o puntos de inflexión. Además, la elección del tamaño de la ventana puede influir significativamente en los resultados: ventanas pequeñas generan imputaciones más sensibles a fluctuaciones locales, mientras que ventanas grandes producen estimaciones más estables pero menos adaptadas a la dinámica inmediata de la serie.

3.4.10. Media móvil lineal ponderada

La imputación mediante media móvil lineal ponderada es un método que estima los valores faltantes utilizando un promedio ponderado de las observaciones vecinas de la serie temporal. A diferencia de la media móvil simple, donde todas las observaciones consideradas tienen la misma importancia, en este enfoque se asignan pesos diferentes a cada valor de la ventana.

El procedimiento consiste en definir una ventana alrededor de la observación ausente y calcular un promedio ponderado de los valores disponibles dentro de dicha ventana. Los pesos varían de manera lineal según la distancia temporal respecto al dato faltante, de modo que las observaciones más próximas reciben un peso mayor y las más alejadas un peso menor. Esto permite que la imputación refleje de manera más precisa la dinámica local de la serie, especialmente cuando existen cambios graduales en el tiempo.

La estimación del valor faltante está dada por:

$$\hat{y}_t = \frac{\sum_{i=1}^k w_i y_i}{\sum_{i=1}^k w_i} \quad (13)$$

donde:

- $\hat{y}_t$ es el valor imputado,
- y_i las observaciones vecinas utilizadas,

- w_i son los pesos asignados a cada observación,
- k es el tamaño de la ventana.

Los pesos w_i suelen sumar uno para asegurar que la media ponderada esté normalizada y refleje adecuadamente la contribución relativa de cada valor observado en la imputación del valor faltante. Estos pesos pueden ser predefinidos, basados en la distancia temporal o calculados dinámicamente según la estructura de los datos y la distribución de los valores observados.

La estimación por media móvil simple es un caso particular, en el cual:

$$w_i = \frac{1}{k}, \quad \forall i \quad (14)$$

Por lo tanto, la media móvil lineal ponderada constituye una generalización de la media móvil simple.

Este método resulta adecuado en series temporales donde las observaciones cercanas presentan mayor similitud entre sí que las más distantes, situación frecuente en procesos con dependencia temporal moderada. Entre sus principales ventajas se destacan su simplicidad y su capacidad para adaptarse mejor a variaciones locales en comparación con la media móvil simple. Sin embargo, al igual que otros métodos basados en promedios, puede producir un efecto de suavización excesiva, reduciendo la variabilidad natural de la serie y dificultando la representación de cambios abruptos o valores extremos. Además, su desempeño depende de la elección del tamaño de la ventana y del esquema de ponderación utilizado.

3.4.11. Media móvil ponderada exponencial

La imputación mediante media móvil ponderada exponencial es un método que estima los valores faltantes utilizando un promedio ponderado de observaciones vecinas, asignando pesos que decrecen exponencialmente a medida que aumenta la distancia temporal respecto al dato faltante. De esta manera, las observaciones más cercanas tienen una influencia mayor sobre la imputación que las más alejadas, permitiendo capturar con mayor sensibilidad la estructura reciente de la serie temporal.

El procedimiento consiste en definir una ventana de observaciones alrededor del valor ausente y calcular un promedio ponderado utilizando pesos exponenciales. A diferencia de la media móvil lineal ponderada, donde los pesos disminuyen de manera lineal, en este enfoque la reducción es más rápida, concentrando la mayor parte de la información en las observaciones más próximas temporalmente. Esto resulta especialmente útil en series donde los valores recientes contienen información más relevante que los antiguos.

La expresión del valor imputado resulta igual a la imputación usando el método media móvil lineal ponderada. Sin embargo, en esta técnica, los pesos decrecen exponencialmente con la distancia temporal. Una forma habitual de representarlos es:

$$w_i = \alpha(1 - \alpha)^{i-1}, \quad 0 < \alpha < 1 \quad (15)$$

donde α es el parámetro de suavizamiento, encargado de controlar la rapidez con la que disminuyen los pesos. Valores elevados de α otorgan mayor importancia a las observaciones más recientes, mientras que valores pequeños producen un suavizado más paulatino.

Este método resulta particularmente adecuado en series temporales donde la información más reciente refleja de manera más precisa el comportamiento actual del proceso. Entre sus principales ventajas se encuentran su capacidad para adaptarse rápidamente a cambios locales y su mayor sensibilidad frente a variaciones recientes de la serie. Sin embargo, puede verse afectado por valores atípicos cercanos al dato faltante, debido al alto peso asignado a las observaciones más próximas. Además, la elección del parámetro de suavizamiento influye significativamente en los resultados obtenidos.

3.4.12. Última observación trasladada hacia adelante

La imputación mediante última observación trasladada hacia adelante (*Last Observation Carried Forward*, LOCF) es un enfoque sencillo y directo que consiste en reemplazar cada valor faltante con el último valor observado disponible. De esta manera, se asume que el valor de la serie permanece constante hasta que se dispone de un nuevo dato observado.

El procedimiento consiste en recorrer la serie temporal y, ante la presencia de una observación faltante, asignarle el valor correspondiente a la observación válida más reciente. En consecuencia, cuando existen varios valores faltantes consecutivos, todos ellos son reemplazados por la misma observación previa conocida.

Este método resulta especialmente útil en series temporales con alta persistencia o cambios lentos en el tiempo, donde las observaciones consecutivas tienden a presentar valores similares. Entre sus principales ventajas se destacan su simplicidad computacional y la preservación de valores reales observados, evitando introducir valores artificiales intermedios. Sin embargo, presenta importantes limitaciones. La utilización repetida de una misma observación puede generar tramos artificialmente constantes, reduciendo la variabilidad de la serie y distorsionando su dinámica temporal. Además, el método puede producir sesgos significativos cuando la serie presenta tendencias, estacionalidad o cambios bruscos, ya que asume implícitamente estabilidad temporal entre observaciones consecutivas.

3.4.13. Siguierte observación trasladada hacia atrás

La imputación mediante próxima observación trasladada hacia atrás (*Next Observation Carried Backward*, NOCB) es un método que reemplaza cada valor faltante utilizando la primera observación disponible posterior al instante faltante. En este enfoque, se asume que el valor observado en el futuro inmediato puede utilizarse como aproximación para los datos ausentes anteriores.

El procedimiento consiste en recorrer la serie temporal e imputar cada observación faltante con el valor válido más cercano ubicado posteriormente en el tiempo, en contraposición al método LOCF. En consecuencia, cuando existen varios valores faltantes consecutivos, todos ellos son reemplazados por la misma observación futura conocida.

Este método resulta adecuado en contextos donde las observaciones futuras pueden considerarse representativas de los valores faltantes previos o cuando se desea evitar la propagación de valores antiguos hacia adelante. Entre sus principales ventajas se encuentran su simplicidad de implementación y la preservación de valores reales observados. Sin embargo, al igual que LOCF, puede generar tramos artificialmente constantes y reducir la variabilidad natural de la serie. Además, puede resultar poco realista en series con tendencia o cambios abruptos, ya que utiliza información futura

para estimar observaciones pasadas, lo que puede introducir distorsiones en la dinámica temporal del proceso.

3.4.14. División estacional

La imputación mediante división estacional es un método que estima los valores faltantes aprovechando la estructura estacional presente en la serie temporal. Asume que los datos tienen un patrón estacional recurrente y utiliza este patrón para inferir los valores faltantes, lo que permite una imputación más precisa cuando la serie temporal tiene una fuerte estacionalidad.

El enfoque de este método se basa en dividir la serie temporal según los ciclos estacionales identificados, y luego imputar los valores faltantes dentro de cada ciclo en función de los valores observados correspondientes a las mismas posiciones estacionales en otros ciclos. La idea principal es que los valores en una misma fase de la estacionalidad (por ejemplo, el mismo mes en diferentes años) tienden a ser similares, por lo que los valores faltantes en una parte del ciclo estacional pueden ser imputados usando datos de otras partes del mismo ciclo en años o periodos anteriores o posteriores.

Este método resulta especialmente útil en series temporales con patrones estacionales marcados y relativamente estables en el tiempo, ya que permite preservar la estructura periódica de los datos durante el proceso de imputación. Entre sus principales ventajas se destaca su capacidad para mantener la estacionalidad de la serie, evitando distorsiones que podrían producir métodos más simples. Sin embargo, su desempeño depende de una correcta estimación del componente estacional y puede verse afectado en series con estacionalidad débil, cambiante o difícil de identificar. Además, requiere que la serie sea de una longitud suficientemente grande para estimar adecuadamente los patrones estacionales.

3.4.15. Descomposición estacional

La imputación mediante descomposición estacional es un método que estima los valores faltantes aprovechando la estructura interna de la serie temporal a través de la separación de sus componentes principales. Este enfoque parte de la idea de que una serie temporal puede representarse como la combinación de distintos componentes, generalmente tendencia, estacionalidad y ruido, los cuales pueden analizarse por separado para facilitar la imputación de observaciones ausentes.

El procedimiento consiste en descomponer la serie temporal en sus componentes estructurales mediante técnicas de descomposición aditiva o multiplicativa. Una vez obtenidos estos componentes, la imputación se realiza sobre la serie ajustada, es decir, sobre aquella en la que se ha eliminado temporalmente el componente estacional y/o de tendencia. Posteriormente, los componentes extraídos son reincorporados para reconstruir la serie original imputada.

Luego de realizar la descomposición, la imputación de los valores faltantes no se efectúa directamente sobre la serie original, sino sobre una versión ajustada de la misma, en la que se han removido temporalmente algunos de sus componentes estructurales, principalmente la tendencia y la estacionalidad. El objetivo de este procedimiento es simplificar la dinámica de la serie antes de realizar la imputación, obteniendo una componente residual más estable y sencilla de modelar.

Una vez eliminados estos componentes, los valores faltantes de la serie ajustada se estiman mediante métodos auxiliares de imputación o interpolación, como interpolación lineal, medias móviles u otros

procedimientos de suavizamiento. Posteriormente, los componentes previamente removidos son re-incorporados para reconstruir la serie temporal completa en su escala original. De esta manera, la imputación final conserva tanto la tendencia como los patrones estacionales presentes en la serie, evitando distorsionar su estructura temporal.

Este método resulta especialmente adecuado en series temporales que presentan patrones estacionales y tendencias claramente definidos, ya que permite preservar dichas estructuras durante la imputación. Entre sus principales ventajas se destacan su capacidad para mantener las características fundamentales de la serie y su flexibilidad para adaptarse a diferentes tipos de comportamiento temporal. Sin embargo, su desempeño depende de la calidad de la descomposición realizada y puede verse afectado cuando la serie presenta alta volatilidad, cambios estructurales o patrones estacionales poco estables. Además, requiere una cantidad suficiente de observaciones para estimar adecuadamente los componentes de la serie.

3.4.16. Suavizado de Kalman en un modelo estructural

Este enfoque captura la estructura interna de la serie, descomponiéndola en componentes como la tendencia, la estacionalidad y el ruido, lo que permite una imputación más precisa y coherente con la dinámica temporal subyacente de los datos. Una vez que la serie temporal se ha descompuesto en sus componentes estructurales, se reformula en un formato conocido como “espacio de estados”. En este marco, los componentes de la serie (como la tendencia o la estacionalidad) se tratan como estados no observados que evolucionan a lo largo del tiempo. A partir de esta representación, entra en juego el filtro de Kalman, que es un algoritmo diseñado para calcular estos estados ocultos basándose en las observaciones disponibles, incluso cuando hay datos faltantes.

Como se mencionó anteriormente, el filtro de Kalman funciona en dos etapas: predicción y actualización. En la fase de predicción, el filtro utiliza el modelo estructural para calcular los valores futuros de la serie basándose en los datos pasados y los estados estimados previamente. Cuando falta un valor en la serie, el filtro de Kalman puede seguir realizando estas predicciones sin necesidad de observaciones en ese punto específico, utilizando solo la información estructural y las observaciones adyacentes. Después, cuando el filtro encuentra nuevas observaciones, ajusta las predicciones iniciales en función de estos nuevos datos, mejorando así la precisión de las imputaciones.

Sin embargo, el verdadero poder de esta técnica se despliega cuando se aplica el suavizado de Kalman. Mientras que el filtro de Kalman se enfoca en predecir hacia adelante (de pasado a presente), el suavizado de Kalman revisa estas predicciones considerando también la información futura. Esto es crucial cuando hay valores faltantes, ya que no solo se utiliza la información previa al valor perdido, sino también las observaciones posteriores, lo que permite refinar las imputaciones de manera mucho más precisa.

Al descomponer la serie en componentes estructurales, el modelo es capaz de capturar patrones que otros métodos de imputación más simples no podrían. Además, el uso del filtro de Kalman permite hacer imputaciones en puntos donde faltan datos de manera precisa, sin necesidad de realizar supuestos fuertes sobre el comportamiento de los datos. El suavizado de Kalman, al aprovechar información tanto pasada como futura, hace que las imputaciones sean mucho más exactas que si solo se consideraran los datos anteriores al valor faltante.

Entre sus principales ventajas se destacan su sólido fundamento estadístico, su capacidad para incorporar simultáneamente tendencia y estacionalidad, y el aprovechamiento eficiente de toda la información temporal disponible. Además, al utilizar información tanto pasada como futura, suele

producir imputaciones más precisas que métodos más simples de interpolación o suavizamiento. Sin embargo, requiere una correcta especificación del modelo estructural y una longitud suficiente de la serie temporal para estimar adecuadamente sus componentes. Asimismo, su implementación resulta considerablemente más compleja y su desempeño puede verse afectado cuando la serie presenta alta irregularidad, cambios estructurales abruptos o patrones difíciles de modelar.

3.4.17. Representación del espacio en estados de ARIMA y suavizado de Kalman

La imputación mediante representación en espacio de estados de modelos ARIMA y suavizado de Kalman es un método que combina la capacidad de modelado de los procesos ARIMA con las técnicas de estimación recursiva del filtro y suavizado de Kalman. Este enfoque permite estimar valores faltantes utilizando la estructura de dependencia temporal propia de los modelos ARIMA, incorporando además información tanto pasada como futura de la serie temporal.

Los modelos ARIMA describen la evolución de una serie temporal a partir de relaciones autorregresivas, diferenciación e incorporación de componentes de medias móviles. Aunque tradicionalmente estos modelos se expresan mediante ecuaciones de series temporales, también pueden reformularse en el marco de espacio de estados. En esta representación, la dinámica del modelo queda expresada mediante estados no observables que evolucionan en el tiempo y generan las observaciones de la serie. En el apartado siguiente se presentarán estos modelos con mayor detalle.

A partir de esta formulación, el filtro de Kalman puede utilizarse para estimar recursivamente los estados del modelo y manejar naturalmente la presencia de observaciones faltantes. Cuando ocurre un dato ausente, el algoritmo continúa realizando predicciones utilizando únicamente la estructura estimada del modelo ARIMA y las observaciones disponibles. Posteriormente, cuando se incorporan nuevas observaciones, las estimaciones son ajustadas mediante el mecanismo de actualización del filtro.

Sin embargo, al igual que en los modelos estructurales, el mayor potencial del método surge al aplicar el suavizado de Kalman. Mientras que el filtro utiliza únicamente información pasada para estimar los estados del sistema, el suavizado incorpora además observaciones futuras, refinando las estimaciones de los valores faltantes. Como consecuencia, las imputaciones obtenidas resultan más consistentes con la dinámica global de la serie temporal.

Este método resulta especialmente útil en series temporales con fuerte dependencia temporal, ya que los modelos ARIMA permiten capturar relaciones dinámicas complejas entre observaciones consecutivas. Entre sus principales ventajas se destacan su sólido fundamento estadístico, su capacidad para manejar naturalmente datos faltantes y la utilización eficiente de toda la información disponible en la serie. Además, al incorporar la estructura propia del modelo ARIMA, las imputaciones suelen preservar adecuadamente la dinámica temporal de los datos.

No obstante, el desempeño del método depende de una correcta especificación del modelo ARIMA subyacente. Una elección inadecuada de los órdenes autorregresivos, de diferenciación o de medias móviles puede afectar significativamente la calidad de las imputaciones. Asimismo, su implementación resulta más compleja que la de métodos simples de interpolación o suavizamiento y puede presentar dificultades en series con cambios estructurales abruptos o comportamientos no lineales.

3.5. Técnicas de modelado

En el análisis de series temporales, los modelos pueden clasificarse de manera general en deterministas y estocásticos. Los primeros describen la evolución de la serie mediante reglas completamente especificadas, sin incorporar un término aleatorio explícito. En cambio, los modelos estocásticos incluyen una componente de aleatoriedad que permite representar la incertidumbre inherente a los datos y describir con mayor realismo la variabilidad observada en fenómenos temporales. Este ruido representa la variabilidad y la incertidumbre que no pueden explicarse únicamente por los valores pasados de la serie. Como resultado, las predicciones generadas por modelos estocásticos son probabilísticas, proporcionando una distribución de posibles valores futuros.

Uno de los casos mas simples de procesos estocásticos son los procesos ruido blanco, los cuales son una secuencia de datos completamente aleatorios, con una media constante, varianza constante y ninguna autocorrelación significativa en ningún rezago. Si una serie se comporta como ruido blanco, cualquier intento de modelarla utilizando enfoques que asumen dependencias temporales resultará en un modelo que no tiene capacidad predictiva y simplemente se ajustará al ruido. Antes de aplicar modelos que asuman estructuras temporales, es fundamental verificar si la serie muestra autocorrelación significativa o si, por el contrario, se trata de una secuencia aleatoria, lo que indicaría que no hay patrones temporales que puedan ser aprovechados para la predicción.

Los modelos deterministas presentan ciertas limitaciones, ya que pueden ser una simplificación excesiva de la realidad, ignorando la aleatoriedad inherente a muchos sistemas reales, lo que puede llevar a grandes diferencias en las predicciones si no se conocen con precisión estas condiciones. En cambio, una de las principales dificultades de los modelos estocásticos es la necesidad de estimar un gran número de parámetros, lo que puede llevar a problemas de sobreajuste si el modelo es demasiado complejo para los datos disponibles. Además, la incorporación de términos aleatorios puede hacer que la interpretación de los modelos sea más compleja y menos intuitiva.

Dentro de los enfoques deterministas y estocásticos, se incluyen varios modelos fundamentales en la modelización de series temporales, como los modelos autorregresivos, los de media móvil, y sus combinaciones, como los modelos ARMA, ARIMA y SARIMA. A continuación, se ofrece una descripción de cada uno de ellos.

3.5.1. Procesos Autorregresivos (AR)

La idea principal de los procesos autorregresivos es que el valor actual de la serie puede explicarse a partir de una combinación lineal de observaciones pasadas y un término aleatorio que representa perturbaciones no explicadas por el modelo.

Un modelo autorregresivo de orden p , denotado como $AR(p)$, supone que cada observación depende linealmente de las p observaciones inmediatamente anteriores. De esta manera, la dinámica de la serie queda determinada por su propia historia reciente. Formalmente, un proceso $AR(p)$ puede expresarse como:

$$Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + a_t \quad (16)$$

donde:

- Y_t representa el valor de la serie temporal en el instante t ,
- c es una constante,

- $\phi_1, \phi_2, \dots, \phi_p$ son los parámetros autorregresivos del modelo,
- a_t es un proceso ruido blanco, con media cero y varianza constante.

Los parámetros autorregresivos determinan la influencia que tienen las observaciones pasadas sobre el valor actual de la serie. En particular, valores elevados de estos coeficientes indican una fuerte dependencia temporal entre observaciones.

Estos modelos resultan especialmente útiles para describir series temporales con dependencia temporal persistente, donde los valores observados presentan correlación significativa con observaciones previas.

3.5.2. Procesos Promedio Móvil (MA)

Los procesos de media móvil constituyen otra clase fundamental de modelos estocásticos utilizados en series temporales. A diferencia de los modelos autorregresivos, donde el valor actual de la serie depende de observaciones pasadas, en los modelos de media móvil cada observación se expresa como una combinación lineal de errores pasados.

Un proceso de media móvil de orden q , denotado como $MA(q)$, supone que el valor observado en cada instante temporal depende de los errores ocurridos en los q períodos anteriores. La ecuación resulta:

$$Y_t = \mu + \theta_1 a_{t-1} + \theta_2 a_{t-2} + \dots + \theta_q a_{t-q} \quad (17)$$

donde:

- Y_t representa el valor de la serie temporal en el instante t ,
- μ es la media de la serie,
- $\theta_1, \theta_2, \dots, \theta_q$, son los parámetros del proceso media móvil y determinan el efecto que ejercen los errores pasados sobre el valor actual de la serie,
- a_t representa un proceso ruido blanco, con media cero y varianza constante.

Una característica importante de los procesos $MA(q)$ es que son siempre estacionarios, ya que se define como una combinación lineal de procesos estacionarios. Además, son conocidos como procesos de memoria corta, ya que presentan una estructura de dependencia temporal de corto plazo, dado que la influencia de los errores desaparece completamente luego de q períodos. Esto implica que su función de autocorrelación se anula después del rezago q . Por lo tanto, debido a su estructura de memoria corta, los modelos de media móvil son apropiados para representar series temporales donde la influencia de los errores decrece rápidamente y desaparece tras un número finito de períodos.

3.5.3. Procesos Autorregresivos de Media Móvil (ARMA)

Los procesos ARMA intentan combinar las propiedades de los procesos autorregresivos y de los promedio móvil, permitiendo representar series temporales cuya dinámica depende tanto de observaciones pasadas como de sus errores pasados.

En un modelo $ARMA(p, q)$, el valor actual de la serie temporal se expresa como una combinación lineal de las p observaciones previas y de los q errores aleatorios pasados. Formalmente, se expresa como:

$$Y_t = c + \sum_{i=1}^p \phi_i Y_{t-i} + \sum_{j=1}^q \theta_j a_{t-j} \quad (18)$$

cuyos componentes ya fueron definidos anteriormente.

La componente autorregresiva permite modelar la dependencia entre observaciones sucesivas, mientras que la componente de media móvil incorpora el efecto de variaciones aleatorias recientes. Gracias a esta combinación, los modelos $ARMA(p, q)$ poseen una mayor flexibilidad para representar distintos patrones de dependencia temporal presentes en las series. Por lo tanto, resultan adecuados para series temporales estacionarias que presentan tanto persistencia temporal como efectos transitorios de corto plazo.

3.5.4. Procesos Autorregresivos Integrados de Media Móvil (ARIMA)

Cuando la serie no es estacionaria, se utiliza el modelo Autorregresivo Integrado de Media Móvil (ARIMA). El término “integrado” significa que se aplica una diferenciación de orden d para hacer la serie estacionaria antes de aplicar los componentes AR y MA, permitiendo así eliminar tendencias u otros patrones no estacionarios presentes en la serie. La notación de un modelo ARIMA es $ARIMA(p, d, q)$, donde d es el número de diferencias necesarias para lograr estacionariedad.

La idea principal de los modelos ARIMA consiste en diferenciar la serie temporal un determinado número de veces hasta alcanzar estacionariedad y, posteriormente, modelar la serie transformada mediante un modelo ARMA. De esta manera, el modelo combina tres componentes fundamentales:

- una componente autorregresiva (AR),
- una componente de integración (I),
- una componente de media móvil (MA).

3.5.5. Procesos Estacionales, Autorregresivos Integrados de Media Móvil (SARIMA)

Los modelos autorregresivos integrados, de media móvil y estacionales, conocidos como modelos $SARIMA(p, d, q)(P, D, Q)_s$, constituyen una extensión de los modelos $ARIMA(p, d, q)$ diseñada para representar series temporales que presentan comportamiento estacional. Estos modelos permiten incorporar simultáneamente dependencia temporal de corto plazo, tendencia y patrones periódicos que se repiten regularmente en el tiempo.

La principal diferencia respecto de los modelos ARIMA radica en la inclusión de componentes estacionales autorregresivos, de diferenciación y de media móvil. De esta manera, el modelo es capaz de capturar relaciones temporales tanto entre observaciones consecutivas como entre observaciones separadas por un período estacional fijo.

3.6. Modelos de pronóstico

A diferencia del análisis predictivo convencional, que puede hacer hincapié en las variables explicativas para predecir un resultado, el pronóstico de series temporales busca estimar el comportamiento futuro de una variable a partir de sus valores históricos. Se pueden categorizar a grandes rasgos los problemas de series temporales de la siguiente manera: si se quiere pronosticar un paso de tiempo hacia adelante en el futuro, que es el caso más común de problemas de series temporales, se denomina predicción de un paso o de un solo paso. Por otro lado, si se hace una predicción que se adelanta varios pasos de tiempo en el futuro, se denomina predicción de varios pasos.

Formalmente, si se quiere pronosticar el valor Y_{T+K} , con $k > 0$, para una serie $Y_1, Y_2, \dots, Y_T$, se define $\hat{Y}_{T+K}$ como un predictor lineal de la observación Y_{T+K} , obtenido como función de las T observaciones, con origen de predicción T y horizonte de predicción k .

A continuación, se describen los modelos de predicción que serán comparados en cada situación.

3.6.1. Modelos ARIMA Y SARIMA

Los modelos ARIMA y SARIMA, descriptos anteriormente, constituyen algunas de las herramientas más utilizadas para el pronóstico de series temporales. Estos modelos permiten describir la dependencia temporal presente en los datos y proyectar dicha estructura hacia períodos futuros.

Una vez ajustado el modelo a la serie observada, los pronósticos se obtienen de manera recursiva utilizando las relaciones definidas por el propio modelo. En particular, las predicciones para horizontes futuros se construyen a partir de los valores observados y de los valores pronosticados en períodos anteriores. De esta forma, es posible generar estimaciones para distintos horizontes de pronóstico y obtener intervalos de predicción asociados.

Es importante destacar que estos modelos requieren series completas para su estimación. Por este motivo, las observaciones faltantes son reemplazadas previamente mediante los distintos métodos de imputación considerados en este trabajo. Una vez completada la serie, el modelo se ajusta sobre los datos imputados y se generan pronósticos para los distintos horizontes de predicción analizados.

La especificación del modelo se realiza de forma automática mediante el procedimiento implementado en la función `auto.arima()` del paquete `forecast` de R. Este algoritmo selecciona los órdenes autorregresivos, de diferenciación y de media móvil que optimizan determinados criterios de información, considerando además la posible presencia de componentes estacionales.

3.6.2. Modelo ETS

El modelo ETS (*Error, Trend, Seasonal*) se basa en el marco de modelos de espacio de estados para el suavizado exponencial. Este enfoque permite descomponer la serie temporal en tres componentes fundamentales: el Error, la Tendencia y la Estacionalidad.

La principal característica de este enfoque es que permite representar explícitamente cada uno de estos componentes mediante estructuras aditivas o multiplicativas, dando lugar a diferentes especificaciones del modelo. De esta manera, los modelos ETS son capaces de adaptarse a una amplia

variedad de comportamientos observados en series temporales, incluyendo series con tendencia creciente o decreciente, patrones estacionales de distinta intensidad y variabilidad dependiente del nivel de la serie.

A diferencia de los modelos ARIMA, que describen la dependencia temporal a través de relaciones entre observaciones y errores pasados, los modelos ETS se basan en la descomposición de la serie en componentes no observados que evolucionan a lo largo del tiempo. Esta formulación permite modelar de manera flexible la tendencia y la estacionalidad, actualizando continuamente sus estimaciones a medida que se incorporan nuevas observaciones.

La especificación del modelo se realiza utilizando la función `ets` del paquete `forecast` de R, la cual evalúa distintas combinaciones de componentes de error, tendencia y estacionalidad, seleccionando aquella que optimiza un criterio de información, generalmente el Criterio de Información de Akaike (AIC). Este procedimiento permite identificar de forma automática la estructura que mejor representa el comportamiento de la serie temporal entre un conjunto de modelos candidatos.

Al igual que los modelos ARIMA y SARIMA, requieren series completas para su estimación, por lo que los datos faltantes son imputados previamente mediante las técnicas consideradas en el estudio.

3.6.3. Modelo Prophet

El modelo **Prophet** es un procedimiento de pronóstico de código abierto basado en **modelos aditivos generalizados (GAM)**. A diferencia de los modelos autorregresivos tradicionales, Prophet aborda el pronóstico como un problema de ajuste de curvas, lo que lo hace muy robusto ante la presencia de valores atípicos (*outliers*) y periodos con datos faltantes. Es por esto que no es necesario utilizar un metodo de imputación para los valores faltantes.

Prophet está optimizado para las tareas de previsión empresarial halladas en Facebook, las cuales suelen tener alguna de las siguientes características:

- Observaciones horarias, diarias o semanales con al menos unos meses (preferiblemente un año) de historial.
- Fuertes estacionalidades múltiples a “escala humana”: día de la semana y época del año.
- Días festivos importantes que ocurren a intervalos irregulares y que se conocen con anticipación (por ejemplo, el *Super Bowl*).
- Un número razonable de observaciones faltantes o valores atípicos grandes.
- Cambios en las tendencias históricas, por ejemplo, debido a lanzamientos de productos o cambios en los registros.
- Tendencias que son curvas de crecimiento no lineales, donde una tendencia alcanza un límite natural o se satura.

Este algoritmo dispone de parámetros de suavizado para la estacionalidad que permiten ajustar la precisión con la que se ajustan a los ciclos históricos, así como parámetros de suavizado para las tendencias que permiten ajustar la intensidad con la que se siguen los cambios de tendencia históricos. Para las curvas de crecimiento, se pueden especificar manualmente las “capacidades” o el límite

superior de la curva, lo que permite incorporar información previa sobre cómo crecerá (o disminuirá) la previsión. Por último, se pueden especificar días festivos irregulares para el modelado.

Se plantea el modelo como uno de regresión aditiva, el cual puede descomponerse en cuatro componentes principales:

- **Tendencia:** Modela el crecimiento de la serie mediante funciones lineales o logísticas por tramos, detectando automáticamente puntos de cambio.
- **Estacionalidad:** Captura los efectos periódicos (como ciclos anuales, semanales o diarios) utilizando **series de Fourier**, lo que permite modelar patrones estacionales complejos de manera flexible.
- **Días festivos:** Permite incorporar el impacto de eventos irregulares o calendarios específicos.
- **Error:** Representa la varianza que no es explicada por los componentes anteriores.

Ajustando el componente de tendencia de forma más flexible, se modela la estacionalidad con mayor precisión y, como resultado, se obtiene un pronóstico más exacto. Para este método se prefieren modelos de regresión muy flexibles en lugar de un modelo de series temporales tradicional, ya que brinda mayor flexibilidad de modelado, facilita el ajuste del modelo y maneja mejor los datos faltantes o los valores atípicos.

Es importante destacar que este modelo, a diferencia de los modelos ARIMA, SARIMA y ETS, permite realizar los pronósticos con una serie incompleta. Por lo tanto, no es necesario imputar valores antes de elaborar los pronósticos.

3.7. Evaluación del desempeño

La precisión de los pronósticos se evaluará utilizando observaciones que no hayan sido empleadas en la estimación de los modelos. Para ello, se aplicará un enfoque de evaluación fuera de la muestra (*out-of-sample*), dividiendo los datos disponibles en dos conjuntos: datos de entrenamiento (*training set*) y datos de prueba (*test set*). Por otro lado, el error de imputación será calculado comparando los valores imputados con los valores reales de la serie.

Los datos de entrenamiento se utilizarán para la estimación de los parámetros de cada método de predicción, mientras que los datos de prueba se reservarán exclusivamente para evaluar su desempeño. Siguiendo la práctica habitual en el análisis de series temporales, se separarán las últimas observaciones de cada serie para conformar el conjunto de prueba (por ejemplo, en series de frecuencia mensual se reservarán las últimas 12 observaciones).

3.7.1. Evaluación del desempeño de los métodos de imputación

En una primera instancia se evaluará el desempeño de los métodos de imputación comparando los valores imputados con los valores originales de la serie antes de la introducción de datos faltantes. Para ello se utilizarán métricas de error como el error cuadrático medio (RMSE), el error absoluto medio (MAE) y el error porcentual absoluto medio (MAPE), que permiten cuantificar la capacidad de cada método para reconstruir adecuadamente los valores faltantes.

3.7.2. Evaluación del desempeño del pronóstico posterior

En una segunda etapa se evaluará el impacto de los métodos de imputación sobre el desempeño de los modelos de pronóstico. Para ello se ajustarán distintos modelos de series temporales sobre las series imputadas y se generarán pronósticos para un horizonte determinado. Posteriormente, los valores pronosticados se compararán con los valores reales mediante métricas de error como RMSE, MAE y MAPE.

3.7.3. Métricas del error

Para evaluar el desempeño tanto de los métodos de imputación como de los modelos de pronóstico se utilizarán distintas métricas de error comúnmente empleadas en el análisis de series temporales.

En este contexto, el error se define como la diferencia entre un valor observado y el valor estimado o pronosticado por el modelo. En particular, se considerarán el error cuadrático medio (RMSE), el error absoluto medio (MAE) y el error porcentual absoluto medio (MAPE), cuyas expresiones se presentan a continuación.

- Error absoluto medio (MAE): Esta métrica es una medida de la diferencia entre dos valores, es decir, permite saber que tan diferente es el valor predicho y el valor real u observado. Para que un error con valor positivo no cancele a un error con error negativo se usa el valor absoluto de la diferencia. Como interesa conocer el comportamiento del error de todas las observaciones y no solamente de una, entonces se obtiene el promedio de los valores absolutos de la diferencia.

$$MAE = \frac{\sum_{t=1}^n |\hat{y}_t - y_t|}{n_m}$$

- Error medio cuadrado (MSE) Esta métrica es muy útil para saber que tan cerca es la línea de ajuste de la regresión a las observaciones. Al igual que en caso anterior se evita que un error con valor positivo anule a uno con valor negativo, pero en lugar de usar el valor absoluto, se eleva al cuadrado la diferencia. Siempre da un valor positivo y entre más cercano sea a cero es mejor.

$$MSE = \frac{\sum_{t=1}^n (\hat{y}_t - y_t)^2}{n_m}$$

- Raíz del error medio cuadrado (RMSE) Como la métrica anterior da el resultado en unidades cuadradas, para poder interpretarlo más fácilmente se saca la raíz cuadrada y de esta manera se obtiene el valor en las unidades originales.

$$RMSE = \sqrt{\frac{\sum_{t=1}^n (\hat{y}_t - y_t)^2}{n_m}}$$

- Porcentaje de error medio absoluto (MAPE) Esta es una métrica de la precisión, pero se presenta como si fuera un porcentaje, como ventaja tiene que es independiente de la escala y fácil de interpretar. Como desventaja es que puede producir valores no definidos, infinito o muy cercanos a cero. El calculo es sencillo, para cada observación se obtiene su porcentaje de error y luego se calcula la media de todos esos valores.

$$MAPE = \frac{100}{n_m} \sum_{t=1}^n \left| \frac{y_t - \hat{y}_t}{y_t} \right|$$

siendo y_t el valor observado, $\hat{y}_t$ el valor imputado o pronosticado y n_m la cantidad de valores perdidos o pronosticados.

4. Aplicación

Con el objetivo de evaluar el impacto de distintos métodos de imputación sobre el desempeño de modelos de pronóstico en series temporales univariadas, se plantea un procedimiento experimental basado en la introducción controlada de datos faltantes en series originalmente completas. Esta estrategia permite conocer en todo momento los valores reales de las observaciones eliminadas y, en consecuencia, evaluar la calidad de las imputaciones realizadas y su efecto sobre la precisión de los pronósticos.

Se selecciona una serie temporal univariada completa, es decir, sin valores faltantes, y sobre esta se realiza un análisis exploratorio inicial con el fin de identificar sus principales características, tales como la presencia de tendencia, estacionalidad, posibles valores atípicos y estructura de autocorrelación. Asimismo, cada serie se divide en un conjunto de entrenamiento y un conjunto de prueba. El conjunto de entrenamiento se utiliza para realizar la imputación de los datos faltantes y ajustar los modelos de pronóstico, mientras que el conjunto de prueba permanece sin modificaciones y se emplea exclusivamente para evaluar la capacidad predictiva de los modelos.

A partir de las series de entrenamiento se generan artificialmente distintos escenarios de datos faltantes. Para ello se consideran diferentes porcentajes de observaciones ausentes y distintos mecanismos de generación de datos faltantes, reproduciendo situaciones que pueden presentarse en aplicaciones reales.

Una vez generados los escenarios de datos faltantes, se aplican los diferentes métodos de imputación considerados para reconstruir las observaciones ausentes. Con el propósito de reducir el efecto del azar asociado a la ubicación de los datos faltantes, cada combinación de serie, mecanismo y porcentaje de faltantes se replica 100 veces utilizando distintas configuraciones de eliminación aleatoria. De esta manera, los resultados obtenidos corresponden al promedio de un elevado número de iteraciones, proporcionando estimaciones más estables del desempeño de cada método.

La calidad de las imputaciones se evalúa comparando los valores imputados con las observaciones originales eliminadas artificialmente. Para cuantificar la precisión de cada método se utilizan las métricas RMSE, MAE y MAPE, anteriormente definidas.

Luego, utilizando las series imputadas, se ajustan los modelos de pronóstico considerados. Los pronósticos se generan para horizontes de $h=1, 3, 6$ y 12 períodos hacia adelante. Finalmente, el desempeño predictivo de cada modelo se evalúa comparando los valores pronosticados con las observaciones reales del conjunto de prueba mediante las mismas métricas de error utilizadas para

evaluar la imputación. Esto permite analizar no solo la capacidad de cada método para reconstruir los valores faltantes, sino también el impacto que dichas imputaciones tienen sobre la precisión de los pronósticos posteriores.

El procedimiento completo puede resumirse en las siguientes etapas:

- 1 - Selección de la serie temporal. Se seleccionan series temporales univariadas completas, que servirán como referencia para la generación de los escenarios experimentales.
- 2 - Análisis exploratorio de la serie. Se estudian las principales características de cada serie, incluyendo tendencia, estacionalidad, autocorrelación y posibles valores atípicos. Asimismo, se define la partición entre conjunto de entrenamiento y conjunto de prueba.
- 3 - Generación de datos faltantes. Se introducen valores faltantes de forma artificial sobre el conjunto de entrenamiento, considerando distintos porcentajes y mecanismos de generación de faltantes.
- 4 - Aplicación de los métodos de imputación. Se imputan las observaciones faltantes mediante las técnicas consideradas en el estudio.
- 5 - Evaluación de la imputación. Se comparan los valores imputados con los valores originales mediante las métricas RMSE, MAE y MAPE. Ajuste de los modelos de pronóstico. Se ajustan los modelos ARIMA/SARIMA y ETS utilizando las series imputadas, mientras que Prophet se ajusta directamente sobre la serie con datos faltantes.
- 6 - Generación de pronósticos. Se obtienen predicciones para horizontes de $h=1, 3, 6$ y 12 .
- 7 - Evaluación del pronóstico. Se comparan los pronósticos con las observaciones del conjunto de prueba utilizando las métricas RMSE, MAE y MAPE.
- 8 - Comparación de resultados. Se analizan conjuntamente los errores de imputación y de pronóstico para determinar el efecto que tienen los distintos métodos de imputación sobre el desempeño predictivo de cada modelo.

Caso de aplicación: Consumo de electricidad

La electricidad constituye un insumo esencial para el funcionamiento de la economía y el bienestar social. En particular, el análisis de la demanda de energía eléctrica resulta de gran interés para los organismos reguladores, las empresas proveedoras y los investigadores, ya que permite comprender los patrones de consumo.

En este trabajo se utilizará una serie temporal mensual de la demanda de electricidad en Argentina, cuya fuente primaria son los registros de CAMMESA y de la Secretaría de Energía de la Nación Argentina. La serie abarca mediciones mensuales desde enero de 2010 hasta diciembre de 2025, y cuenta con 300 observaciones, que reflejan el consumo eléctrico total del país en gigavatios-hora (en miles de GWh).

4.1. Análisis descriptivo

Se realizó una partición de la serie temporal en dos subconjuntos. Las observaciones comprendidas entre enero de 2010 y diciembre de 2024 conforman el conjunto de entrenamiento, utilizado para la especificación y ajuste del modelo. Por su parte, los datos de 2025 se reservaron como conjunto de prueba para evaluar la capacidad predictiva del modelo seleccionado sobre datos no utilizados en su estimación.




Figura 1: Demanda mensual de energía eléctrica en Argentina (2010–2024)

La Figura 1 muestra una tendencia creciente en la demanda a lo largo del período analizado, aunque dicha tendencia no es estrictamente lineal.

En 2020 se observa un evento atípico: un quiebre o shock estructural asociado a la pandemia de COVID-19. Por otro lado, en marzo de 2023 se observa un pico de demanda asociado a condiciones climáticas extremas (ola de calor).

En la Figura 2 se observa que antes del 2015 la demanda fue aumentando con el paso de los años, entre 2015 y 2019 la demanda se mantuvo relativamente estable, mientras que en 2020 se produjo una caída marcada con mayor dispersión, asociada al impacto de la pandemia. A partir de 2021, la mediana anual comienza a incrementarse de forma sostenida, alcanzando máximos en 2023–2024. Asimismo, en los años más recientes se evidencia una mayor variabilidad intraanual, lo cual refleja la aparición de episodios extremos de consumo, como olas de calor e inviernos más intensos.

En la Figura 3 se observa que la serie tiene un patrón claramente estacional, donde en cada año se ven picos y valles recurrentes, típicos de la demanda energética que depende del clima (veranos con aire acondicionado, inviernos con calefacción eléctrica). La amplitud de los picos varía con el tiempo, mostrando un aumento de la estacionalidad en los últimos años.

La Figura 4 evidencia la presencia de un componente estacional anual en la demanda eléctrica. Se observan picos en los meses de marzo y enero, asociados a olas de calor, y valores mínimos en abril. Las medias mensuales confirman un patrón recurrente de consumo que se repite año tras año.




Figura 2: Distribución de la demanda eléctrica por año




Figura 3: Gráfico estacional de la serie por año




Figura 4: Gráfico estacional de la serie por mes




Figura 5: Función de autocorrelación de la serie

De la Figura 5 se puede decir que la autocorrelación no decae rápidamente, lo cual indica la presencia de dependencia a largo plazo (tendencia y/o estacionalidad). Además, las autocorrelaciones positivas en los primeros rezagos sugieren que la demanda de un mes está muy relacionada con los meses inmediatamente anteriores.

Se observan picos significativos en rezagos múltiplos de 12 meses, lo cual evidencia la estacionalidad anual de la serie.




Figura 6: Función de autocorrelación parcial de la serie

Por otro lado, en la Figura 6 se observan valores distintos de cero en los primeros rezagos, indicando la importancia de términos autorregresivos de bajo orden (AR).

Al igual que en la ACF, aparecen picos en rezagos estacionales (12, 24, ...), lo cual confirma la estacionalidad anual.

4.2. Resultados

Tabla 1: Errores de imputación (Escenario 10 % MCAR)

Método	RMSE	MAE	MAPE
random	1.948	1.615	15.285
replace	10.834	10.782	100.000
mean	1.078	0.877	8.172
median	1.089	0.875	8.044
mode	2.564	2.338	20.902
ilinear	0.750	0.583	5.387
ispline	0.860	0.656	6.124
istine	0.758	0.583	5.385
masimple	1.041	0.894	8.275
malinear	0.958	0.816	7.551
maexp	0.882	0.743	6.870
lof	1.011	0.833	7.728
nocb	1.020	0.834	7.653
seadec	0.497	0.362	3.321
seasplit	0.568	0.434	3.985
kalmans	0.523	0.400	3.697
kalmana	0.553	0.411	3.763

Tabla 2: 10 % MCAR, pronosticando con ARIMA

Método	h=3			h=6			h=12		
	RMSE	MAE	MAPE	RMSE	MAE	MAPE	RMSE	MAE	MAPE
random	1.014	0.931	7.197	1.005	0.914	7.629	0.931	0.802	6.717
replace	2.604	2.450	18.923	2.171	1.869	14.952	2.003	1.688	13.671
mean	0.961	0.841	6.454	0.830	0.731	6.005	0.689	0.568	4.706
median	0.961	0.848	6.521	0.831	0.738	6.069	0.692	0.574	4.765
mode	1.349	1.211	9.294	1.257	1.095	8.969	1.173	0.980	8.069
ilinear	0.889	0.788	6.050	0.767	0.688	5.683	0.636	0.537	4.490
ispline	0.852	0.759	5.830	0.750	0.671	5.569	0.628	0.532	4.467
istine	0.879	0.779	5.970	0.764	0.684	5.649	0.635	0.536	4.475
masimple	0.944	0.837	6.447	0.842	0.753	6.251	0.708	0.602	5.055
malinear	0.924	0.821	6.324	0.815	0.733	6.077	0.684	0.581	4.877
maexp	0.920	0.816	6.273	0.800	0.719	5.943	0.667	0.566	4.735
lof	0.842	0.764	5.910	0.773	0.701	5.851	0.668	0.575	4.843
nocb	0.944	0.832	6.391	0.804	0.711	5.869	0.657	0.549	4.593
seadec	0.848	0.765	5.893	0.730	0.664	5.477	0.600	0.507	4.230
seasplit	0.802	0.725	5.632	0.723	0.661	5.468	0.602	0.507	4.229
kalmans	0.846	0.762	5.896	0.730	0.656	5.380	0.605	0.496	4.103
kalmana	0.819	0.738	5.719	0.733	0.663	5.480	0.609	0.510	4.253

Tabla 3: 10 % MCAR, pronosticando con ETS

Método	h=3			h=6			h=12		
	RMSE	MAE	MAPE	RMSE	MAE	MAPE	RMSE	MAE	MAPE
random	1.085	0.924	7.077	0.906	0.763	6.224	0.722	0.574	4.726
replace	2.650	2.507	19.410	2.211	1.909	15.271	1.954	1.647	13.348
mean	1.125	0.954	7.292	0.915	0.756	6.092	0.728	0.550	4.445
median	1.136	0.967	7.393	0.922	0.762	6.130	0.741	0.557	4.491
mode	1.304	1.150	8.841	1.056	0.863	6.881	0.839	0.650	5.247
ilinear	1.113	0.964	7.380	0.892	0.739	5.940	0.697	0.524	4.243
ispline	1.063	0.925	7.088	0.853	0.711	5.739	0.679	0.513	4.169
istine	1.110	0.963	7.374	0.888	0.736	5.922	0.693	0.519	4.196
masimple	1.108	0.934	7.128	0.912	0.761	6.161	0.728	0.559	4.546
malinear	1.124	0.951	7.264	0.917	0.760	6.141	0.726	0.552	4.481
maexp	1.127	0.961	7.344	0.912	0.757	6.101	0.721	0.546	4.425
lof	1.030	0.878	6.707	0.856	0.711	5.747	0.686	0.526	4.291
nocb	1.156	1.009	7.737	0.913	0.762	6.136	0.708	0.538	4.360
seadec	1.043	0.880	6.730	0.835	0.689	5.563	0.670	0.495	3.999
seasplit	1.037	0.862	6.600	0.830	0.678	5.473	0.663	0.483	3.898
kalmans	1.062	0.883	6.749	0.850	0.690	5.556	0.675	0.492	3.969
kalmana	1.046	0.869	6.645	0.835	0.679	5.472	0.668	0.486	3.918

Tabla 4: 10 % MCAR, pronosticando con Prophet

Modelo	h=3			h=6			h=12		
	RMSE	MAE	MAPE	RMSE	MAE	MAPE	RMSE	MAE	MAPE
Prophet	0.827	0.640	5.022	0.761	0.644	5.527	0.641	0.554	4.836

Tabla 5: Errores de imputación (Escenario 25 % MCAR)

Método	RMSE	MAE	MAPE
random	1.952	1.618	15.273
replace	10.824	10.771	100.000
mean	1.077	0.872	8.137
median	1.088	0.869	8.005
mode	2.544	2.312	20.690
ilinear	0.844	0.666	6.176
ispline	0.980	0.751	6.999
istine	0.847	0.663	6.144
masimple	1.069	0.911	8.442
malinear	0.994	0.841	7.799
maexp	0.933	0.781	7.242
lof	1.101	0.892	8.275
nocb	1.095	0.889	8.206
seadec	0.580	0.426	3.933
seasplit	0.603	0.452	4.164
kalmans	0.553	0.420	3.894
kalmana	0.592	0.433	3.987

Tabla 6: 25 % MCAR, pronosticando con ARIMA

Método	h=3			h=6			h=12		
	RMSE	MAE	MAPE	RMSE	MAE	MAPE	RMSE	MAE	MAPE
random	1.345	1.171	8.926	1.267	1.120	9.315	1.149	0.992	8.299
replace	4.533	4.434	34.573	3.874	3.628	29.551	3.687	3.466	28.736
mean	1.231	1.076	8.244	1.136	1.000	8.214	1.025	0.849	6.993
median	1.270	1.113	8.527	1.164	1.019	8.350	1.060	0.868	7.114
mode	2.008	1.806	13.855	1.704	1.429	11.434	1.550	1.238	9.949
ilinear	1.044	0.934	7.173	0.948	0.833	6.918	0.824	0.692	5.796
ispline	0.993	0.886	6.824	0.931	0.814	6.803	0.817	0.681	5.718
istine	1.029	0.917	7.036	0.928	0.815	6.776	0.800	0.672	5.629
masimple	1.164	1.015	7.755	1.169	1.046	8.784	1.081	0.938	7.896
malinear	1.133	0.994	7.612	1.131	1.010	8.454	1.050	0.903	7.575
maexp	1.084	0.962	7.386	1.068	0.958	8.029	0.977	0.841	7.072
lof	1.020	0.902	6.939	1.073	0.949	8.013	1.002	0.854	7.213
nocb	1.122	1.002	7.698	1.065	0.949	7.925	0.961	0.819	6.868
seadec	0.828	0.749	5.774	0.743	0.665	5.519	0.625	0.526	4.405
seasplit	0.777	0.677	5.301	0.756	0.661	5.516	0.640	0.524	4.385
kalmans	0.837	0.750	5.849	0.746	0.650	5.349	0.633	0.508	4.210
kalmana	0.811	0.706	5.538	0.796	0.689	5.758	0.676	0.556	4.660

Tabla 7: 25 % MCAR, pronosticando con ETS

Método	h=3			h=6			h=12		
	RMSE	MAE	MAPE	RMSE	MAE	MAPE	RMSE	MAE	MAPE
random	1.220	1.075	8.244	1.038	0.882	7.195	0.875	0.709	5.840
replace	4.480	4.404	34.347	3.857	3.638	29.647	3.668	3.466	28.734
mean	1.243	1.076	8.218	1.026	0.861	6.958	0.850	0.659	5.328
median	1.280	1.115	8.529	1.049	0.875	7.033	0.872	0.670	5.390
mode	1.782	1.651	12.759	1.449	1.206	9.562	1.259	1.040	8.410
ilinear	1.245	1.128	8.666	1.016	0.865	6.982	0.837	0.659	5.340
ispline	1.215	1.120	8.635	0.988	0.848	6.848	0.817	0.649	5.271
istine	1.261	1.148	8.834	1.024	0.872	7.029	0.843	0.661	5.353
masimple	1.177	1.016	7.750	1.017	0.876	7.188	0.855	0.703	5.816
malinear	1.191	1.028	7.848	1.011	0.862	7.035	0.842	0.680	5.586
maexp	1.221	1.069	8.172	1.018	0.864	7.012	0.845	0.673	5.488
lof	1.011	0.882	6.739	0.908	0.780	6.392	0.786	0.630	5.178
nocb	1.333	1.218	9.386	1.062	0.909	7.362	0.867	0.700	5.714
seadec	1.097	0.966	7.422	0.885	0.745	6.022	0.704	0.544	4.428
seasplit	0.997	0.833	6.467	0.819	0.673	5.478	0.663	0.498	4.069
kalmans	1.023	0.861	6.608	0.839	0.698	5.668	0.673	0.516	4.222
kalmana	1.052	0.892	6.872	0.851	0.695	5.611	0.685	0.513	4.167

Tabla 8: 25 % MCAR, pronosticando con Prophet

Modelo	h=3			h=6			h=12		
	RMSE	MAE	MAPE	RMSE	MAE	MAPE	RMSE	MAE	MAPE
Prophet	0.838	0.658	5.153	0.779	0.657	5.641	0.638	0.546	4.753

Tabla 9: Errores de imputación (Escenario 40 % MCAR)

Método	RMSE	MAE	MAPE
random	1.891	1.556	14.662
replace	10.830	10.776	100.000
mean	1.094	0.887	8.284
median	1.105	0.883	8.135
mode	2.521	2.279	20.356
ilinear	0.925	0.738	6.844
ispline	1.165	0.872	8.087
istine	0.932	0.739	6.847
masimple	1.085	0.920	8.530
malinear	1.023	0.860	7.976
maexp	0.979	0.814	7.553
locf	1.147	0.928	8.603
nocb	1.169	0.953	8.783
seadec	0.671	0.503	4.651
seasplit	0.653	0.485	4.484
kalmans	0.579	0.442	4.102
kalmana	0.628	0.459	4.226

Tabla 10: 40 % MCAR, pronosticando con ARIMA

Método	h=3			h=6			h=12		
	RMSE	MAE	MAPE	RMSE	MAE	MAPE	RMSE	MAE	MAPE
random	1.505	1.303	9.916	1.366	1.191	9.846	1.235	1.058	8.794
replace	6.154	6.083	47.582	5.469	5.298	43.700	5.281	5.130	42.997
mean	1.424	1.244	9.493	1.275	1.109	9.080	1.157	0.961	7.882
median	1.500	1.312	10.005	1.330	1.144	9.318	1.205	0.983	8.016
mode	2.543	2.399	18.516	2.085	1.784	14.173	1.909	1.577	12.658
ilinear	1.297	1.153	8.830	1.229	1.071	8.891	1.123	0.940	7.825
ispline	1.290	1.140	8.725	1.258	1.086	9.072	1.161	0.975	8.176
istine	1.308	1.157	8.859	1.236	1.069	8.854	1.130	0.942	7.821
masimple	1.321	1.127	8.557	1.283	1.124	9.419	1.178	1.021	8.605
malinear	1.282	1.100	8.359	1.262	1.109	9.310	1.159	1.006	8.489
maexp	1.272	1.093	8.315	1.250	1.096	9.191	1.148	0.990	8.330
locf	1.236	1.061	8.086	1.269	1.105	9.321	1.172	1.008	8.533
nocb	1.373	1.191	9.076	1.283	1.116	9.273	1.169	0.995	8.296
seadec	0.977	0.871	6.684	0.877	0.767	6.372	0.740	0.619	5.192
seasplit	0.891	0.743	5.895	0.871	0.711	5.924	0.737	0.571	4.766
kalmans	0.925	0.812	6.373	0.829	0.701	5.761	0.716	0.567	4.707
kalmana	0.948	0.789	6.233	0.935	0.760	6.322	0.800	0.627	5.240

Tabla 11: 40 % MCAR, pronosticando con ETS

Método	h=3			h=6			h=12		
	RMSE	MAE	MAPE	RMSE	MAE	MAPE	RMSE	MAE	MAPE
random	1.388	1.222	9.336	1.212	1.047	8.591	1.055	0.883	7.301
replace	6.137	6.070	47.483	5.466	5.306	43.790	5.282	5.138	43.092
mean	1.404	1.245	9.522	1.165	0.985	7.952	0.988	0.781	6.313
median	1.452	1.299	9.951	1.195	1.006	8.086	1.017	0.796	6.403
mode	2.241	2.121	16.436	1.850	1.599	12.767	1.659	1.418	11.517
ilinear	1.484	1.373	10.572	1.209	1.033	8.329	1.017	0.819	6.643
ispline	1.536	1.452	11.228	1.241	1.068	8.605	1.041	0.843	6.845
istine	1.527	1.426	11.002	1.232	1.052	8.455	1.037	0.834	6.749
masimple	1.314	1.142	8.703	1.160	1.004	8.264	0.999	0.836	6.930
malinear	1.338	1.178	9.001	1.157	0.997	8.167	0.991	0.819	6.746
maexp	1.394	1.247	9.553	1.175	1.004	8.161	1.002	0.812	6.636
lof	1.105	0.973	7.441	1.040	0.894	7.376	0.930	0.764	6.337
nocb	1.656	1.551	11.982	1.310	1.120	9.024	1.098	0.898	7.291
seadec	1.252	1.152	8.883	1.021	0.873	7.062	0.832	0.659	5.365
seasplit	0.956	0.794	6.332	0.887	0.711	5.889	0.751	0.563	4.669
kalman	1.004	0.872	6.807	0.844	0.702	5.720	0.706	0.544	4.471
kalmana	1.065	0.915	7.173	0.919	0.751	6.130	0.764	0.585	4.809

Tabla 12: 40 % MCAR, pronosticando con Prophet

Modelo	h=3			h=6			h=12		
	RMSE	MAE	MAPE	RMSE	MAE	MAPE	RMSE	MAE	MAPE
Prophet	0.876	0.687	5.370	0.807	0.668	5.675	0.658	0.547	4.717

5. Conclusiones

6. Bibliografía

- Arrioja, N. *Métricas en regresión*. <https://medium.com/@nicolasarrioja/métricas-en-regresión-5e5d4259430b>
- Benavides, I. F., Santacruz, M., Romero-Leiton, J. P., Barreto, C., & Selvaraj, J. J. (2023). Assessing methods for multiple imputation of systematic missing data in marine fisheries time series with a new validation algorithm. *Aquaculture and Fisheries*, 8(5), 587-599. <https://doi.org/https://doi.org/10.1016/j.aaf.2021.12.013>
- Hyndman, R. J., & Athanasopoulos, G. (2018). *Forecasting: Principles and Practice*. OTexts.
- Mandeville, P. B. (2010). Tema 24: Observaciones perdidas. *Ciencia UANL*, 13(3), 313-324.
- Moritz, S., Sardá, A., Bartz-Beielstein, T., Zaefferer, M., & Stork, J. (2015). Comparison of different methods for univariate time series imputation in R. *arXiv*.
- Niako, N., Melgarejo, J. D., Maestre, G. E., & Vatcheva, K. P. (2024). Effects of missing data imputation methods on univariate blood pressure time series data analysis and forecasting with ARIMA and LSTM. *BMC Medical Research Methodology*, 24(1), 320. <https://doi.org/https://doi.org/10.1186/s12874-024-02448-3>
- Q2B Studio. *Manejo de datos faltantes en R: guía de imputación con MICE*. <https://www.q2bstudio.com/nuestro-blog/25440/manejo-de-datos-faltantes-en-r-guia-de-imputacion-con-mice>
- R. J., & Athanasopoulos, G. (2018). *Forecasting: Principles and Practice*. OTexts.
- Román Radó, G. (2017). *Los valores perdidos en el muestreo de poblaciones finitas: Técnicas de imputación* [Trabajo Fin de Máster, Universidad de Vigo]. http://eio.usc.es/pub/mte/descargas/Proyectos_FinMaster/Proyecto_1468.pdf
- Tamplin, L. (2025). *Evaluación de métodos de imputación de datos faltantes en series temporales univariadas* [Tesis de grado]. Universidad Nacional de Rosario.
- Taylor, S. J., & Letham, B. (2018). Forecasting at scale. *The American Statistician*.
- Wu, S.-F., Chang, C.-Y., & Lee, S.-J. (2015). Time series forecasting with missing values. *2015 1st International Conference on Industrial Networks and Intelligent Systems (INISCom)*.
- Xian, X., Wang, L., Wu, X., & Tang, X. (2023). Comparison of SARIMA model, Holt-Winters model and ETS model in predicting the incidence of foodborne disease. *BMC Infectious Diseases*, 23(1), 803.

7. Anexo